# *Análisis de información generada en las plataformas educativas a partir de herramientas de Inteligencia Artificial*

Universidad Internacional de Valencia

00 Mes 2026

Titulación:

MIAR – Máster universitario en inteligencia artificial

Curso académico

2025 – 2026

Alumno/a:

Michael Laudrup Luis González

Directora de TFM: Irma Zoraida Sanabria Cárdenas

De:
Planeta Formación y Universidades

# Índice

Resumen ..... 9

Abstract ..... 10

1. Introducción ..... 11

2. Objetivos ..... 12

2.1. Objetivo General ..... 12

2.2. Objetivos Específicos ..... 12

3. Marco teórico y estado del arte ..... 14

3.1. Marco teórico ..... 14

3.1.1. Minería de Datos Educativos (EDM) y Learning Analytics. ..... 14

3.1.2. Heterogeneidad de datos y estándares ..... 15

3.1.3. Deserción frente a bajo rendimiento ..... 16

3.1.4. Aprendizaje No Supervisado: Descubrimiento de Patrones (Clustering) ..... 17

3.1.5. Aprendizaje Supervisado y Modelos de Ensamble. ..... 17

3.1.6. Síntesis del marco teórico ..... 18

3.2. Estado del arte. ..... 19

3.2.1. Aprendizaje no supervisado en EDM. ..... 19

3.2.2. Aprendizaje supervisado en EDM. ..... 20

3.2.3. El enfoque híbrido. ..... 22

3.2.4. Inteligencia Artificial Explicable (XAI) en Educación. ..... 23

3.2.5. Síntesis del estado del arte ..... 24

4. Planteamiento del problema y metodología ..... 25

4.1. Planteamiento del problema. ..... 25

4.2. Solución propuesta. ....26
4.2.1. Ventanas de tiempo. ....26
4.2.2. Reducción de dimensionalidad y Aprendizaje no supervisado. ....27
4.2.3. Modelado secuencial con Transformer. ....28
4.2.4. IA Explicativa. ....29
4.2.5. Ecosistema completo ....30
4.3. Metodología. ....31
4.3.1. Metodología CRISP-DM. ....31
4.3.2. Definición de tareas. ....32
4.3.3. Planificación. ....34
5. Desarrollo del proyecto. ....35
5.1. Comprensión del negocio. ....35
5.2. Análisis exploratorio de datos (EDA). ....37
5.3. Preprocesamiento de datos. ....42
5.3.1. Preprocesamiento para EDA. ....43
5.3.2. Preprocesamiento para Autoencoder y clustering. ....44
5.3.3. Preprocesamiento para red neuronal Transformer. ....45
5.4. Ingeniería de características. ....46
5.4.1. Fase I: Características para Autoencoder. ....46
5.4.2. Fase II: Características para Transformers. ....48
5.5. Modelado. ....50
5.5.1. Autoencoder. ....50
5.5.2. Embeddings. ....52
5.5.3. Clustering. ....53

5.5.4. Transformer I: Modelado....57
5.5.5. Transformer II: Influencia de características. ....59
5.5.6. Transformer III: Estrategia del entrenamiento. ....62
5.6. Evaluación....64
5.6.1. Evaluación de Autoencoder. ....64
5.6.2. Evaluación de Clustering....65
5.6.3. Evaluación del Transformer. ....66
5.7. Dockerización y Pipelines Automatizados ....68
6. Resultados....70
6.1. Resultados de Autoencoder. ....70
6.1.1. Fidelidad de reconstrucción. ....70
6.1.2. Representaciones vectoriales (Embeddings)....73
6.2. Resultados de clustering. ....74
6.3. Resultados en Transformer....77
6.3.1. Clasificación binaria: Aprobar vs Abandonar. ....77
6.3.2. Otros tipos de clasificación. ....80
6.4. IA Explicable (XAI) en clustering. ....81
6.5. IA Explicativa en el modelo secuencial Transformer. ....83
6.5.1. Valores SHAP estáticos....83
6.5.2. Valores SHAP dinámicos....86
6.5.3. Mapas de atención....87
7. Conclusiones....88
7.1. Conclusiones para trabajar en proyectos reales de IA ....89
8. Referencias....91

Apéndice I: Repositorio de Código y Reproducibilidad ..... 94

Apendice II: Tablas de características ..... 97

Características del autoencoder. ..... 97

Características del Transformer. ..... 99

Apéndice III: Métricas de entrenamiento en Transformers. ..... 105

Resultados en clasificación binaria (Existo vs Fracaso) ..... 105

Resultados clasificación trinaria (éxito, suspenso, abandono) ..... 105

Clasificación cuaternaria (Éxito, abandono, suspenso, sobresaliente). ..... 106

Apéndice IV: Descripción de campos de SHAP ..... 107

Anexos I: Estructura y diccionario de datos OULAD. ..... 110

# Índice de ilustraciones

Ilustración 1 Diagrama de Deep Clustering Network (DCN) https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10047866.....28

Ilustración 2 Diagrama representativo de la arquitectura del proyecto.....30

Ilustración 3 Cronograma de tareas definidas. Elaboración propia .....34

Ilustración 4 Distribución de estudiantes por resultado académico. Autoría propia - Apéndice 1 - Notebook I .....39

Ilustración 5 Análisis comparativo de de interacciones: Ruido diario frente a señal semanal agregada. Autoría propia - Apendice I - Notebook I.....39

Ilustración 6 Contraste entre riqueza y resultados académicos - Autoría Propia - Apéndice I - Notebook I.....40

Ilustración 7 Comparación de interacciones por curso. Autoría propia - Apéndice I - Notebook I .....41

Ilustración 8 Relación entre diferentes métricas y resultados académicos. Apéndice 1 - Notebook I.....41

Ilustración 9 Relación entre nivel educativo y resultados académicos Apéndice 1 – Notebook I.....42

Ilustración 10 Comparación BIC/AIC en PCA Autoría propia - Apéndice I - Notebook 4 .....54

Ilustración 11 Evolución BIC/AIC con AE - Autoría propia - Apéndice I - Notebook 4 .....54

Ilustración 12 Comparativa de resultados en diferentes métricas entre AE y PCA.....¡Error! Marcador no definido.

Ilustración 13 Resultados al inyectar variables sociodemográficas.....59

Ilustración 14 Resultados de inyectar variables asociadas al clustering.....60

Ilustración 15 Influencia de variables acumulativas en resultados de entrenamiento.....60

Ilustración 16 Evolución de huber loss durante entrenamiento de autoencoder .....70
Ilustración 17 Evolución de perdidas en la fase de entrenamiento conjunto ...71
Ilustración 18 Evolución de Sillouette y Davies-Bounldir en la fase 3 .....72
Ilustración 19 Representación de datos de estudiantes en el espacio original, latente y reconstrucción - Autoría Propia - Apéndice I - Reportes -AE.....73
Ilustración 20 Agrupación de estudiantes a 1 semana de curso .....74
Ilustración 21 Agrupaciones de estudiantes por grupos .....75
Ilustración 22 Distribución de resultados académicos por perfil en la semana 20 (Validación y Test) .....76
Ilustración 23 Matriz Z-Effect de las 30 variables más discriminativas por clúster (W12) .....81

# Índice de tablas

Tabla 1 Métricas obtenidas en clasificación binaria (Éxito vs Abandono) .....77

Tabla 2 Ficha técnica de repositorio código fuente .....94

Tabla 3 Características de entrada al autoencoder .....99

Tabla 4 Métricas de entrenamiento del transformer clase binaria (Exito vs Fracaso) .....105

Tabla 5 Resultados del transformer en clasificación binaria. .....106

Tabla 6 Descripción de datos de estudiantes .....110

Tabla 7 Descripción de entrega de actividades .....111

Tabla 8 Descripción datos de interacción de estudiantes .....112

# Resumen

# Abstract

# 1. Introducción

La digitalización de los procesos de enseñanza-aprendizaje ha situado a los sistemas de gestión del aprendizaje (LMS) como infraestructuras centrales para organizar y monitorizar la actividad académica. En este contexto, Moodle (*Modular Object-Oriented Dynamic Learning Environment*) destaca por su adopción extendida y flexibilidad, especialmente en entornos presenciales y a distancia (Gamage, Ayres, & Behrend, 2022)- Esta adopción genera una huella digital detallada: cada interacción del estudiante —accesos, participación, entregas o navegación— queda registrada en forma de *logs*, útiles para analizar comportamientos y modelar fenómenos como retención o carga de trabajo (Soepriyanto, Nugroho, Nahri, Kesuma, & Setiasih, 2025). Sin embargo, su explotación pedagógica sigue siendo limitada: el profesorado carece de herramientas operativas para identificar tempranamente perfiles de aprendizaje y alumnado en riesgo, y muchas decisiones se toman cuando la intervención ya es tardía. En consecuencia, el LMS tiende a funcionar como una "caja negra" difícil de traducir en acciones docentes, lo que refuerza la necesidad de sistemas inteligentes que conviertan los *logs* en señales interpretables y útiles para la prevención del fracaso académico (Khosravi, y otros, 2022)

El presente Trabajo de Fin de Máster (TFM) aborda esta problemática mediante técnicas de Inteligencia Artificial (IA) y Minería de Datos Educativos (EDM), orientadas a extraer conocimiento accionable a partir de datos de interacción en LMS, con especial atención a la detección temprana del riesgo académico. La memoria se organiza en ocho capítulos, que recorren de forma secuencial el planteamiento del problema, los objetivos y fundamentos teóricos del estudio, la metodología propuesta, el desarrollo técnico de la solución, el análisis de resultados obtenidos y la documentación complementaria incluida en los anexos.

# 2. Objetivos

Tras identificar la brecha existente entre la recolección masiva de datos en entornos virtuales y su aprovechamiento pedagógico, este capítulo formaliza los objetivos que guían la investigación. Para ello, se definen metas que equilibran la capacidad predictiva de los modelos híbridos con la transparencia necesaria para su aplicación en el contexto docente.

## 2.1. Objetivo General

Implementar una arquitectura híbrida de aprendizaje profundo aplicada a datos de interacción generados en un LMS (dataset OULAD), con el fin de detectar de forma temprana el riesgo de abandono académico y proporcionar al profesorado una caracterización interpretable de los perfiles de aprendizaje. Para ello, el sistema combina técnicas de aprendizaje no supervisado, modelado secuencial con Transformers y métodos de inteligencia artificial explicable.

## 2.2. Objetivos Específicos

- Analizar la evolución del estado del arte en minería de datos educativos, contrastando las limitaciones de los métodos lineales clásicos (PCA, Regresión) frente a las capacidades de las arquitecturas profundas (*deep Learning*) para modelar la complejidad del comportamiento estudiantil.

- Tratar el conjunto de datos OULAD, transformando los registros brutos de interacción en secuencias temporales que permitan modelar la evolución del comportamiento del estudiante en el LMS, superando el uso de métricas estáticas y facilitando su tratamiento mediante arquitecturas Transformer.

- Implementar una arquitectura de Autoencoders (Aprendizaje de Representaciones) para transformar los datos de alta dimensionalidad en un espacio latente comprimido, capaz de capturar relaciones no lineales que escapan a técnicas tradicionales como el PCA.

- Aplicar técnicas de aprendizaje no supervisado mediante algoritmos de clustering sobre distintas representaciones comprimidas de los datos —espacio latente aprendido por Autoencoder y espacio reducido mediante PCA— con el objetivo de segmentar la población estudiantil e identificar arquetipos de aprendizaje emergentes. Por razones de concisión, en esta memoria se presentan únicamente los resultados obtenidos con el modelo de Mixturas Gaussianas (GMM), mientras que el análisis comparativo con otros algoritmos, como K-Means o Clustering jerárquicos, se documentan en los notebooks de exploración.

- Implementar modelos de predicción secuencial basados en Transformers (Aprendizaje Supervisado), aprovechando el mecanismo de Autoatención (*Self-Attention*) para detectar dependencias a largo plazo en el curso.

- Desplegar una estrategia de Explicabilidad Dual (XAI) para mitigar el problema de la "caja negra", combinando explicabilidad intrínseca mediante la visualización de mapas de atención y explicabilidad agnóstica mediante valores SHAP, con el fin de identificar los momentos clave del curso y cuantificar la contribución individual y global de las variables en la predicción del riesgo académico.

- Diseñar un marco de "Explicaciones Accionables", traduciendo los hallazgos técnicos (pesos de atención y valores SHAP) en recomendaciones pedagógicas concretas que permitan al docente realizar intervenciones personalizadas.

# 3. Marco teórico y estado del arte

Este capítulo presenta, en primer lugar, el marco teórico que sustenta la investigación en Minería de Datos Educativos (EDM) y Analítica de Aprendizaje (LA). A continuación, se revisa el estado del arte reciente sobre el uso de estas técnicas en entornos educativos digitales, con especial atención a los trabajos basados en el dataset OULAD.

## 3.1. Marco teórico

A continuación, se desarrolla el marco conceptual que define la Minería de Datos Educativos (EDM) y la Analítica de Aprendizaje (LA), así como los principales conceptos metodológicos sobre los que se apoya este trabajo: heterogeneidad de datos, clustering, aprendizaje supervisado y modelado secuencial.

### 3.1.1. Minería de Datos Educativos (EDM) y Learning Analytics.

La minería de datos educativos (EDM, Educational Data Mining) y la analítica del aprendizaje (LA, Learning Analytics) son técnicas que utilizan el análisis de datos para mejorar los procesos educativos. Para ello se extraen patrones y tendencias del rendimiento, el comportamiento y las interacciones de los estudiantes. Estas disciplinas optimizan los procesos de aprendizaje, identifican a los estudiantes con sus dificultades y logran personalizar las experiencias de aprendizaje (Instituto Andaluz Interuniversitario en Ciencia de Datos e Inteligencia Computacional (DASCI), s.f.).

Para materializar estas promesas, es fundamental comprender el origen de la información. Como se detalla en la revisión fundamental sobre EDM

publicada en la revista *Modelling*, el primer paso crítico en cualquier ciclo de minería de datos es la recolección de registros provenientes de los "entornos educativos" donde interactúan los estudiantes (Papadogiannis, Wallace, & Karountzou, 2024). Estos entornos, principalmente los Sistemas de Gestión de Aprendizaje (LMS), actúan como la fuente primaria que alimenta los algoritmos.

### 3.1.2. Heterogeneidad de datos y estándares

En la actualidad existen una gran diversidad de instituciones educativas con plataformas educativas en línea. Cada una de estas plataformas tiene su propio sistema de gestión del aprendizaje, es decir, su propia manera de recolectar datos de los estudiantes, de estructurar la información y de delimitar qué tipo de datos tienen mayor relevancia sobre otros, así como la relación entre estos. Esta falta de estandarización en la captura y estructuración de los datos plantea un desafío metodológico significativo: la dificultad para replicar estudios y generalizar hallazgos entre distintos entornos tecnológicos (Gašević, Dawson, Rogers, & Gasevic, 2016).

A consecuencia de esta situación, se establece un marco de referencia común que garantice la validez externa y la comparabilidad de los resultados (benchmarking). En este contexto, el conjunto de datos OULAD (*Open University Learning Analytics Dataset*) se ha consolidado como un conjunto de datos de referencia ampliamente utilizado en la investigación sobre Minería de Datos Educativos. Este dataset destaca no solo por su amplia adopción en la literatura científica, sino por su riqueza multidimensional y su proceso de tratamiento y certificación garantizando la anonimidad de los datos. Integra datos demográficos, resultados de evaluación y registros detallados de interacción (*logs*) generados en el Entorno Virtual de Aprendizaje (*VLE*) de la Open University durante los cursos académicos 2013 y 2014. (Kuzilek, Hlosta, & Zdrahal, 2017)

Si bien han surgido conjuntos de datos más recientes en los últimos años, su idoneidad para la presente investigación es limitada. Gran parte de los datasets actuales (procedentes de competiciones tipo Kaggle o plataformas MOOC específicas) presentan inconvenientes críticos: o bien se trata de datos sintéticos generados artificialmente para sortear regulaciones de privacidad —lo que compromete la fidelidad del comportamiento humano real—, o bien carecen de la documentación académica rigurosa necesaria para sustentar una investigación formal. Asimismo, alternativas masivas como EdNet se centran excesivamente en el trazado de conocimiento (Knowledge Tracing) a nivel de ítem, alejándose de la estructura general de interacción típica de Moodle que este trabajo pretende modelar. Por tanto, OULAD se mantiene como un recurso idóneo para validar modelos predictivos en entornos LMS tradicionales, cuya relevancia continúa siendo reconocida en los inventarios de datos de la literatura científica actual (Papadogiannis, Wallace, & Karountzou, 2024).

### 3.1.3. Deserción frente a bajo rendimiento

En el ámbito del *Learning Analytics* es crucial diferenciar entre la deserción (dropout) y el bajo rendimiento (failure).

La deserción se define como el cese de la actividad en la plataforma y la desvinculación formal del curso antes de su finalización. Este fenómeno suele estar asociado a factores motivacionales, gestión del tiempo o insatisfacción con el entorno. En el dataset OULAD, esto se representa mediante la etiqueta Withdrawn (retirada). Por el contrario, el bajo rendimiento se refiere a aquellos estudiantes que, completando el ciclo del curso y participando en las evaluaciones, no alcanzan los estándares mínimos de conocimiento, etiquetados como Fail.

Distinguir estos dos fenómenos es fundamental para la modelización computacional, ya que los patrones de interacción que preceden a un abandono (ej. disminución progresiva de accesos) difieren sustancialmente de los patrones de un estudiante que suspende (ej. accesos constantes, pero bajo desempeño en cuestionarios). Un sistema robusto debe ser capaz de diagnosticar ambos riesgos por separado.

### 3.1.4. Aprendizaje No Supervisado: Descubrimiento de Patrones (Clustering)

El Aprendizaje No Supervisado es una rama de la Inteligencia Artificial donde el modelo trabaja con datos no etiquetados, buscando estructuras ocultas o patrones intrínsecos en la información. A diferencia de la clasificación, donde se le dice al algoritmo "este es un buen alumno", el clustering agrupa a los estudiantes basándose únicamente en la similitud de sus comportamientos (ej. frecuencia de accesos, horarios de conexión, tipos de recursos visitados). Esto permite identificar arquetipos de estudiantes (perfiles) que no son evidentes a simple vista, como "el estudiante intensivo de fin de semana" o "el estudiante que solo lee foros, pero no participa".

### 3.1.5. Aprendizaje Supervisado y Modelos de Ensamble.

El aprendizaje supervisado agrupa técnicas de modelado predictivo entrenadas con datos etiquetados, es decir, registros en los que se conoce la variable objetivo. En minería de datos educativos, estas técnicas permiten predecir resultados como el rendimiento académico o el riesgo de abandono a partir de información previa del estudiante.

- Modelos lineales: establecen relaciones directas entre las variables de entrada y la variable objetivo. Métodos como la regresión logística

destacan por su simplicidad, interpretabilidad y bajo coste computacional.

- Modelos de ensamble (Ensemble Learning): combinan múltiples modelos base para mejorar la capacidad predictiva. Entre ellos destacan Random Forest y los algoritmos de *gradient boosting*, especialmente adecuados para datos tabulares estructurados y para capturar relaciones no lineales entre variables.

- Modelos secuenciales y Transformers: cuando los datos presentan una dimensión temporal, se abre la oportunidad de explorar modelos capaces de procesar secuencias. En este grupo se incluyen las redes recurrentes, como RNN y LSTM, y los Transformers, basados en mecanismos de autoatención (*self-attention*) que permiten identificar relaciones entre eventos distantes dentro de una misma secuencia.

En conjunto, el aprendizaje supervisado proporciona la base conceptual para construir modelos predictivos adaptados a distintas estructuras de datos y objetivos analíticos en contextos educativos.

### 3.1.6. Síntesis del marco teórico

En síntesis, el marco teórico expuesto muestra que las técnicas no supervisadas y supervisadas responden a finalidades distintas pero complementarias dentro del análisis educativo. Mientras el clustering permite descubrir estructura latente en los datos, los modelos supervisados permiten formular predicciones sobre resultados académicos. Esta base conceptual servirá como referencia para analizar, en la siguiente sección, cómo la literatura reciente ha aplicado y combinado estos enfoques.

## 3.2. Estado del arte.

La literatura científica reciente en minería de datos educativos ha evolucionado desde la aplicación aislada de algoritmos básicos hacia arquitecturas cada vez más complejas orientadas a la personalización. Para contextualizar la contribución de este TFM, esta sección analiza las investigaciones más relevantes de los últimos cinco años que han utilizado el dataset OULAD. El análisis se estructura focalizándose en la evolución metodológica: partiendo de los enfoques puramente exploratorios (no supervisados) y predictivos (supervisados), hasta llegar a las propuestas híbridas más vanguardistas. Asimismo, se identifican las limitaciones recurrentes en los estudios actuales —específicamente en la reducción de dimensionalidad y la interpretabilidad— que permiten delimitar la aportación de este trabajo.

### 3.2.1. Aprendizaje no supervisado en EDM.

En el contexto específico del dataset OULAD, la investigación más reciente no solo valida la eficacia de las técnicas de clustering, sino que las posiciona como herramientas indispensables para la personalización educativa. Un ejemplo es el estudio publicado por El Ghali, Atouf, El Guemmat, Broumi, & Talea (2025), quienes profundizaron en la segmentación estratégica de estudiantes utilizando este conjunto de datos. Su investigación contrastó algoritmos basados en vecindad (KNN) frente al clustering jerárquico, empleando PCA (Análisis de Componentes Principales) para gestionar la alta dimensionalidad de las variables demográficas y de interacción.

Los resultados presentados por El Ghali et al. marcan el estándar del estado del arte actual: la aplicación del PCA no solo redujo el tiempo de cómputo en un 60%, sino que, combinado con clustering jerárquico, permitió alcanzar métricas de calidad excepcionales. Mediante esta metodología, lograron

identificar cuatro arquetipos de estudiantes, revelando perfiles complejos como aquellos con "alta participación, pero bajo rendimiento" o patrones de compromiso erráticos (El Ghali, Atouf, El Guemmat, Broumi, & Talea, 2025). Estos hallazgos sugieren que el dataset OULAD contiene estructura y regularidades aprovechables para la segmentación de perfiles estudiantiles.

### 3.2.2. Aprendizaje supervisado en EDM.

La evolución de los modelos predictivos aplicados a OULAD muestra un desplazamiento progresivo desde clasificadores lineales hacia métodos de ensamble y, más recientemente, hacia enfoques secuenciales de deep learning. Esta transición resulta coherente con la propia naturaleza del dataset, que combina variables demográficas, resultados de evaluación e interacciones registradas en el LMS a lo largo del tiempo.

- Modelos lineales: En una primera etapa, los estudios aplicados a OULAD recurrieron a clasificadores lineales, como la regresión logística, útiles como referencia inicial por su sencillez interpretativa y bajo coste computacional, pero limitados para capturar relaciones complejas y no lineales del comportamiento estudiantil.

- Modelos de ensamble: Posteriormente, la literatura se orientó hacia métodos de ensamble, especialmente Random Forest y algoritmos de gradient boosting, al mostrar un mejor rendimiento sobre datos tabulares estructurados. En esta línea, Hasan et al. (2020) evidencian que Random Forest puede superar a técnicas clásicas y a redes neuronales simples en tareas de clasificación del rendimiento, mientras que Firat (2025) reporta mejores resultados de XGBoost frente a Random Forest en su configuración experimental. No obstante, estos enfoques dependen en gran medida de la ingeniería manual de características y de la forma en que se

agregan los registros del LMS —por semana, día, tipo de actividad o curso—, de modo que la secuencia de aprendizaje queda reducida a variables acumuladas y puede perderse información temporal relevante.

- Modelado secuencial y Transformers: Más recientemente, la literatura ha incorporado modelos capaces de preservar la dimensión temporal de las interacciones del estudiante, tratando los registros del LMS como series temporales. En esta línea, las redes recurrentes, especialmente LSTM, han mostrado resultados competitivos en predicción temprana del riesgo académico; por ejemplo, Torkhani y Rezgui (2025) obtienen alrededor de un 83 % de accuracy, superando a varios enfoques clásicos en su comparación.

  De forma complementaria, Junejo y otros. (2024) amplían el análisis a escenarios multiclase —pass, fail, withdrawn y distinction— y muestran que las redes neuronales mejoran la predicción temprana cuando integran información demográfica, evaluaciones y clickstream mediante un preprocesado y feature engineering más exhaustivos. Sobre esta base, estudios más recientes exploran arquitecturas Transformer, cuyos mecanismos de autoatención permiten ponderar la relevancia de cada evento del curso en relación con el resto de la secuencia y capturar dependencias a largo plazo.

  Kusumawardani y Alfarozi (2023) reportan resultados competitivos sobre OULAD en configuraciones diarias y semanales, destacando además ventajas asociadas a la paralelización del entrenamiento, mientras que Luo, Yu, Xie, Wu y Xu (2024) obtienen un rendimiento alto y estable en predicción temprana del abandono (withdrawal) mediante secuencias semanales de actividad. Estas evidencias se sitúan en continuidad con trabajos previos que ya subrayaban la relevancia de preservar la evolución

temporal del comportamiento estudiantil en OULAD (Kuzilek, Hlosta, & Zdrahal, 2017).

En conjunto, la literatura muestra una evolución desde modelos de ensamble sobre variables agregadas hacia enfoques secuenciales, especialmente Transformers, más adecuados para capturar la dimensión temporal del aprendizaje y mejorar la predicción temprana del riesgo académico. No obstante, la atención se considera una señal explicativa complementaria, por lo que suele recomendarse su combinación con técnicas de explicabilidad agnósticas.

### 3.2.3. El enfoque híbrido.

Los modelos híbridos representan la vanguardia en la minería de datos educativos, combinando técnicas no supervisadas y supervisadas en una arquitectura secuencial. A diferencia de los modelos monolíticos tradicionales, el enfoque híbrido segmenta primero la población mediante clustering para luego entrenar predictores especializados en cada perfil.

Esta estrategia ha sido validada empíricamente por Al-Tameemi et al. (2024) quienes demostraron que el uso de clústeres previos mejora significativamente la precisión de la clasificación en entornos educativos. No obstante, existe un patrón recurrente en la literatura de vanguardia, observado tanto en Al-Tameemi et al. como en El Ghali et al. (2025): la omnipresencia del PCA como técnica estándar de reducción de dimensionalidad, lo que implica una presuposición de que la relación entre los datos es lineal.

Dado que el aprendizaje humano es un proceso complejo y dinámico, la asunción de linealidad puede resultar limitante en ciertos contextos y simplificar relaciones potencialmente más ricas en los datos. Esta limitación abre una línea de investigación relevante: explorar arquitecturas de Autoencoders como

alternativa no lineal de reducción de dimensionalidad, con el fin de analizar si permiten obtener representaciones latentes más expresivas que las derivadas de PCA.

### 3.2.4. Inteligencia Artificial Explicable (XAI) en Educación.

Tal como se adelantó al finalizar el análisis sobre los modelos supervisados y la arquitectura Transformer, la búsqueda de una mayor precisión predictiva conlleva la creación de "cajas negras", modelos con estructuras complejas que no son fácilmente interpretables (Khosravi, y otros, 2022). En el ámbito educativo, un modelo que predice el fracaso con un 90% de acierto pero que no explica las causas es pedagógicamente estéril, ya que impide al docente diseñar una intervención correctiva fundamentada. La literatura define esto como la necesidad de generar "explicaciones accionables" (*actionable explanations*), entendidas como datos que permiten establecer un procedimiento correctivo o bucle de retroalimentación para un conjunto de acciones (Khosravi, y otros, 2022).

Estudios recientes coinciden en que la adopción efectiva de la Minería de Datos Educativos depende de la confianza del usuario final, siendo la explicabilidad un factor clave para incrementarla. Sin embargo, los modelos avanzados de *Deep Learning*, como LSTM o Autoencoders, operan mediante transformaciones no lineales complejas que dificultan la comprensión de la relación entre entrada y salida, incluso para expertos, debido a la geometría de sus espacios de alta dimensión (Sejnowski, 2020). Esta opacidad limita la capacidad del docente para interpretar las causas subyacentes de una predicción de riesgo.

Para mitigar esta problemática sin renunciar a la potencia de los modelos no lineales, la literatura reciente propone combinar estrategias de explicabilidad intrínseca y técnicas agnósticas al modelo, en línea con el marco XAI-ED:

- Explicabilidad Intrínseca (*Attention Maps*): Las matrices de pesos de atención (*self-attention weights*) pueden visualizarse para identificar en qué momentos del curso o actividades específicas se apoya el modelo al estimar el riesgo del estudiante, aportando una señal interpretativa complementaria (Khosravi, y otros, 2022).
- Explicabilidad Agnóstica del Modelo (*SHAP*): Para garantizar una interpretación global, se utilizarán valores SHAP (*Shapley Additive exPlanations*). Esta técnica, fundamentada en la teoría de juegos, permite asignar una puntuación de contribución a cada variable, desvelando qué características empujaron la predicción hacia el éxito o el fracaso y distribuyendo equitativamente la importancia entre ellas.

### 3.2.5. Síntesis del estado del arte

La revisión bibliográfica sobre OULAD identifica tres líneas recurrentes en la literatura reciente: el predominio de técnicas lineales de reducción de dimensionalidad, la creciente incorporación de modelos secuenciales para preservar la evolución temporal de la actividad del estudiante y la necesidad de integrar mecanismos de explicabilidad en sistemas predictivos complejos. No obstante, estas aproximaciones suelen aparecer de forma parcial o aislada, por lo que persiste un vacío en torno a propuestas que combinen de manera coherente reducción de dimensionalidad no lineal, aprendizaje no supervisado, modelado secuencial y explicabilidad dentro de un mismo sistema orientado a la detección temprana del riesgo académico.

# 4. Planteamiento del problema y metodología.

Este capítulo detalla el desarrollo técnico de un sistema para la detección temprana del riesgo académico utilizando datos propios de un LMS, concretamente el dataset OULAD. Partiendo de las limitaciones actuales en el aprovechamiento pedagógico de los registros de los LMS, se propone una solución basada en una arquitectura híbrida que combina aprendizaje no supervisado y modelado secuencial. Todo el proceso se estructura bajo la metodología CRISP-DM, abarcando las fases de preprocesamiento, entrenamiento y evaluación, con un enfoque especial en asegurar la interpretabilidad de los resultados para su aplicación práctica por parte del equipo docente.

## 4.1. Planteamiento del problema.

Tal y como se ha fundamentado en los capítulos previos, aunque los LMS registran una "huella digital" exhaustiva de cada estudiante (Soepriyanto, Nugroho, Nahri, Kesuma, & Setiasih, 2025), , persiste una brecha crítica entre esta recolección masiva de datos y su verdadero aprovechamiento pedagógico. Para contextualizar la necesidad del sistema propuesto, esta problemática se desglosa en los siguientes ejes fundamentales:

- Opacidad y falta de interpretabilidad: Los LMS y los modelos predictivos avanzados suelen operar como "cajas negras" (Khosravi et al., 2022), dificultando la extracción de explicaciones claras y pedagógicamente útiles para el profesorado.
- Detección tardía: Falta de herramientas para identificar de forma temprana a estudiantes en riesgo de fracaso o abandono, cuando la intervención ya no es efectiva.

- Limitación en el modelado temporal: Predominio de enfoques basados en métricas estáticas acumuladas que ignoran la naturaleza secuencial del aprendizaje e impiden detectar cambios conductuales indicativos de riesgo.

Se requiere, por tanto, un sistema inteligente que prediga el rendimiento final de manera explicable, transformando los datos brutos en conocimiento accionable para facilitar la intervención del docente.

## 4.2. Solución propuesta.

Al abordar un problema de detección temprana de riesgo, uno de los desafíos metodológicos es evitar la "fuga de datos" (*data leakage*). Para que el modelo predictivo sea válido y aplicable a la realidad docente, es indispensable garantizar que solo evalúe la información generada desde el inicio del curso (Día 0) hasta el momento exacto en el que se realiza la predicción.

### 4.2.1. Ventanas de tiempo.

Esta limitación hace necesario introducir el concepto de ventana de tiempo, un enfoque fundamental para estructurar el análisis en este proyecto. Como ya se observó en el Análisis Exploratorio de Datos (EDA), el registro diario de interacciones presenta un nivel de ruido que dificulta la extracción de patrones claros. Sin embargo, al agregar la actividad de los estudiantes de forma semanal, el comportamiento se vuelve mucho más estable y manejable. Esta decisión de diseño concuerda con los hallazgos de Kusumawardani y Alfarozi (2023), quienes demostraron empíricamente que los modelos basados en ventanas semanales tienden a superar a los diarios y resultan computacionalmente más eficientes.

A partir de este punto, la temporalidad del problema se modela mediante ventanas semanales acumulativas, desde el inicio del curso hasta la semana $W$, momento en el que se estima el riesgo de abandono. En la construcción de las

variables se garantiza estrictamente la ausencia de información futura, de modo que cada predicción utiliza únicamente los datos disponibles hasta la semana analizada, asegurando el funcionamiento del sistema como una alerta temprana.

En cada ventana de tiempo calculamos métricas acumuladas hasta esa semana (clics en los foros, actividades entregadas, notas acumuladas hasta entonces, etc.) y las juntamos con variables que conocemos desde el día cero del estudiante (rango de edad, índice de riqueza del código postal, interactividad antes del comienzo del curso con la plataforma educativa, etc.)

### 4.2.2. Reducción de dimensionalidad y Aprendizaje no supervisado.

Una vez obtenida esta información (aproximadamente 58 características), siguiendo una aproximación inspirada en el estudio de El Ghali, Atouf, El Guemmat, Broumi, & Talea (2025), se realiza un agrupamiento (clustering) del estudiantado utilizando exclusivamente la información disponible hasta la semana W, con el objetivo de identificar perfiles de comportamiento diferenciados.

Para optimizar el agrupamiento, se comparan técnicas de reducción de dimensionalidad, concretamente PCA y un autoencoder, con el fin de proyectar la información a un espacio latente de menor dimensión y potencialmente más separable. En el caso del autoencoder se le penalizará no solo por su capacidad de reconstrucción sino también por su capacidad para clusterizar, más visualmente podemos verlo en la ilustración 1.

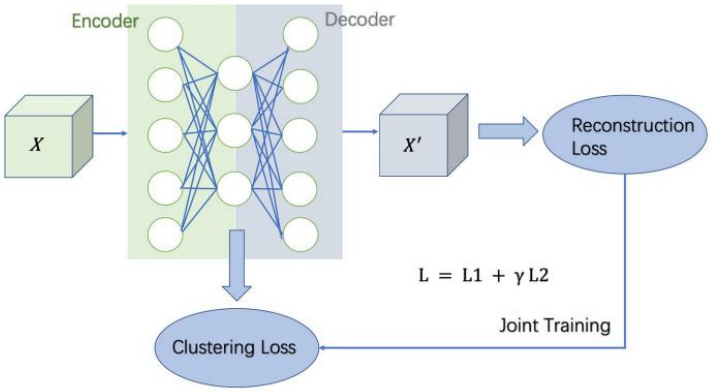


*Ilustración 1 Diagrama de Deep Clustering Network (DCN)*
*https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10047866*

En concreto, se entrenará un único autoencoder (común a todas las ventanas) para aprender una representación comprimida de los datos. Posteriormente, se ajustará un modelo de clustering independiente para cada ventana temporal W, de modo que cada uno esté especializado en agrupar a los estudiantes basándose en su comportamiento acumulado desde el inicio del curso hasta la semana W.

El algoritmo de agrupamiento seleccionado es el Modelo de Mixtura Gaussiana (GMM), cuya naturaleza probabilística se adapta a distribuciones continuas con fronteras difusas entre perfiles. A diferencia del hard clustering, GMM asigna a cada estudiante una distribución de probabilidades, lo que permite obtener una representación probabilística más rica y flexible del perfil de cada estudiante. Inicialmente, estas soft labels se consideraron candidatas para enriquecer la entrada del Transformer; no obstante, su principal utilidad en la formulación final del sistema reside en aportar una caracterización interpretable de los perfiles de aprendizaje.

### 4.2.3. Modelado secuencial con Transformer.

El objetivo principal de la red neuronal Transformer es predecir de forma temprana el riesgo de abandono (Withdrawn) o de fracaso académico (Fail).

Para ello, la arquitectura se ha diseñado con la flexibilidad necesaria para abordar distintos escenarios predictivos. Principalmente, el problema se formuló como una clasificación binaria (éxito académico frente a abandono), excluyendo los casos de suspenso para simplificar la frontera de decisión y maximizar la eficacia de la alerta temprana. No obstante, el diseño del sistema permite evaluar también clasificaciones multiclase a medida que avanza el curso y se dispone de mayor evidencia evaluativa. Para gestionar esta temporalidad y evitar la fuga de datos, se entrenan modelos Transformer independientes, cada uno especializado en realizar predicciones utilizando exclusivamente la información disponible hasta su ventana temporal correspondiente.

Aunque cada Transformer se entrena de forma específica para su ventana temporal, todos forman parte de un mismo pipeline arquitectónico, compartiendo el preprocesamiento, la arquitectura y la lógica general del sistema híbrido. Para alimentar estos modelos, se procesarán secuencias temporales que capturen la evolución semanal de la interactividad del estudiante en la plataforma. Inicialmente, se planteó enriquecer la información secuencial del Transformer con variables derivadas del clustering, como las soft labels generadas por el GMM. No obstante, la evaluación experimental mostró que su aportación al rendimiento era marginal, por lo que la configuración final prioriza señales secuenciales, estáticas y acumulativas, manteniendo el clustering como módulo complementario de interpretabilidad.

### 4.2.4. IA Explicativa.

Para dotar de transparencia al sistema y resolver el problema de interpretabilidad mencionado, se integrarán técnicas de Inteligencia Artificial Explicable (XAI). El propósito es dotar de transparencia a las predicciones generadas tanto en la fase de clustering como en la clasificación del

Transformer, transformando los resultados matemáticos en explicaciones pedagógicas accionables para el docente.

### 4.2.5. Ecosistema completo

En la siguiente figura se presenta una visión global del ecosistema metodológico del proyecto, integrando el flujo de información desde las fuentes de datos hasta la generación de predicciones y recomendaciones pedagógicas. El diagrama sintetiza las distintas capas del sistema —preprocesamiento, aprendizaje no supervisado, modelado secuencial y XAI— y sus interacciones, mostrando la contribución coordinada de cada componente a la detección temprana del riesgo académico.

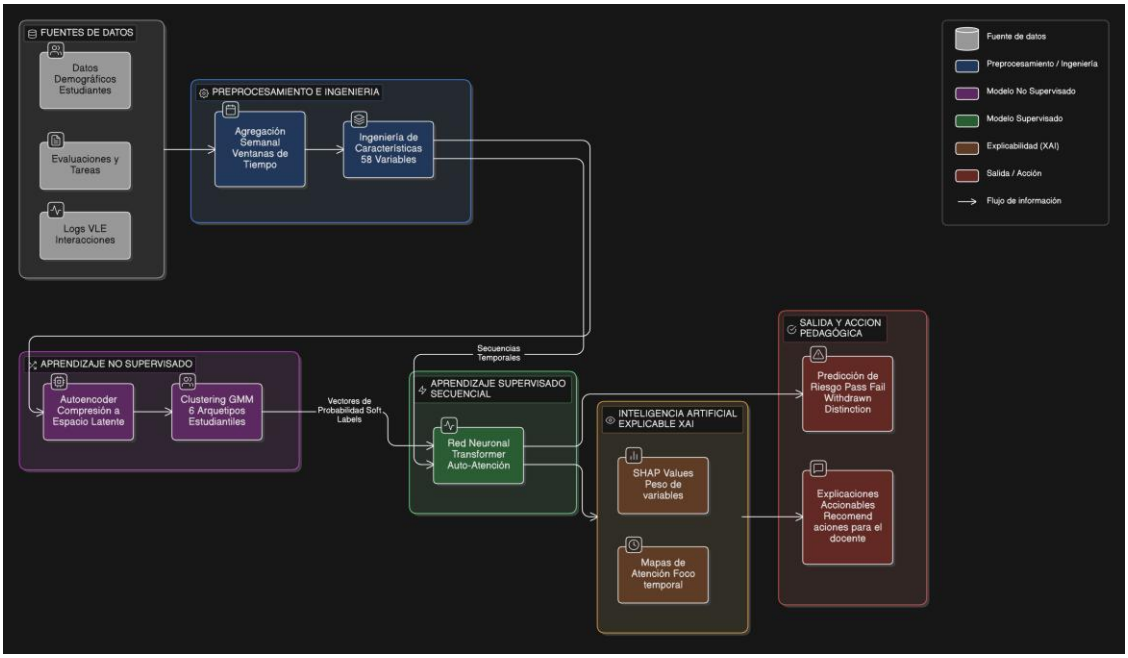


*Ilustración 2 Diagrama representativo de la arquitectura del proyecto*

## 4.3. Metodología.

La implementación de un sistema predictivo basado en *Deep Learning* dentro del contexto educativo requiere un enfoque estructurado. En este subapartado se detalla el marco metodológico adoptado. Para garantizar la rigurosidad científica y la replicabilidad de la investigación, se describe a continuación el estándar procedimental seguido (CRISP-DM), la jerarquía de las tareas operativas diseñadas para este estudio junto con las tareas específicas a realizar y la hoja de ruta temporal que guía el desarrollo del proyecto.

### 4.3.1. Metodología CRISP-DM.

Este proyecto adopta la metodología iterativa CRISP-DM (Wirth & Hipp, 2000). A diferencia de un proceso lineal CRISP-DM es cíclico e iterativo permitiendo volver atrás y refinar lo aprendido en cada etapa para que el resultado final sea lo más preciso posible. Para este estudio, el ciclo de vida se ha personalizado en seis grandes bloques:

- Comprensión del Negocio: Definir la necesidad pedagógica: ¿por qué abandonan los alumnos y qué información necesita el profesor para ayudarles a tiempo?
- Exploración de Datos (EDA): Analizar la "huella digital" del estudiante en Moodle para comprender la información disponible.
- Preparación de Datos: Transformar los clics diarios en secuencias que cuentan la historia del estudiante semana a semana, siguiendo la tendencia actual de analíticas de aprendizaje (Soepriyanto, Nugroho, Nahri, Kesuma, & Setiasih, 2025).
- Modelado: Aplicar modelos avanzados (Deep Learning) capaces de aprender patrones de comportamiento.

- Evaluación y Explicabilidad (XAI): No basta con que el modelo acierte; se integran técnicas explicables.
- Despliegue: Convertir las predicciones en recomendaciones pedagógicas aplicables en un entorno real.

Adicionalmente, cabe subrayar que, para este TFM, este bloque no se ha concebido como una serie de pasos manuales, sino como un pipeline de datos automatizado. Esta decisión garantiza que cualquier transformación (normalización, imputación o ingeniería de variables) se aplique a los conjuntos de entrenamiento, validación y test, eliminando el riesgo de "fuga de datos" y asegurando la reproducibilidad total del experimento.

### 4.3.2. Definición de tareas.

Para alcanzar los objetivos propuestos, el proyecto se ha desglosado en una serie de hitos técnicos y operativos. Estas tareas no solo cubren el desarrollo del código, sino también la fundamentación teórica y la transferencia de resultados al ámbito pedagógico:

#### Fase I: Fundamentación y contextualización

- Comprensión del ecosistema (Business Understanding): Análisis del dominio de la Minería de Datos Educativos (EDM) y la Analítica de Aprendizaje para alinear el modelo con las necesidades docentes.
- Definición de objetivos: Formalización del problema a resolver.
- Investigación del estado del arte: Revisión de literatura científica de los últimos cinco años para identificar arquitecturas de vanguardia y evitar redundancias en la investigación.

### Fase II: Gestión y Exploración de Datos

- Adquisición de la fuente de datos: Selección y descarga del conjunto de datos OULAD, por su representatividad en interacciones tipo Moodle.
- Preprocesamiento y Limpieza: Tratamiento de valores nulos, normalización de variables y filtrado de registros inconsistentes para asegurar la calidad de la entrada.
- Análisis Exploratorio de Datos (EDA): Identificación de patrones visuales, correlaciones y desequilibrios de clase (ej. tasa de abandono frente a suspensos).

### **Fase III**: Ingeniería de Características y Modelado Híbrido.

- Ingeniería de Características I (Transformación Temporal): Conversión de los *logs* de interacción brutos en secuencias temporales estructuradas por semanas de curso.
- Modelado No Supervisado (Clustering): Implementación de algoritmos para descubrir arquetipos de estudiantes de forma automática.
- Ingeniería de Características II (Enriquecimiento): Integración de las etiquetas de los clústeres en el conjunto de entrenamiento para potenciar la capacidad de discriminación del modelo.
- Desarrollo del Modelo Supervisado: Diseño y entrenamiento de una red neuronal basada en la arquitectura Transformer, optimizada para capturar dependencias secuenciales a largo plazo.

### Fase IV: Evaluación y Explicabilidad

- Evaluación del desempeño: Cálculo de métricas de rendimiento (Accuracy, F1-Score, Precisión) para validar la robustez de las predicciones.

- Implementación de Inteligencia Artificial Explicable (XAI): Aplicación de técnicas de interpretabilidad para desglosar el peso de cada variable y visualizar los mapas de atención del modelo.
- Acciones Pedagógicas (Transferencia): Traducción de los hallazgos técnicos en recomendaciones concretas para la intervención docente personalizada.

### 4.3.3. Planificación.

A continuación, se plasman sen la ilustración 3 un diagrama de tipo Gantt la hoja de ruta cronológica y la distribución de esfuerzos diseñada para este trabajo. Este cronograma organiza temporalmente las cuatro fases operativas descritas anteriormente, estableciendo una secuencia lógica que garantiza el cumplimiento de los objetivos técnicos y pedagógicos dentro del plazo académico establecido.

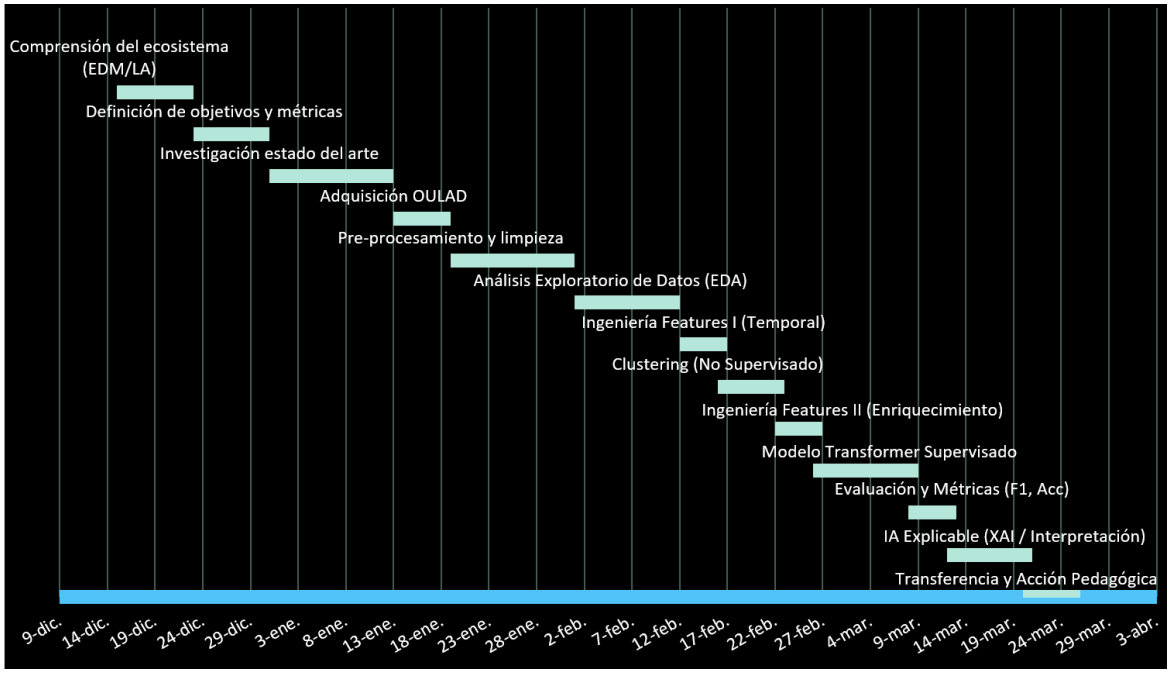


*Ilustración 3 Cronograma de tareas definidas. Elaboración propia*

# 5. Desarrollo del proyecto.

La implementación técnica de la arquitectura propuesta se ha llevado a cabo siguiendo los estándares de desarrollo de software y ciencia de datos. Cabe destacar que la totalidad del código fuente, los scripts de preprocesamiento y los cuadernos de experimentación se encuentran alojados en un repositorio público de GitHub (Véase Apéndice I: Repositorio de Código y Reproducibilidad). Esta decisión responde a un doble objetivo metodológico:

- Garantizar la trazabilidad y autoría: El historial de *commits* (registro de cambios) actúa como una prueba temporal veraz del progreso y la originalidad del trabajo realizado, así como la autoría de este.
- Optimizar la memoria académica: Para evitar que este documento se extienda innecesariamente con bloques de código, este apartado se centra en describir la lógica, las decisiones arquitectónicas y los flujos de datos más relevantes.

La estructura de este apartado sigue fielmente las fases del ciclo de vida CRISP-DM, detallando cómo se ha ejecutado cada etapa técnica:

## 5.1. Comprensión del negocio.

El proceso de comprensión del negocio se inició con una investigación exhaustiva sobre fuentes de datos que cumplieran con requisitos de fiabilidad, volumen y representatividad de un entorno LMS real. Tras evaluar diversas alternativas, se seleccionó el conjunto de datos OULAD (*Open University Learning Analytics Dataset*). Tal y como se vio en el marco teórico la elección de este dataset se fundamenta en su veracidad, anonimización, volumen representativo y su idoneidad para realizar comparativas (benchmarking) con el estado del arte.

Cabe señalar que la fundamentación del problema, así como el análisis profundo del estado del arte que contextualiza estos datos, se encuentran documentados en detalle en el Capítulo 3 de esta memoria. El análisis estructural del conjunto de datos OULAD se fundamenta en tres dimensiones que alimentarán el modelo híbrido propuesto:

- Dimensión del estudiante: Se trata de la información estática y demográfica, actuando como el perfil base de cada alumno matriculado. Ejemplos: El género del estudiante, su región de residencia, el nivel educativo previo, etc.

- Dimensión de actividades: Contiene los resultados en diferentes actividades realizadas durante el curso por parte del alumno. Ejemplos: La calificación obtenida en una tarea (escala 0-100), el tipo de evaluación (si es corregida por un tutor o automática) y la fecha real en la que el alumno realizó la entrega frente a la fecha límite

- Dimensión de comportamiento: Representa el log de actividad diario en el Sistema de gestión del aprendizaje (LMS) y constituye la huella digital que el estudiante deja al interaccionar con la plataforma. Ejemplos: El número de clics o interacciones diarias con materiales de lectura, la participación en foros de discusión, el acceso a cuestionarios o la descarga de recursos específicos del curso.

El diccionario de datos detallado con la descripción de todas las variables que componen estas tres dimensiones puede consultarse en el Anexo I: Estructura y Diccionario de Datos OULAD. Otros aspectos relevantes de la base de datos son:

- Las fechas normalmente están relativizas con respecto al inicio del curso y se expresan en días previos (negativo) o posteriores (positivos).

- Las interacciones no solo se recogen desde el día cero del curso, sino que antes de iniciar el curso, ya se capturan las interacciones que hacen los estudiantes con la plataforma.

El análisis de la estructura y relación de los datos junto con el marco teórico y el estado del arte constituyen el núcleo de la fase de comprensión del negocio. Además, es importante destacar que, bajo el enfoque iterativo de la metodología CRISP-DM, esta comprensión no es estática; por el contrario, se profundiza y matiza en la comprensión del negocio en cada una de las fases sucesivas del proyecto, desde el preprocesamiento hasta la evaluación de los modelos. Una vez consolidada esta base conceptual y estratégica, se procede a ejecutar el análisis exploratorio de datos (EDA).

## 5.2. Análisis exploratorio de datos (EDA).

A nivel técnico, la exploración de los datos (EDA) se materializó mediante scripts de análisis en un Jupyter Notebook, concretamente en el archivo I_data_exploration.ipynb. Este cuaderno, cuya ubicación exacta dentro de la estructura del proyecto se detalla en el Apéndice I: Repositorio de Código y Reproducibilidad, permite examinar las distribuciones de las variables y la correlación entre las interacciones y el rendimiento final. Del análisis de datos exploratorio (EDA) realizado en dicho cuaderno, se extrajeron las siguientes conclusiones más relevantes:

- Descarte por ética y directrices del EU AI act (Parlamento Europeo y Consejo de la Unión Europea, 2024): Para hacer un sistema ético, equitativo y que cumpla la legislación vigente en la unión europea, datos sensibles como género y discapacidad se descartan del estudio.

- Valores nulos: En el conjunto de datos OULAD, los valores nulos poseen un alto significado estructural y rara vez responden a deficiencias de calidad. Los casos en los que se detectan nulos son:
  - Dimensión de Estudiantes: Se detectaron nulos masivos en la variable date_unregistration (22,521 registros), lo cual es un indicador positivo de persistencia, ya que representa a los alumnos que no han abandonado el curso. Asimismo, variables como imd_band (1,111 nulos) y date_registration (45 nulos) requieren un tratamiento diferente para evitar sesgos de selección al eliminar registros.
  - Dimensión de Evaluaciones: Se identificaron 173 registros sin calificación (score) y 2,865 sin fecha de entrega definida. Estas inconsistencias en los hitos evaluativos marcan la necesidad de un filtrado estricto en la fase de preprocesamiento para garantizar la veracidad de las etiquetas de rendimiento.
  - Dimensión de Interacciones: Los campos temporales en los logs muestran nulos que deben ser normalizados para no interrumpir el cálculo de métricas secuenciales como el momentum o el engagement pesado.
- Balanceo de clases y representatividad: El análisis de la ilustración 4 evidencia una distribución asimétrica de los resultados académicos, con una representación mayoritaria de las categorías de aprobado y abandono y una presencia reducida de sobresalientes y suspensos. Este desbalance justifica la adopción de métricas robustas frente a clases mayoritarias, como el F1-Score, así como el uso de arquitecturas de *Deep Learning* capaces de identificar patrones sutiles en grupos minoritarios.

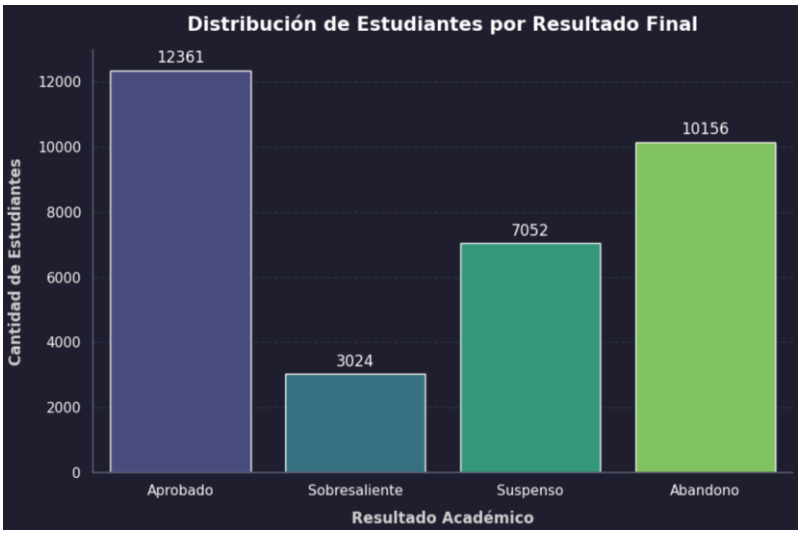


*Ilustración 4 Distribución de estudiantes por resultado académico. Autoría propia - Apéndice 1 - Notebook I*

- Ruido diario de interacciones diarias frente a ruido semanal: En la ilustración 5 al contrastar el promedio de interacciones, se observó que el análisis diario presenta un ruido de alta frecuencia difícil de modelar. Por el contrario, la agregación semanal ofrece una señal limpia con patrones identificables. Esta observación justifica la decisión técnica de transformar los registros brutos en secuencias semanales para mejorar la capacidad predictiva del modelo.

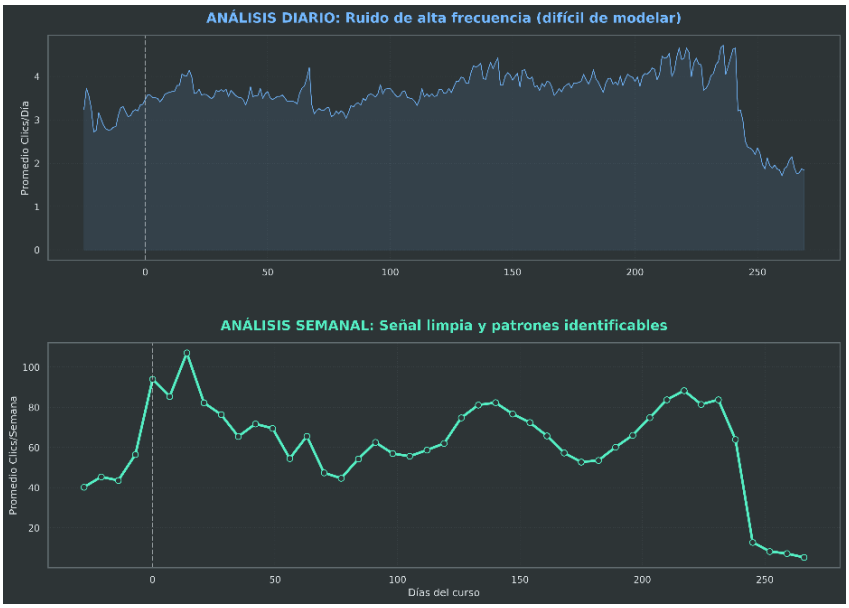


*Ilustración 5 Análisis comparativo de de interacciones: Ruido diario frente a señal semanal agregada. Autoría propia - Apendice I - Notebook I*

- Nivel de riqueza en el código postal del estudiante: Se observa una relación directa entre el nivel de riqueza medio del código postal del estudiante y los resultados. Vemos como la tasa de abandono y suspensos es más alta en barrios pobres, frente a una mayor tasa de aprobados y sobresalientes en barrios más adinerados.

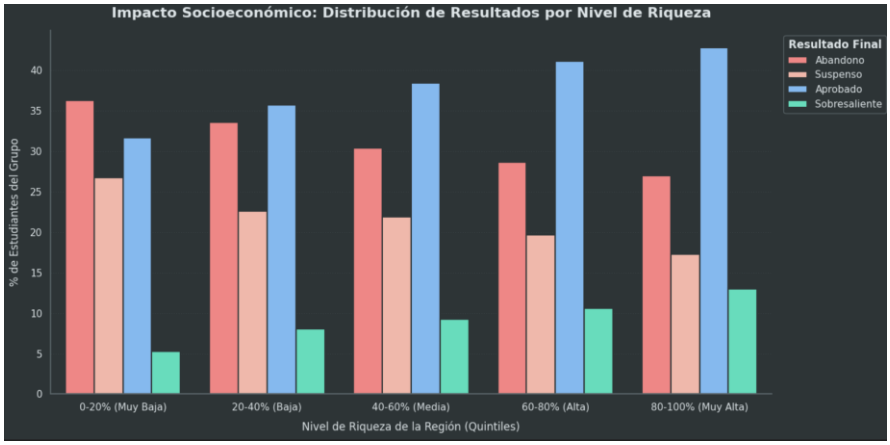


*Ilustración 6 Contraste entre riqueza y resultados académicos - Autoría Propia - Apéndice I - Notebook I*

- La influencia del tipo de curso en la cantidad de iteraciones: Como muestra el análisis diferencial (ilustración 7), la intensidad de interacción varía drásticamente según la materia; por ejemplo, el curso FFF triplica la actividad del BBB. Sin un ajuste previo, el algoritmo de clustering sufriría un sesgo de volumen, agrupando a los estudiantes por la asignatura matriculada en lugar de por su comportamiento real, lo que invalidaría la identificación de patrones de compromiso genuinos.

  Para evitar esto, en lugar de contar clics totales, se mide qué tanto destaca un alumno respecto al promedio de su propia clase. Así podemos comparar con justicia a estudiantes de distintos cursos, asegurando que el análisis se centre en el ritmo y la constancia individual, sin importar si la materia exige muchas o pocas interacciones.

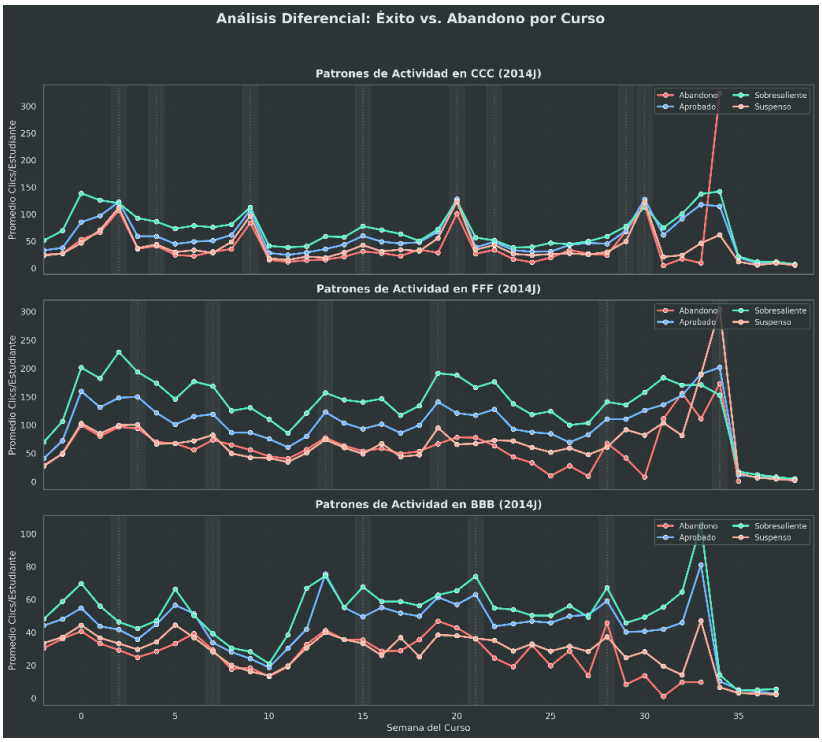


*Ilustración 7 Comparación de interacciones por curso.*
*Autoría propia - Apéndice I - Notebook I*

- Si nos fijamos en la ilustración 8 podemos apreciar que no hay relación entre el día que se matricularon los alumnos y si se abandona o si se aprueba, por el contrario, el número de intentos previos y el número de interacciones con la plataforma educativa antes del comienzo del curso sí que están directamente relacionada con la tasa de abandono, el porcentaje de aprobados y el número de sobresalientes, por lo tanto, se las proporcionaremos a nuestro modelo:

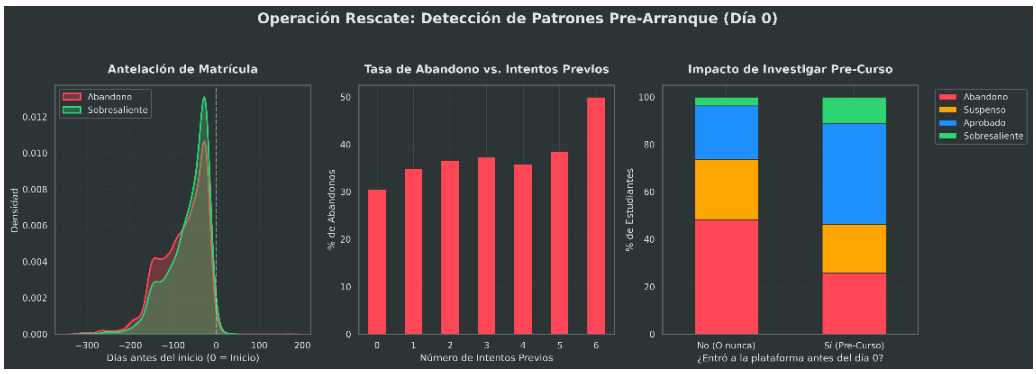


*Ilustración 8 Relación entre diferentes métricas y resultados académicos.*
*Apéndice 1 - Notebook I*

- Se puede ver también en la ilustración 9 que hay una relación entre el nivel educativo previo y los resultados obtenidos. Cuanto mayor es el nivel educativo previo más probabilidades hay de que el estudiante tenga éxito.

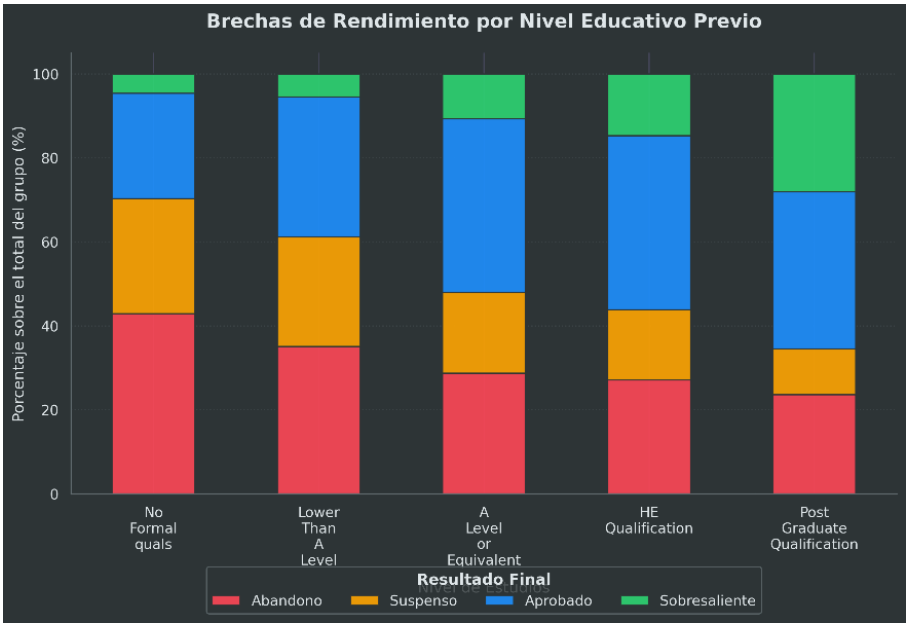


*Ilustración 9 Relación entre nivel educativo y resultados académicos*
*Apéndice 1 – Notebook I*

Es fundamental señalar que esta fase de análisis exploratorio (EDA) no constituye un bloque estático o aislado dentro del flujo de trabajo. Por el contrario, el EDA actúa como un proceso transversal y evolutivo que acompaña al ciclo de vida del proyecto. A medida que se itera en las fases de preprocesamiento, entrenamiento de modelos y evaluación, los hallazgos obtenidos permiten volver al análisis de los datos para pulir métricas y perfeccionar la ingeniería de características.

## 5.3. Preprocesamiento de datos.

Tras comprender la naturaleza de los datos, el preprocesamiento se estructuró en tres fases: un tratamiento inicial para el Análisis Exploratorio (EDA), y dos vías de ingeniería de características adaptadas a los requisitos de cada modelo (el Autoencoder para el *clustering* y la red neuronal Transformer).

### 5.3.1. Preprocesamiento para EDA.

El procesado de los datos para el análisis exploratorio de datos se llevó a cabo a partir de los datos obtenidos de la base de datos oficial de OULAD, el tratamiento de los datos se llevó a cabo en el script dataset.py dentro de la carpeta "educational_ai_analytics/0_data" (Véase apéndice I) y las salidas tras procesar los datos se genera en "data/1_interim" y en "data/2_processed". Las acciones específicas que se llevan a cabo en este script son:

- Consolidación de los múltiples archivos tabulares del sistema (estudiantes, cursos, registros, evaluaciones e interacciones VLE) en tres grandes conjuntos de datos unificados. Durante este proceso, se estandarizaron los valores faltantes o desconocidos (originalmente representados con caracteres especiales como '?').

- Partición y protección contra fuga de datos (Data Leakage): División estratificada de la población estudiantil en conjuntos de Entrenamiento (70%), Validación (15%) y Prueba (15%).

- Durante este preprocesamiento, se prestó especial atención a la imputación de valores nulos para no distorsionar la muestra. Concretamente, las ausencias en el índice de privación múltiple (*imd_band*) se recategorizaron bajo la etiqueta 'Unknown' para preservar los registros sin introducir sesgos poblacionales. Por su parte, los valores faltantes en la fecha de matriculación (*date_registration*) se imputaron estadísticamente utilizando la mediana temporal del curso correspondiente (code_presentation), calculada estrictamente sobre el conjunto de entrenamiento para evitar fuga de datos (data leakage).

### 5.3.2. Preprocesamiento para Autoencoder y clustering.

La preparación de los datos para el Autoencoder se llevó a cabo en dos scripts de Python, específicamente "ae_uptow_features.py" y "day0_static _features" dentro de la carpeta "educational_ai_analytics/1_proccesed" y la salida de estos scripts se generó en la carpeta "data/2_features" (Véase Apéndice I). Aunque a nivel práctico se hayan fusionado el preprocesado e ingeniería de características en un mismo script. En este epígrafe nos limitaremos a la parte de preprocesamiento.

- Para evitar la redundancia y garantizar la trazabilidad longitudinal del alumno, se construyó un identificador único compuesto por el código del estudiante, el módulo matriculado y el semestre (id_student + code_module + code_presentation). Este identificador actuó como índice principal para todas las tablas.

- Normalización condicional por curso: Para evitar que las variaciones inherentes a cada asignatura distorsionaran el análisis del comportamiento, se aplicó una normalización estadística (*Z-score*) sobre las variables continuas. Esta normalización no se calculó de forma global, sino de manera agrupada y específica para cada cohorte (curso y convocatoria), asegurando que el comportamiento de un estudiante se evalúe exclusivamente en relación con el promedio de sus compañeros de clase.

- Gestión de variables categóricas y valores atípicos (Demografía): Variables ordinales como el índice de privación múltiple (*imd_band*), el rango de edad (*age_band*) y el nivel educativo previo (*highest_education*) se mapearon a escalas numéricas continuas o discretas, facilitando su interpretación por parte de las redes neuronales.

- Tratamiento robusto de interacciones (Clipping): Dada la alta varianza en la frecuencia de interacción diaria de los estudiantes con la plataforma (clics), se implementó una técnica de clipping (acotamiento). Se limitaron los valores máximos de actividad diaria utilizando el cuantil superior de la distribución, mitigando así el impacto de outliers extremos generados por actividad inusual (por ejemplo, bots de descarga masiva).

### 5.3.3. Preprocesamiento para red neuronal Transformer.

El preprocesamiento para el modelo Transformer difiere del enfoque tradicional, ya que requiere estructurar la información en secuencias temporales en lugar de vectores planos. Este tratamiento se automatizó para transformar los registros diarios en tensores tridimensionales, ejecutando las siguientes acciones clave:

- Estructuración temporal y de identidad: Se generó un identificador único por estudiante y curso, transformando la granularidad de los registros de días relativos a índices semanales.
- Generación de tensores y máscaras: Los registros se agruparon en un tensor de dimensionalidad (N, T, F) (estudiantes, semanas transcurridas, tipos de actividad). Simultáneamente, se creó una máscara booleana (mask_activity) para indicar explícitamente al mecanismo de atención del Transformer qué semanas contienen señales de comportamiento real y cuáles son vacíos estructurales por inactividad.
- Normalización contextualizada: Para mitigar la alta varianza en la frecuencia de clics, se aplicó una transformación Log1p seguida de una estandarización (Z-score). Para prevenir la fuga de datos (data leakage), los estadísticos de normalización se calcularon estrictamente sobre el conjunto de entrenamiento, diferenciando por curso y considerando exclusivamente las semanas con actividad.

## 5.4. Ingeniería de características.

En el caso de la ingeniería de características tenemos dos fases: La primera consistente en la preparación y selección de los datos para el autoencoder, el cual representará la información en un espacio latente de menor dimensión que luego será clusterizado. La segunda es dependiente de la resolución de la primera fase, dado que los resultados de las agrupaciones de estudiantes serán inyectados a la entrada de la red neuronal Transformers.

### 5.4.1. Fase I: Características para Autoencoder.

El conjunto de características que alimenta el entrenamiento del modelo se construye a partir de los scripts ae_uptow_features.py y day0_static_features.py, alojados en la carpeta educational_analytics/1_features/ (véase el Apéndice I). Una vez procesados los datos provenientes del directorio data/2_processed, las variables resultantes para el autoencoder se exportan a data/3_features. La arquitectura de estos datos se fundamenta en dos bloques principales:

- Información que se tiene del estudiante desde el comienzo del curso, es decir desde el día cero:
    - Datos sociodemográficos: Con el fin de cumplir con aspectos éticos y legales, se descartó incluir información como discapacidad o género. Sin embargo, dado el poder discriminativo que se encontró en EDA de variables como Región, índice de riqueza del código postal, nivel educativo previo, número de veces que intento previamente el curso, etc. Se opto por incluirlas
    - Características de Arranque (Preinicio del curso): Se modeló el nivel de proactividad antes del comienzo oficial de las clases (Día 0).

Para ello, se calcularon métricas como la intensidad previa (*prestart_intensity*), que mide la relación entre los clics totales y los días activos, y la anticipación (*prestart_anticipation*), que cuantifica cuántos días antes del inicio el alumno comenzó a interactuar con la plataforma.

- Información acumulada en diferentes ventanas de tiempo: El objetivo es que para diferentes ventanas de tiempo (desde la semana cero hasta la semana X) se calcules los valores acumulados de clics en los diferentes tipos de actividad, junto con calificación obtenida hasta la fecha, etc.

- Métricas de Compromiso Ponderado (Weighted Engagement): Se creó una métrica de compromiso ponderado (total_weighted_engagement) donde se asignó un mayor peso (1.3) a actividades que requieren esfuerzo cognitivo activo (como cuestionarios o herramientas colaborativas) y un peso menor (0.8) a la lectura pasiva de recursos.

- Dinámicas Temporales y Momentum: Para capturar el ritmo y la constancia del estudiante, se derivaron variables secuenciales críticas:

  - Tendencia de esfuerzo (effort_slope): Indica si la actividad del alumno va en aumento o en declive.

  - Momentum a corto plazo (momentum): Cuantifica la aceleración o desaceleración del compromiso.

  - Rachas y latencia: Se extrajeron métricas como la racha final de semanas consecutivas activas (streak_final) y la cantidad de semanas transcurridas desde la última actividad (weeks_since_last_activity), fundamentales para detectar riesgo inminente de abandono.

- Diversidad y Dispersión del Aprendizaje: Se diseñaron indicadores para perfilar el estilo de navegación del alumno. Entre ellos destaca la entropía temporal (temporal_entropy_uptoW), que diferencia a los estudiantes constantes de aquellos que concentran su actividad en picos esporádicos. Asimismo, métricas como el top1_share (proporción de clics en la actividad principal) y el índice de curiosidad (curiosity_index) permitieron medir si el estudiante explora transversalmente varios recursos.

- Evolución del Rendimiento (Assessments): Se generaron características de evaluación que incluyen el ratio de actividades aprobadas (pass_ratio), la tendencia en las calificaciones (score_slope), la proporción de entregas tardías (late_ratio) y el tiempo transcurrido desde la última entrega (weeks_since_last_submission). Adicionalmente, se formuló un índice compuesto (api_index) que pondera la nota media lograda por el logaritmo del volumen de entregas realizadas.

Estas 58 características conformarón el vector que alimentó la arquitectura del Autoencoder. Esto permitió a la red comprimir la información en un espacio latente, extrayendo patrones de comportamiento no lineales y limpios de ruido. Para una revisión exhaustiva del conjunto de datos resultante, el Apéndice II detalla las 58 características definitivas con las que se entrenó el modelo.

### 5.4.2. Fase II: Características para Transformers.

La segunda fase de la ingeniería de características tiene como propósito construir el conjunto de datos que alimentará el modelo secuencial. A diferencia del Autoencoder, que evalúa vectores estáticos de datos agregados, la red neuronal Transformer requiere una representación enriquecida con el contexto

global del estudiante. Esta fase de implemento en el script transformer_GLU_classifier.py dentro de la carpeta educational_ai_analytics/modeling/transformes, la exploración previa para modelar este script se encuentra en el notebook 5 (Apéndice I). La arquitectura de las características generadas en este script se estructura en los siguientes tres bloques fundamentales:

- Matriz Secuencial de Interacciones (Comportamiento Temporal): Constituye el núcleo dinámico del modelo. En lugar de métricas acumuladas, la información se estructura en un tensor tridimensional de dimensionalidad (N x T x F) (estudiantes, semanas transcurridas, tipos de actividad). Esto permite a la red evaluar la evolución de las interacciones semanales del alumno con cada recurso del LMS (foros, cuestionarios, lecturas) de forma cronológica.
- Características Estáticas y Perfil de Arranque (Día 0): Para contextualizar el punto de partida del estudiante, se concatena al tensor la información disponible antes de iniciar el curso. Esto incluye las variables sociodemográficas de alto poder predictivo (como el índice de riqueza del código postal, el nivel educativo previo y los intentos anteriores) junto con las métricas de proactividad previas al arranque.
- Variables acumulativas en la ventana de tiempo: Como resultado de la fase de experimentación, se optó por incorporar también las características históricas acumuladas por el estudiante hasta la semana objeto de predicción (W). La inyección de estas métricas agregadas —calculadas inicialmente para el Autoencoder— complementa el análisis secuencial del mecanismo de atención, lo que se tradujo empíricamente en una mejora sustancial de las métricas de rendimiento del modelo final.

De forma adicional, se evaluó la incorporación de señales procedentes del módulo de clustering, concretamente las soft labels y su entropía asociada. No

obstante, dado que su impacto sobre las métricas de validación fue prácticamente nulo y no consistente, estas variables no se incluyeron en la configuración predictiva final del Transformer. Finalmente, en el apéndice II, en el subapartado de características del Transformer se ven más detallas de las características utilizadas en esta fase.

## 5.5. Modelado

En esta fase se ha diseñado una arquitectura híbrida compuesta por dos módulos complementarios: una fase de aprendizaje no supervisado orientada al descubrimiento de perfiles latentes y una fase de aprendizaje supervisado basada en Transformers orientada a la predicción temprana del riesgo académico.

### 5.5.1. Autoencoder.

El modelado del Autoencoder (AE) se materializa en los scripts autoencoder.py donde se construye la arquitectura del AE con Keras y train_autoencoder.py donde se especifica la manera en la que se entrena, todos estos ficheros se encuentran en la carpeta "educational_ai_analytics/2_modeling/ae" (véase apéndice I).

La estrategia principal consiste en entrenar un único autoencoder global que procesa simultáneamente todas las ventanas semanales (1, 3, 5, 8, 10, 12, 15, 18, 20, 24 y 28). Esta decisión se fundamenta en primer lugar en que garantiza la coherencia del espacio latente, creando un marco de referencia universal que permite rastrear la evolución del estudiante sin las incompatibilidades de usar modelos independientes para cada ventana de tiempo y en segundo lugar que actúa como una técnica implícita de aumento de datos (*data augmentation*), multiplicando las muestras disponibles y reduciendo el sobreajuste (*overfitting*).

Adicionalmente, la arquitectura implementada se enmarca en la categoría de redes Deep Clustering Networks (DCN), inspirada en los principios del Deep Embedded Clustering (DEC). A nivel de optimización, esto significa que el modelo no se limita únicamente a la reducción de dimensionalidad, sino que es guiado por una función de pérdida dual durante su fase de entrenamiento.

Por un lado, la red minimiza una pérdida de reconstrucción (empleando la métrica Huber Loss) para garantizar que el espacio latente retenga fielmente la información estructural y las características originales del estudiante. Por otro lado, incorpora simultáneamente una pérdida de agrupamiento basada en la divergencia de Kullback-Leibler (KL). Mediante esta optimización conjunta, el autoencoder genera embeddings que no solo están limpios de ruido, sino que están matemáticamente forzados a ser altamente discriminativos para la segmentación de perfiles de aprendizaje.

Para llevar a cabo esta optimización dual de manera estable, el proceso de entrenamiento del modelo (implementado en el script train_autoencoder.py) no se ejecuta en un solo paso, sino que se estructura cuidadosamente en tres fases secuenciales:

- Fase 1 - Pre-entrenamiento (Reconstrucción): En esta etapa inicial, la red se entrena de manera estándar como un autoencoder tradicional, desactivando temporalmente el objetivo de clustering. El objetivo exclusivo es minimizar el error de reconstrucción mediante la métrica Huber Loss garantizando que el modelo aprenda primero a proyectar los datos en un espacio latente que retenga fielmente toda la información estructural (estática y dinámica) de los estudiantes.

- Fase 2 - Inicialización de Centroides (K-Means): Una vez obtenido un espacio latente pre-entrenado y estable, se extraen los embeddings de los estudiantes y se aplica sobre ellos el algoritmo K-Means clásico. Los

centroides encontrados (k=5, según lo determinado en la experimentación) no se usan como resultado final, sino que se inyectan en la red neuronal para inicializar los pesos de la capa específica de clustering. Este paso es un requisito clave del enfoque DEC, ya que proporciona a la red un punto de partida antes de aplicar la pérdida probabilística.

- Fase 3 - Optimización Conjunta (Entrenamiento DCN): Aquí, la red se afina (*fine-tuning*) minimizando simultáneamente la pérdida de reconstrucción y la divergencia de Kullback-Leibler (KL). Durante esta etapa, el modelo calcula una distribución objetivo que fuerza a las predicciones probabilísticas a ser más "nítidas" (acercando los estudiantes a su centroide más próximo y alejándolos del resto). Esta distribución se recalcula iterativamente a lo largo de las épocas, guiando al espacio latente para que aumente la cohesión intra-clúster sin perder la capacidad de reconstrucción original.

Adicionalmente, a nivel de ingeniería de Machine Learning, el bucle de entrenamiento incorpora técnicas para garantizar la robustez del modelo, tales como Early Stopping basado en la pérdida conjunta para evitar el sobreajuste (*overfitting*), visualización y monitorización de evolución del entrenamiento, etc.

### 5.5.2. Embeddings

Los embeddings —entendidos como representaciones de los vectores de datos de estudiantes en un espacio latente de menor dimensionalidad— fueron creados empleando el autoencoder descrito en el epígrafe anterior. De forma complementaria, y con el objetivo de disponer de una línea base (*baseline*) interpretable, se entrenó también un modelo PCA, ajustando su número de componentes al mismo tamaño dimensional del espacio latente del autoencoder. Esto nos permite reducir la dimensionalidad de los datos siguiendo dos filosofías

diferentes (PCA y AE permitiendo realizar una comparación que evaluará cuál de las dos técnicas resulta más adecuada como etapa previa al clustering.

Para la generación de los embeddings se utilizó el script "generate_embeddings.py" en la carpeta educational_ai_analytics/2_modeling /ae (véase apéndice I), este script toma como entrada los datos en la carpeta "data/3_features" y a partir de ella se generan los embeddings tanto para AE (*ae_latent.csv*) como para PCA(*pca_latent.csv*), estos vectores característicos de los estudiantes en el espacio latente son los que se utilizarán en la siguiente fase de Clustering.

### 5.5.3. Clustering

El modelado de clustering fue un proceso iterativo del cual destacan dos ajustes metodológicos clave para lograr un sistema de alerta temprana robusto:

- Prevención de fuga de datos: Se pasó de una ventana temporal única a ventanas acumulativas semanales, garantizando que el modelo agrupe a los estudiantes basándose estrictamente en la información histórica disponible hasta ese momento.
- Mejora del espacio latente: Se incorporó una pérdida adicional basada en la divergencia de Kullback–Leibler (KL) al Autoencoder, lo que generó representaciones (embeddings) mucho más cohesivas y separables que minimizando únicamente el error de reconstrucción.

El detalle completo de los experimentos para tomar decisiones de clustering puede consultarse en el Notebook 4 dentro de la carpeta Notebooks del repositorio (véase Apéndice I).

En dicho notebook se exploran dos familias de combinaciones: (PCA o AE) + K-Means y (PCA o AE) + Gaussian Mixture Model (GMM). Para no extender excesivamente el presente documento, el análisis detallado se centrará

únicamente en la segunda combinación (con GMM), ya que fue el modelo finalmente seleccionado.

Para fundamentar esta elección y evaluar la calidad de los clústeres formados por GMM, nos apoyamos en dos métricas: el Criterio de Información Bayesiano (BIC) y el Criterio de Akaike (AIC). En términos sencillos, ambos indicadores evalúan qué tan bien logra el modelo representar la realidad de los datos, pero le aplican una penalización matemática si utiliza una cantidad innecesaria de grupos para lograrlo. Por lo tanto, un valor más bajo indica siempre un modelo mejor y más eficiente. Sin embargo, no siempre se escoge el valor más bajo, sino que aquel que da equilibrio entre un valor bajo de BIC/AIC y utilidad interpretativa. En la ilustración 10 se muestra la evolución de los criterios de información BIC/AIC para distintos valores de k (número de componentes) al aplicar GMM sobre embeddings generados mediante PCA y mediante autoencoder.

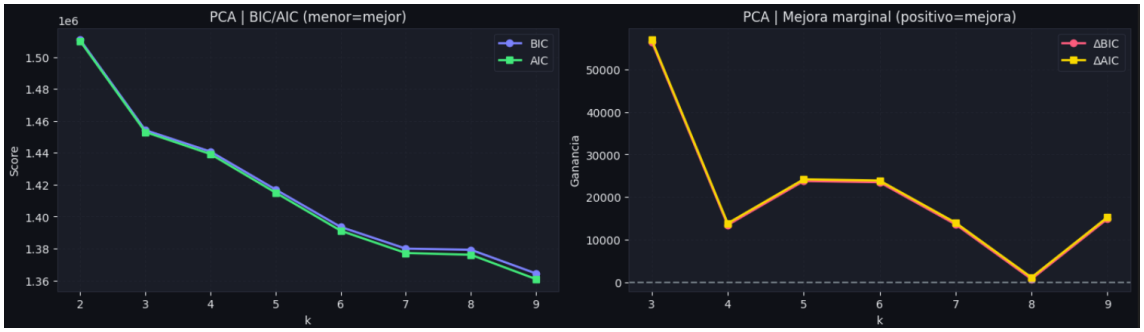


*Ilustración 10 Comparación BIC/AIC en PCA*
*Autoría propia - Apéndice I - Notebook 4*

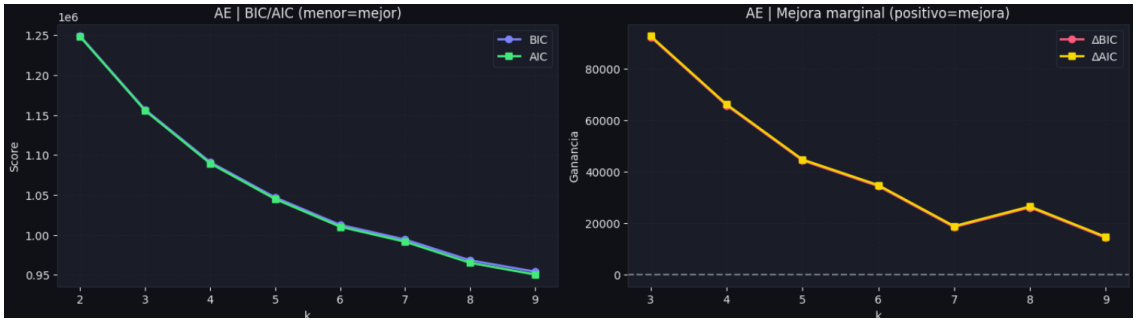


*Ilustración 11 Evolución BIC/AIC con AE -*
*Autoría propia - Apéndice I - Notebook 4*

El análisis de las métricas revela una clara ventaja del Autoencoder sobre el PCA. Aunque ambos enfoques operan en el mismo orden de magnitud, el modelo AE presenta valores de BIC y AIC consistentemente inferiores para cualquier número de componentes (k). Mientras que el PCA se sitúa entre 1.36 y 1.50 millones, el AE logra reducir el *score* al rango de 0.95 a 1.25 millones. Esta diferencia evidencia que las representaciones latentes extraídas por el Autoencoder logran un ajuste matemático muysuperior.

Por otro lado, la evolución de la mejora marginal (ΔBIC y ΔAIC) resalta la mayor estabilidad del Autoencoder en la definición de perfiles. Mientras que el PCA presenta una curva de ganancias errática y altamente volátil —lo que dificulta al algoritmo GMM encontrar fronteras naturales constantes—, el AE muestra una estructura de descenso mucho más coherente. Específicamente, el modelo AE registra un último máximo local de ganancia en k=8, seguido de un desplome drástico cercano a la línea del cero al probar con k=9. Este comportamiento marca un claro punto de inflexión, indicando que añadir un noveno clúster solo incrementaría la complejidad del modelo sin aportar un beneficio matemático real, elevando así el riesgo de sobreajuste.

Adicionalmente, en la ilustración 12 se corrobora visualmente la superioridad del Autoencoder al comparar las proyecciones en el espacio tridimensional (*3D Space*) y la distribución de frecuencias de las categorías desde etapas tempranas del curso, específicamente en las semanas 3 y 5 (W3 y W5). Al analizar en detalle la distribución de frecuencias en la semana 3, se evidencia que el modelo basado en PCA carece de una transición progresiva y escalonada desde los grupos con mayor índice de fracaso hacia aquellos con calificaciones sobresalientes. Por el contrario, el Autoencoder demuestra una capacidad notable para perfilar y separar de forma clara los clústeres extremos desde etapas muy tempranas, delineando mejor las fronteras entre el riesgo

crítico (R0) y el éxito académico (EXCELENCIA). En definitiva, esta progresión confirma que el modelo AE logra mapear un gradiente de rendimiento mucho más lógico, coherente y útil para la detección temprana del alumnado.

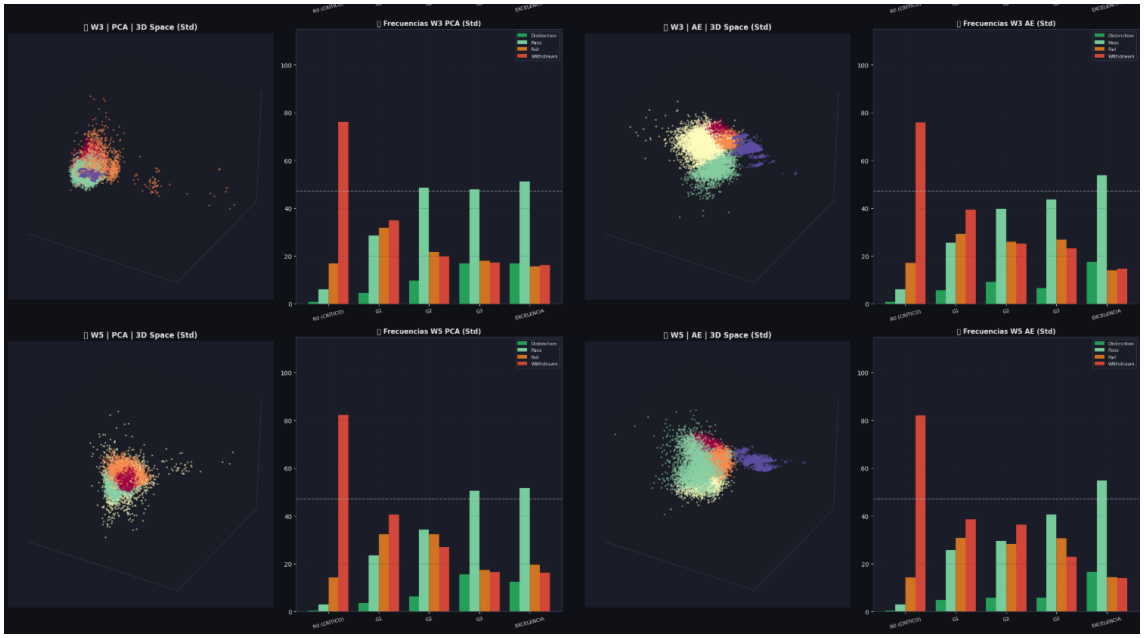


*Ilustración 12 Comparativa visual de reducción de dimensionalidad y clústeres: PCA vs. AE (Semanas 3 y 5)*

Además, al trasladar esto a los gráficos de frecuencias (columnas de barras), observamos el impacto real de dicha separación espacial, concretamente en cómo se construyen estas agrupaciones. Mientras que en PCA el algoritmo de clustering se ve forzado a "cortar" fronteras de manera algo arbitraria dentro de una nube de puntos fuertemente solapada, en el Autoencoder la segmentación de todos los perfiles —incluyendo los grupos de riesgo intermedio (G1, G2, G3)— se apoya en una distribución espacial natural y robusta, validando así su mejor ajuste matemático y su capacidad de perfilado temprano. Otras métricas que validan nuestros argumentos son las expuestas en la tabla 1, donde el Autoencoder demuestra superioridad frente al PCA en todas las dimensiones evaluadas.

| nombre metrica | valor PCA | valor AE | objetivo | ganador | descripcion |
|---|---|---|---|---|---|
| Silueta | 0.0600 | 0.1870 | ↑ MAX | AE 🚀 | Cohesión vs separación (distancias). Más alto = clusters más compactos y separados. |
| Calinski-Harabasz | 903.1506 | 6848.6567 | ↑ MAX | AE 🚀 | Dispersión entre-clusters vs intra-cluster. Más alto = mejor partición. |
| Davies-Bouldin | 3.9037 | 1.6067 | ↓ MIN | AE 🚀 | Solape promedio entre clusters. Más bajo = clusters más separados. |
| BIC | 1416998.4688 | 1086602.2358 | ↓ MIN | AE 🚀 | Bayesian Information Criterion. Evalúa ajuste penalizando la complejidad. Más bajo = mejor. |
| AIC | 1415038.2075 | 1084641.9745 | ↓ MIN | AE 🚀 | Akaike Information Criterion. Similar a BIC pero con menor penalización por complejidad. Más bajo = mejor. |
| Log-Likelihood Promedio | -31.0413 | -23.7910 | ↑ MAX | AE 🚀 | Probabilidad logarítmica media de los datos según el GMM. Más alto = mejor ajuste. |

*Tabla 1 Métricas de evaluación: PCA vs. AE.*

Esta mejora generalizada demuestra que el modelo AE no solo genera clústeres mucho más compactos y mejor separados espacialmente, sino que también garantiza un ajuste probabilístico superior y más robusto para los datos.

Finalmente, la elección de k=5 se establece como la configuración óptima para el modelo Autoencoder. Como refleja la curva de mejora marginal, este valor proporciona el equilibrio ideal: captura una ganancia matemática sustancial en el ajuste del modelo y, al mismo tiempo, garantiza una alta interpretabilidad, evitando una fragmentación excesiva y poco práctica de los perfiles estudiantiles

### 5.5.4. Transformer I: Modelado.

Para el modelado de la red neuronal Transformers se usó Keras, el archivo en el que se materializa la implementación del modelo es "transformer_GLU_classifier.py" dentro de la carpeta "ai_educational_analytics/2_modeling/transformer", y su entrenamiento se realiza en el archivo "train_transformer.py" (Apéndice II), complementariamente hay muchos scripts que sirven de utilidades (finetuning, comparaciones de métricas entre entrenamientos, etc.). Las principales características de su arquitectura son:

- Procesamiento en paralelo: El modelo recibe la información dividida en dos naturalezas muy distintas, por un lado, una rama de secuencias temporales: Toma las interacciones del estudiante semana a semana (clics, entregas, tiempo de conexión). Esta información se transforma en representaciones vectoriales (*embeddings*) más compactas y ricas en significado. Por otro lado, una rama de contexto estático, de la cual, se comentará en más detalle en el siguiente epígrafe.

- Fusión temprana (*Early Fusion*): Mediante un mecanismo de compuertas (*Gated Fusion*), el modelo inyecta el "perfil base" del estudiante en cada una de las semanas de su secuencia temporal. De este modo, la red aprende a interpretar una misma acción (por ejemplo, una bajada de actividad en la semana 3) de forma distinta dependiendo de si el alumno tiene un perfil histórico de alto riesgo o no.

- El motor de atención: Una vez enriquecida, la secuencia ingresa al bloque Transformer. Allí, la "Atención Multicabezal" evalúa toda la evolución del estudiante de forma simultánea, relacionando patrones pasados y recientes. Para garantizar la precisión matemática de este análisis, se aplican máscaras lógicas que filtran el "ruido" (semanas inactivas o de *padding*), obligando a la red a concentrarse únicamente en la información válida.

- Decisión final: Tras el análisis secuencial, el Transformer comprime toda la evolución del estudiante en un único vector de resumen. Para tomar la decisión final con la máxima garantía, el modelo junta tres el resumen de la evolución temporal y el perfil estático procesado.

Finalmente, esta información combinada pasa por un último bloque de red neuronal (el Head de clasificación) que emite la predicción probabilística (Aprobado / Abandono) sobre el estado final del estudiante en el curso.

### 5.5.5. Transformer II: Influencia de características.

Como se expuso previamente, el diseño multimodal del Transformer cuenta con una rama de entrada específica para procesar el contexto estático del alumno. Aprovechando la flexibilidad de esta arquitectura para habilitar distintos bloques de variables, se llevó a cabo un entrenamiento incremental. Inicialmente, el modelo se entrenó empleando de forma exclusiva las secuencias temporales (interacciones semanales por tipo de actividad). Posteriormente, se integró la información socioeconómica y demográfica (rango de edad, índice de riqueza, nivel educativo previo, etc.), obteniendo los siguientes resultados:

```
⚙️ HIPERPARÁMETROS MODIFICADOS:
    * with_static:  False  --->  True

📈 EVOLUCIÓN DE MÉTRICAS (Validación):
    - loss              : 0.0441  ->  0.0413  (Δ: -0.0028 | -6.38%)  🟩 MEJORÓ
    - accuracy          : 0.7125  ->  0.7402  (Δ: +0.0277 | +3.88%)  🟩 MEJORÓ
    - balanced_accuracy : 0.7058  ->  0.7239  (Δ: +0.0181 | +2.57%)  🟩 MEJORÓ
    - auc_ovr           : 0.7625  ->  0.7863  (Δ: +0.0238 | +3.13%)  🟩 MEJORÓ
    - precision         : 0.5195  ->  0.5585  (Δ: +0.0390 | +7.51%)  🟩 MEJORÓ
    - recall            : 0.6886  ->  0.6826  (Δ: -0.0061 | -0.88%)  🟥 empeoró
    - f1_score          : 0.5922  ->  0.6143  (Δ: +0.0221 | +3.73%)  🟩 MEJORÓ
--------------------------------------------------------------------------------
```

*Ilustración 13 Resultados al inyectar variables sociodemográficas*

Como se aprecia en la comparativa de resultados, la flexibilidad de la arquitectura implementada facilita una experimentación ágil. Con tan solo modificar el hiperparámetro "with_static" de False a True, el sistema incorpora automáticamente las variables sociodemográficas y de contexto al proceso de entrenamiento. Esta activación demuestra empíricamente que, a excepción de un levísimo descenso en el recall, la inclusión de la información estática se traduce en una mejora generalizada de la capacidad predictiva del modelo, optimizando significativamente la precisión, el F1-Score y reduciendo la pérdida global (loss).

Posteriormente, para completar el marco de información del modelo, se procedió a integrar un bloque de variables acumulativas a la arquitectura que ya contenía las secuencias temporales y los datos estáticos. Estas nuevas

características sintetizan el historial de esfuerzo del estudiante hasta la semana objeto de predicción (como, por ejemplo, el volumen total de clics acumulados o la nota media en las evaluaciones entregadas hasta la fecha). La incorporación de esta 'memoria histórica' agregada arrojó los siguientes resultados

```
🚀 COMPARATIVA: [29] 2026-03-10 19:09:53  vs  [30] 2026-03-10 19:11:31
  ⚙️ HIPERPARÁMETROS MODIFICADOS:
      * accumulated_uptow:  False  --->  True

  📈 EVOLUCIÓN DE MÉTRICAS (Validación):
      - loss              : 0.0353  ->  0.0316  (Δ: -0.0038 | -10.63%)  🟩 MEJORÓ
      - accuracy          : 0.7319  ->  0.7974  (Δ: +0.0655 | +8.95%)  🟩 MEJORÓ
      - balanced_accuracy : 0.7182  ->  0.7649  (Δ: +0.0467 | +6.50%)  🟩 MEJORÓ
      - auc_ovr           : 0.7794  ->  0.8327  (Δ: +0.0534 | +6.85%)  🟩 MEJORÓ
      - precision         : 0.5462  ->  0.6605  (Δ: +0.1143 | +20.92%)  🟩 MEJORÓ
      - recall            : 0.6836  ->  0.6826  (Δ: -0.0010 | -0.15%)  🟥 empeoró
      - f1_score          : 0.6072  ->  0.6713  (Δ: +0.0641 | +10.56%)  🟩 MEJORÓ
```

*Ilustración 14 Influencia de variables acumulativas en resultados de entrenamiento*

Como muestra la comparativa, las métricas acumulativas mejoran de forma consistente el rendimiento del modelo, especialmente en precisión y F1-score. Para analizar el papel del clustering, se realizaron dos pruebas sucesivas. En la primera, mostrada en la Ilustración 15, se incorporaron las soft labels y la entropía a una configuración que aún no incluía variables acumulativas, observándose una mejora moderada en validación. Esto sugiere que las señales de clustering pueden aportar contexto útil cuando el modelo aún no dispone de variables acumulativas:

```
  ⚙️ HIPERPARÁMETROS MODIFICADOS:
      * use_clustering_features:  False  --->  True

  📈 EVOLUCIÓN DE MÉTRICAS (Validación):
      - loss              : 0.0413  ->  0.0403  (Δ: -0.0010 | -2.36%)  🟩 MEJORÓ
      - accuracy          : 0.7402  ->  0.7718  (Δ: +0.0317 | +4.28%)  🟩 MEJORÓ
      - balanced_accuracy : 0.7239  ->  0.7360  (Δ: +0.0121 | +1.68%)  🟩 MEJORÓ
      - auc_ovr           : 0.7863  ->  0.7974  (Δ: +0.0111 | +1.41%)  🟩 MEJORÓ
      - precision         : 0.5585  ->  0.6187  (Δ: +0.0602 | +10.77%)  🟩 MEJORÓ
      - recall            : 0.6826  ->  0.6450  (Δ: -0.0375 | -5.50%)  🟥 empeoró
      - f1_score          : 0.6143  ->  0.6316  (Δ: +0.0172 | +2.81%)  🟩 MEJORÓ
--------------------------------------------------------------------------------
```

*Ilustración 15 Resultados de inyectar variables asociadas al clustering en ausencia de variables acumulativas*

No obstante, este resultado se contrastó en una configuración más completa, incorporando variables acumulativas, como se muestra en la Ilustración 16. En este nuevo escenario, la mejora asociada al clustering dejó de ser determinante, ya que la información acumulada capturaba de manera más directa y robusta la evolución del comportamiento del estudiante. Esto sugiere que la ganancia observada inicialmente no respondía tanto a un valor diferencial del clustering, sino a que, en ausencia de señales acumulativas, este actuaba como una fuente auxiliar de contexto.

```
⚙️ HIPERPARÁMETROS MODIFICADOS:
    * use_clustering_features:  False  --->  True

📈 EVOLUCIÓN DE MÉTRICAS (Validación):
    - loss              : 0.0316  ->  0.0315  (Δ: -0.0000 | -0.11%)  🟩 MEJORÓ
    - accuracy          : 0.7974  ->  0.7974  (Δ: +0.0000 | +0.00%)  ⬜ Estable
    - balanced_accuracy : 0.7649  ->  0.7592  (Δ: -0.0057 | -0.75%)  🟥 empeoró
    - auc_ovr           : 0.8327  ->  0.8284  (Δ: -0.0043 | -0.52%)  🟥 empeoró
    - precision         : 0.6605  ->  0.6670  (Δ: +0.0066 | +0.99%)  🟩 MEJORÓ
    - recall            : 0.6826  ->  0.6623  (Δ: -0.0203 | -2.97%)  🟥 empeoró
    - f1_score          : 0.6713  ->  0.6646  (Δ: -0.0067 | -1.00%)  🟥 empeoró
--------------------------------------------------------------------------------
```

*Ilustración 16 Efecto del clustering en una configuración con variables acumulativas*

En síntesis, las variables acumulativas ofrecen una representación más compacta y altamente informativa del historial del estudiante, con un margen de mejora mucho más notable sobre el rendimiento del modelo. Por su parte, las variables de clustering mostraron cierta utilidad en escenarios donde el Transformer aún no disponía de información acumulativa, ya que aportaban contexto adicional sobre patrones de comportamiento. Sin embargo, su contribución se redujo de forma clara al incorporar las métricas acumuladas. En consecuencia, la configuración final prioriza las variables acumulativas como componente central del modelo predictivo, mientras que el clustering se mantiene como un módulo complementario de segmentación e interpretabilidad dentro del enfoque híbrido global del sistema.

### 5.5.6. Transformer III: Estrategia del entrenamiento.

Una vez diseñada la arquitectura multimodal, el proceso de aprendizaje del modelo (gestionado mediante el script train_transformer.py) se configuró estratégicamente para afrontar el fuerte desbalanceo natural de los alumnos y la necesidad de adaptar el sistema a diferentes definiciones de "riesgo académico". Para lograr que el modelo sea útil en un entorno real, la estrategia de entrenamiento se fundamenta en los siguientes pilares:

- Flexibilidad en los escenarios de predicción: El sistema no está anclado a un único objetivo. Permite resolver el problema con distintos niveles de granularidad: desde una clasificación binaria directa (estudiantes en riesgo frente a casos de éxito, permitiendo aislar abandonos o suspensos según convenga), pasando por una visión trinaria (fracaso, abandono y éxito), hasta una clasificación cuaternaria que respeta todas las calificaciones originales (incluyendo las matrículas de honor).
- Aprendizaje enfocado en la minoría (Focal Loss): Debido al desbalance natural en las aulas (donde la gran mayoría aprueba), los algoritmos tradicionales tienden a ignorar a la minoría en riesgo para maximizar su acierto global. Para neutralizar este sesgo, se implementa la técnica *Focal Loss*. Este mecanismo penaliza severamente los errores en la clase minoritaria y resta peso a los casos evidentes, obligando al modelo a concentrarse en los estudiantes más difíciles de detectar.
- Ajuste dinámico de la alerta (Threshold Tuning): En los escenarios de predicción de riesgo, disparar una alerta simplemente porque la probabilidad cruza la barrera del 50% rara vez es la mejor decisión. El sistema incorpora un algoritmo que evalúa cientos de puntos de corte de forma automática durante la fase de validación. Su objetivo es encontrar el umbral matemático óptimo que logre el equilibrio perfecto: maximizar la

cantidad de alumnos en peligro detectados (exhaustividad), garantizando al mismo tiempo que no se sature a los docentes con falsas alarmas (precisión).

- Estabilidad y prevención de sobreajuste: Si detecta que el aprendizaje se estanca, reduce de forma autónoma la velocidad a la que actualiza sus conocimientos para realizar ajustes más finos. Si la mejora se detiene por completo, el entrenamiento finaliza prematuramente (Early Stopping) y rescata la versión exacta de la red que logró el mejor equilibrio predictivo.

Finalmente, para gobernar la complejidad de este ecosistema predictivo y garantizar la robustez de los resultados, el proyecto se dotó de una infraestructura de experimentación automatizada. Conscientes de que el rendimiento de una red Transformer es sensible a su configuración, se desarrolló un script de búsqueda diseñado para evaluar varias combinaciones de hiperparámetros (tasas de aprendizaje, dimensiones latentes, número de cabezas de atención, ratios de dropout, etc.). Para gestionar la cantidad de modelos generados en este proceso, se implementó paralelamente un sistema de evaluación comparativa automática. Esta herramienta rastrea, archiva y contrasta el rendimiento de cada iteración, permitiendo auditar de un vistazo qué modificaciones se traducen en mejoras reales (aumentos en Recall o precisión) y cuáles provocan un empeoramiento.

Gracias a este marco de trabajo, el ajuste fino del modelo dejó de ser un proceso de ensayo y error manual para convertirse en una toma de decisiones guiada estrictamente por la evidencia empírica.

## 5.6. Evaluación

A nivel técnico, el proceso de evaluación se ha diseñado de manera transversal a lo largo de los diferentes scripts y cuadernos de experimentación del proyecto. Para garantizar una trazabilidad rigurosa, todos los reportes, gráficas y métricas generadas durante las fases de validación se exportan automáticamente al directorio reports/, mientras que los archivos con los pesos de los modelos finalmente entrenados se preservan en la carpeta models/ (Véase apéndice I).

El presente epígrafe tiene como propósito establecer el marco teórico y justificar la elección de las métricas que rigen esta evaluación, reservando el análisis empírico de las cifras obtenidas para el capítulo de Resultados.

Adicionalmente, la evaluación de un sistema predictivo en el ámbito de la Minería de Datos Educativos no puede limitarse a cuantificar su tasa de acierto global. Dado que el objetivo primordial del proyecto es construir una alerta temprana para permitir la intervención docente, el modelo debe ser evaluado bajo una óptica multidimensional: su robustez estadística frente a datos desbalanceados, el análisis del coste del error y su interpretabilidad pedagógica.

### 5.6.1. Evaluación de Autoencoder.

Dado que el ecosistema propuesto incluye un bloque de aprendizaje no supervisado, su éxito no puede medirse con métricas de clasificación tradicionales. La calidad del Autoencoder y del agrupamiento posterior se evaluará mediante dos enfoques:

- Fidelidad de Reconstrucción: Monitorización de la pérdida de reconstrucción (Huber Loss) durante el entrenamiento, garantizando que la

compresión al espacio latente no destruya la información estructural del estudiante.

- Clustering como tarea derivada: La prueba definitiva de la utilidad del Autoencoder no es su capacidad de compresión aislada, sino su impacto empírico en la fase de agrupamiento. Se contrastará si el espacio latente generado por el AE permite encontrar perfiles de estudiantes más definidos y robustos frente al uso de reducciones lineales clásicas (PCA).

### 5.6.2. Evaluación de Clustering.

Para medir la calidad de las agrupaciones generadas, la evaluación no se limita a un único indicador, sino que aborda el problema desde dos dimensiones complementarias: la forma geométrica de los grupos y su eficiencia matemática.

- Calidad Estructural de la Segmentación: Esta dimensión evalúa visual y geométricamente cómo se distribuyen los estudiantes en el espacio latente. Para comprobar si los grupos están bien construidos, utilizamos tres métricas:
  - Coeficiente de Silueta: Mide qué tan "seguro" está un estudiante en su grupo. Matemáticamente, evalúa si los alumnos de un mismo clúster están muy juntos entre sí (cohesión) y, al mismo tiempo, muy lejos de los alumnos de otros perfiles (separación). Cuanto más alto es el valor, más claras son las fronteras del grupo.
  - Índice de Calinski-Harabasz: Actúa como un medidor de densidad. Premia matemáticamente a los modelos que logran formar grupos que parecen "islas": muy compactos por dentro y muy alejados del resto de grupos. Un valor alto indica una estructuración fuerte y bien definida.
  - Índice de Davies-Bouldin: Funciona como un detector de solapamiento. Su objetivo es calcular cuánto se mezclan o se "pisan"

las fronteras de los diferentes clústeres. Al revés que los anteriores, aquí se busca el valor más bajo posible, ya que penaliza a los grupos que se confunden entre sí.

- Criterio de Información Bayesiano (BIC) y el Criterio de Akaike (AIC). En términos prácticos, estas dos métricas buscan el equilibrio entre precisión y simplicidad. Miden con qué exactitud el modelo representa la realidad de los estudiantes, pero le aplican una "multa" o penalización matemática por cada grupo extra que se crea de forma innecesaria. De esta manera, nos garantizan encontrar el modelo más eficiente: aquel que explica bien los datos utilizando la menor cantidad de clústeres posible (por lo que siempre buscaremos los valores más bajos en ambos criterios).

### 5.6.3. Evaluación del Transformer.

A diferencia de los modelos tradicionales donde el éxito se mide habitualmente por la exactitud global (Accuracy), la evaluación de la red neuronal Transformer debe alinearse estrictamente con su propósito pedagógico: funcionar como un sistema de alerta temprana.

En un entorno educativo real, existe un fuerte desbalance natural en las aulas (donde la gran mayoría del alumnado aprueba y solo una minoría fracasa o abandona). En este contexto, el coste de cometer un error no es simétrico. Para un docente, es mucho más grave no detectar a un alumno en riesgo de abandono (falso negativo) que enviarle un mensaje de apoyo preventivo a un alumno que finalmente iba a aprobar (falso positivo). Por consiguiente, el desempeño del modelo se evaluará bajo el siguiente conjunto de métricas especializadas:

- Recall (Exhaustividad): Constituye la métrica principal para un sistema de alerta. Mide la proporción de estudiantes en riesgo real que el modelo logra identificar correctamente. Un Recall alto garantiza que la "red de arrastre" del sistema no deje a ningún alumno vulnerable atrás.

- Precision (Precisión): Evalúa la fiabilidad de las alertas generadas. Responde a la pregunta: de todos los estudiantes que el modelo marcó en riesgo, ¿cuántos lo estaban realmente? Actúa como contrapeso del Recall para garantizar que no se sature al equipo docente con falsas alarmas.

- F1-Score y Exactitud Balanceada (Balanced Accuracy): Mientras que la exactitud estándar puede verse sesgada por la clase mayoritaria (los aprobados), estas métricas son robustas ante el desbalanceo. El F1-Score proporciona la media armónica entre Precisión y Exhaustividad, mientras que la Exactitud Balanceada calcula el acierto promedio ponderado de todas las clases, garantizando que el modelo es justo y aprende de los grupos minoritarios.

- AUC-OVR (Área bajo la curva - One vs Rest): Permite evaluar la capacidad del modelo probabilístico para separar y distinguir correctamente a los alumnos de las diferentes categorías (Éxito, Fracaso, Abandono) sin depender de un umbral de decisión fijo.

- Loss (Pérdida Matemática y Calibración de Pesos): Representa el error interno que la red intenta minimizar durante el entrenamiento. Es en este punto donde reside una de las características más potentes y adaptables del sistema: el modelo permite configurar la "fuerza" o el peso que se le otorga a cada clase. Dependiendo de la naturaleza del problema que se quiera resolver o de la política del centro educativo, el Transformer puede calibrarse matemáticamente para ser extremadamente sensible (penalizando fuertemente si se le escapa un abandono) o más equilibrado.

- Accuracy (Exactitud): Aunque se registrará el porcentaje de acierto global del sistema para tener una visión general, se considerará una métrica secundaria, asumiendo que un ligero descenso en la misma es aceptable si se traduce en una mejora en la detección de los casos de riesgo (Recall).

La combinación de estos indicadores permitirá realizar un análisis exhaustivo en el capítulo de Resultados, garantizando que el modelo no solo es matemáticamente sólido y configurable, sino pedagógicamente útil y seguro para su despliegue en el aula.

## 5.7. Dockerización y Pipelines Automatizados

Para garantizar que la arquitectura de Deep Learning sea agnóstica al hardware de diferentes dispositivos y así garantizar su reproducibilidad se ha diseñado el proyecto bajo una infraestructura modular y reproducible basada en dos pilares:

Contenerización del entorno (Docker): Se ha implementado una arquitectura de contenedores que aísla las dependencias críticas (como las bibliotecas CUDA/cuDNN para aceleración por GPU):

- Dockerfile: Define una imagen base inmutable con la versión exacta de python 3.11. Incluye todas las capas de sistema necesarias para la aceleración por hardware y las bibliotecas de cálculo numérico (TensorFlow, Scikit-learn), garantizando que el modelo se comporte igual en un servidor local que en la nube, o en cualquier hardware.
- Docker-Compose: Actúa como el orquestador del entorno, configurando de forma automática el montaje de volúmenes de datos, la gestión de puertos y la inyección de variables de entorno, permitiendo levantar el "laboratorio experimental" completo con un solo comando.

- Dev Containers: Se ha integrado un estándar de desarrollo que permite vincular el IDE directamente con el contenedor. Esto asegura que el código escrito y el código ejecutado compartan siempre el mismo ecosistema, librerías y versiones de compiladores.

Orquestación del Pipeline (Makefile): A diferencia del enfoque tradicional basado exclusivamente en notebooks experimentales, este proyecto implementa una Pipeline-as-Code profesional. Se ha diseñado un archivo maestro de orquestación (Makefile) que automatiza el flujo de trabajo completo:

- Ingesta de datos (make data): Realiza la limpieza, el limpiado preventivo de directorios y la división del dataset (Split) de forma determinista.
- Entrenamiento y Latencia (make prep_latent): Encadena de forma secuencial el entrenamiento del Autoencoder y la generación de embeddings, asegurando la integridad referencial entre los modelos y sus representaciones vectoriales.
- Reproducibilidad Total: Este sistema permite que cualquier investigador pueda replicar el experimento completo desde cero ejecutando un comando único, eliminando la intervención manual y los posibles sesgos humanos en el preprocesamiento de los datos.

# 6. Resultados.

En este capítulo se presentan los resultados obtenidos tras la implementación de la arquitectura híbrida propuesta. El análisis se estructura de acuerdo con las distintas fases del sistema: aprendizaje no supervisado, modelado secuencial con Transformer y mecanismos de explicabilidad.

## 6.1. Resultados de Autoencoder.

El entrenamiento del autoencoder se realizó bajo un esquema no supervisado, cuyo objetivo principal consiste en aprender una representación latente comprimida de los datos que preserve la mayor cantidad de información estructural posible, para poder validar su funcionalidad se analiza la fidelidad de reconstrucción junto con visualizaciones de las representaciones vectoriales.

### 6.1.1. Fidelidad de reconstrucción.

Para evaluar la capacidad de reconstrucción del modelo se utilizó la función de pérdida Huber Loss que mide la discrepancia entre el vector original de entrada $x$ y su reconstrucción $x'$ generada por el autoencoder. A mayor diferencia entre ambos, mayor será el valor de la pérdida. La siguiente imagen

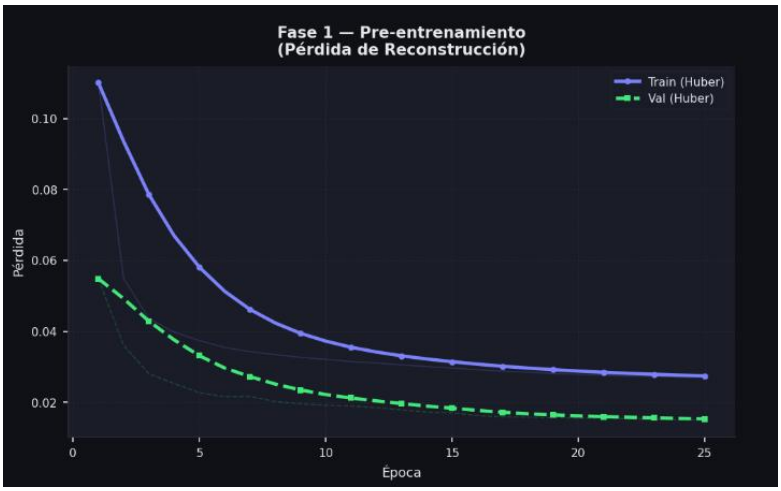


*Ilustración 17 Evolución de huber loss durante entrenamiento de autoencoder*

El descenso inicial de ambas curvas y su estabilización indican que el autoencoder aprende eficazmente una representación latente y converge sin signos de sobreajuste, al no presentar divergencia entre ellas. Además, que la pérdida de validación se mantenga ligeramente por debajo de la de entrenamiento es un comportamiento esperado debido a mecanismos de regularización como Dropout o Batch Normalization. Mientras que en la fase de entrenamiento estas técnicas introducen ruido y penalizan la red, durante la validación se desactivan, lo que permite al modelo generar reconstrucciones más consistentes y reportar un error menor.

Una vez completada la fase de preentrenamiento se inicia la fase de entrenamiento conjunto, en la que se incorpora el término adicional correspondiente al objetivo de clustering (divergencia KL): por un lado, busca la preservación de la información original y, por otro, la reorganización estructural del espacio latente en agrupaciones. La dinámica de este proceso puede observarse en la siguiente figura, donde se muestra la evolución de la pérdida asociada al objetivo de clustering durante el entrenamiento conjunto.

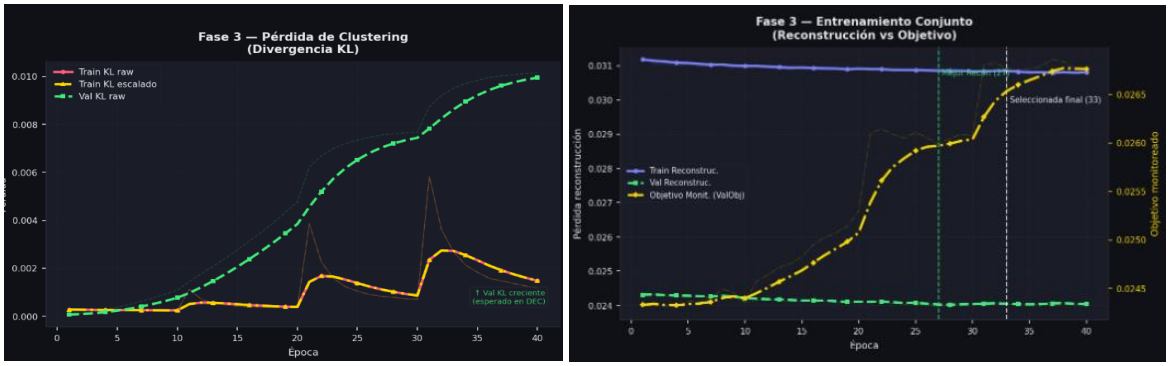


*Ilustración 18 Evolución de perdidas en la fase de entrenamiento conjunto*

Durante la Fase 3, observamos en la gráfica izquierda que la divergencia KL aumenta, tal y como se espera en un modelo DEC. A su vez, la gráfica de la derecha demuestra que la pérdida de reconstrucción se mantiene estable y tiende a la baja, independientemente del aumento en la métrica objetivo. Los saltos visibles en ambas gráficas corresponden a la reagrupación periódica de los

clústeres. Para demostrar que este comportamiento interno realmente optimiza nuestro objetivo, evaluamos el espacio latente con dos métricas independientes a la pérdida KL: el coeficiente de Silhouette y el índice Davies-Bouldin. La siguiente figura confirma el éxito del agrupamiento, mostrando una mejora significativa de ambas métricas durante esta fase.

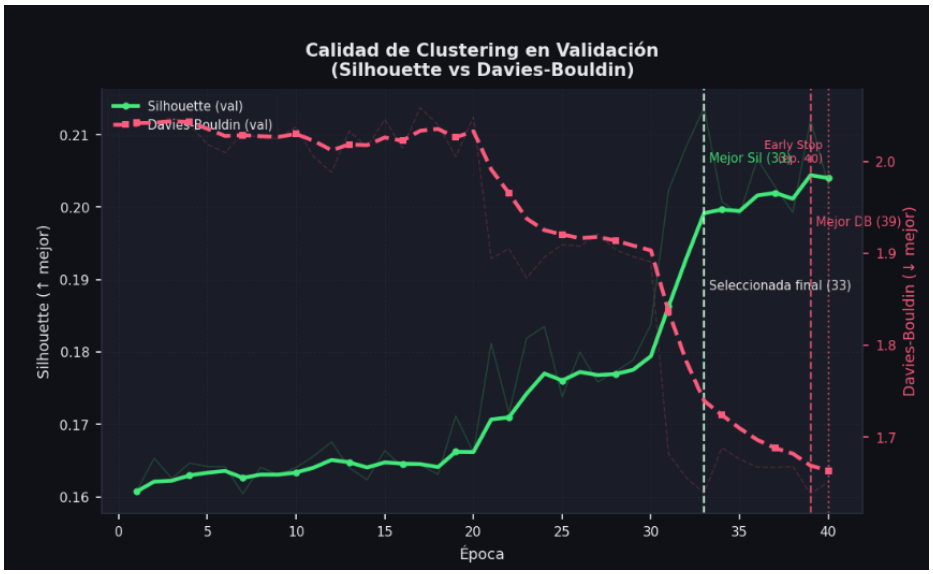


*Ilustración 19 Evolución de Sillouette y Davies-Bounldir en la fase 3*

Específicamente, la mejora de las métricas de clustering se intensifica a partir de la época 20 y alcanza sus mejores valores individuales en las últimas épocas del entrenamiento. No obstante, la selección final del modelo no se realiza únicamente por el máximo de separación entre clústeres, sino mediante un criterio híbrido que exige, en primer lugar, mantener la pérdida de reconstrucción de validación dentro del 3% de su valor mínimo y, dentro de ese conjunto de épocas admisibles, escoger la que optimiza conjuntamente Silhouette y Davies-Bouldin. Bajo este criterio, la época 33 se selecciona como el mejor punto de equilibrio entre fidelidad de reconstrucción y calidad del agrupamiento, mientras que la época 39 corresponde al punto de parada del entrenamiento y al mejor valor individual de Davies-Bouldin.

### 6.1.2. Representaciones vectoriales (Embeddings).

Tal y como se aprecia en la Ilustración 20, la primera columna muestra a cada estudiante representado por un punto, donde sus 60 características originales han sido reducidas a un espacio bidimensional mediante PCA. La segunda columna exhibe a los mismos estudiantes tras procesar la información con un *autoencoder*, el cual comprime los datos de 60 a 24 características latentes, proyectadas también en 2D mediante PCA. Por último, la tercera columna ilustra la reconstrucción de los datos; es decir, el paso inverso de las 24 características latentes de vuelta a los 60 originales, visualizadas nuevamente a través de PCA.

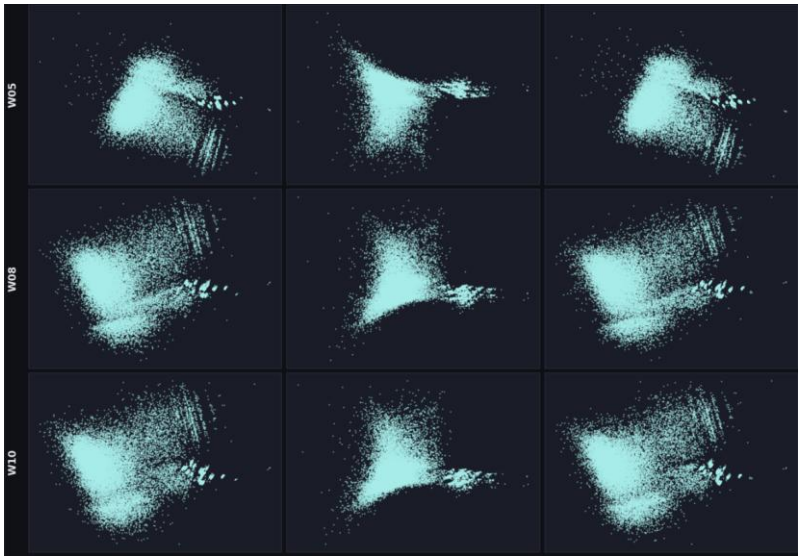


*Ilustración 20 Representación de datos de estudiantes en el espacio original, latente y reconstrucción - Autoría Propia - Apéndice I - Reportes -AE*

Este comportamiento evidencia tres logros clave del modelo:

- Agrupación densa En el espacio latente, los datos forman estructuras más densas gracias a las pérdidas de reconstrucción y *clustering*.
- La reconstrucción mantiene la forma original, logrando compresión sin pérdida significativa de información.
- Generación de *embeddings* optimizados para segmentar perfiles de aprendizaje claramente separables.

## 6.2. Resultados de clustering.

Ya en el apartado 5.5.3 Clustering se justificó de manera empírica porque se escogió el modelo de mixtura de gaussianas junto Autoencoder para la clusterización de los estudiantes. Los resultados que se analizarán a continuación se encuentran en la carpeta de reports/clustering (Véase Apéndice I) y se efectúan sobre el conjunto de validación y test.

Se procede a analizar la distribución de resultados académicos dentro de cada grupo identificado permitiendo evaluar si los grupos generados presentan coherencia semántica y diferenciación real en términos de rendimiento y abandono, más allá de las métricas propias de aprendizaje no supervisado para agrupaciones. En la ilustración 20 observamos como el modelo ha agrupado a los estudiantes con la información acumulada únicamente de la primera semana.

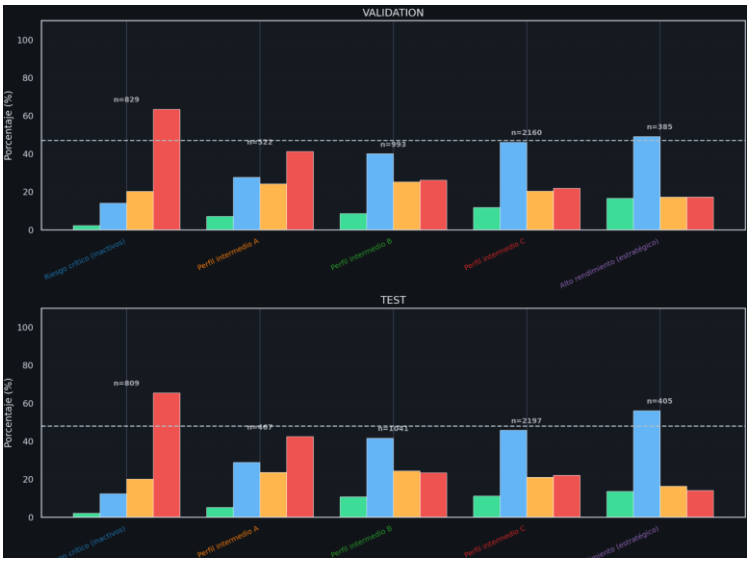


*Ilustración 21 Agrupación de estudiantes a 1 semana de curso*

Uno de los aspectos más reseñables es como el modelo es capaz de crear un grupo cuya pertenencia implica un 65% de probabilidad de abandonar la universidad y aproximadamente un 20% de suspender. Por lo que ya si agrupa a un nuevo estudiante en este grupo hay suficientes motivos para intervenir. Sin

embargo, el modelo aún no es lo suficientemente bueno para separar bien los grupos intermedios o dejar más limpio el grupo de alto rendimiento.

Continuamos observando la ilustración 21, aquí el modelo ha agrupado a los estudiantes con la información de las primeras 5 semanas. Ya aquí vemos una reducción de casos que aprueban o sacan sobresalientes en el grupo de riesgo y vemos que ya concentra más del 80% de los abandonos, además, vemos también que la proporción de aprobados y sobresalientes crece en el grupo de alto rendimiento y el perfil intermedio C. Por lo que el modelo esta separando mejor, a pesar de esto, 5 semanas sigue siendo muy poca información.

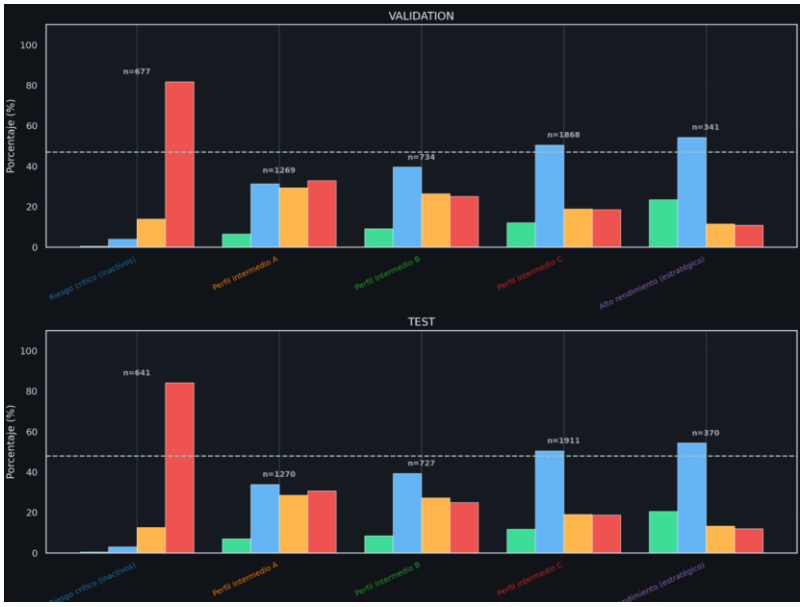


*Ilustración 22 Agrupaciones de estudiantes por grupos*

Además, los perfiles intermedios exhiben una evolución coherente y progresiva desde las tasas de abandono hacia las de aprobación, confirmando la solidez del ordenamiento latente aprendido por el algoritmo.

Todo esto indica que con datos limitados, el modelo es más preciso detectando el riesgo de abandono que confirmando el éxito académico definitivo, lo cual, se alinea bastante bien con nuestro objetivo. Para evaluar la consolidación de estos grupos, a continuación, se analizan los resultados de la

semana 20 (W20); en esta etapa avanzada, la mayor acumulación de información conductual y evaluativa debería reflejar una diferenciación mucho más nítida y definitiva entre todos los clústeres.

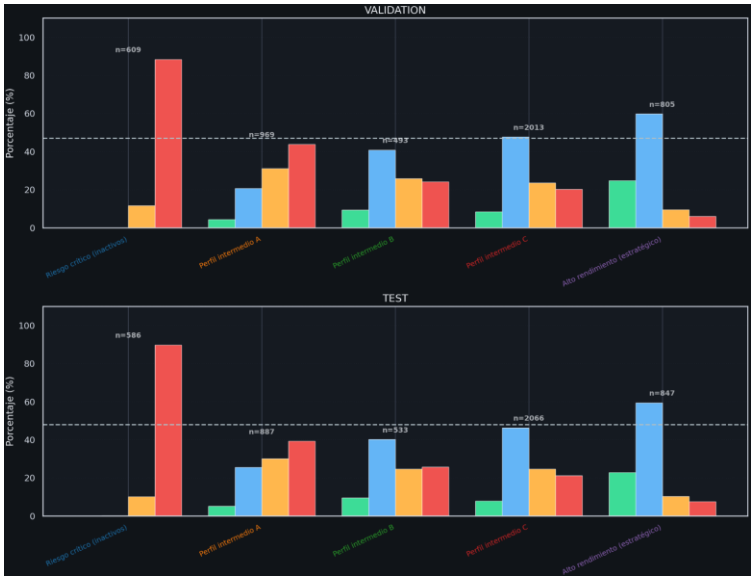


*Ilustración 23 Distribución de resultados académicos por perfil en la semana 20 (Validación y Test)*

En la semana 20 (W20), la mayor acumulación de datos permite una consolidación mucho más nítida de los perfiles. Por un lado, el grupo de "Riesgo crítico" (clúster 0) reafirma su estabilidad manteniendo una tasa de abandono cercana al 90%, adicionalmente, ya no hay casos de aprobados o sobresalientes en este grupo, lo que confirma la fiabilidad de la alerta temprana. Por otro lado, a diferencia de lo ocurrido en la semana 5, el perfil de "Alto rendimiento" logra ahora una diferenciación clara, reduciendo drásticamente su porcentaje de suspensos y abandonos.

En la parte de inteligencia artificial explicable para dotar de interpretabilidad a estos resultados y conocer mejor que caracteriza a cada grupo se empleará una matriz Z-Effect, permitiendo identificar los patrones conductuales que definen a los perfiles extremos y revelando los matices específicos que justifican las agrupaciones intermedias.

## 6.3. Resultados en Transformer.

Como se detalló en la fase de modelado, la arquitectura de entrenamiento diseñada ofrece una gran flexibilidad, permitiendo abordar el problema mediante clasificación binaria, trinaria o cuaternaria de forma sencilla. En aras de la concisión y para evitar extender excesivamente esta memoria, el análisis principal se centrará en la clasificación binaria (Aprobado/Sobresaliente frente a Abandono), al ser el enfoque que reportó un mejor rendimiento predictivo. Adicionalmente, se incluirá una breve evaluación complementaria del resto de configuraciones.

### 6.3.1. Clasificación binaria: Aprobar vs Abandonar.

En esta configuración se consideran únicamente dos clases diferenciadas en el entrenamiento: por un lado, los estudiantes que aprueban o alcanzan sobresaliente, y por otro, aquellos que abandonan el curso (*withdrawn*). En consecuencia, los estudiantes con resultado de suspenso quedan excluidos de esta fase de modelado, con el objetivo de simplificar la frontera de decisión y centrar el análisis en la discriminación temprana entre éxito académico y abandono.

| semana | n_sample | accuracy | Balanced accuracy | precision | recall | auc |
|---|---|---|---|---|---|---|
| 1 | 2858 | 0.6519 | 0.6615 | 0.4181 | 0.6828 | 0.7001 |
| 3 | 3268 | 0.7454 | 0.7175 | 0.5541 | 0.6506 | 0.7824 |
| 5 | 3304 | 0.7893 | 0.7624 | 0.6284 | 0.6968 | 0.8266 |
| 8 | 3321 | 0.8380 | 0.8030 | 0.7295 | 0.7176 | 0.8720 |
| 10 | 3330 | 0.8450 | 0.8200 | 0.7278 | 0.7589 | 0.8837 |
| 12 | 3331 | 0.8577 | 0.8319 | 0.7537 | 0.7691 | 0.8978 |
| 15 | 3336 | 0.8930 | 0.8663 | 0.8305 | 0.8010 | 0.9231 |
| 18 | 3337 | 0.9092 | 0.9020 | 0.8217 | 0.8843 | 0.9498 |
| 20 | 3338 | 0.9269 | 0.9116 | 0.8777 | 0.8741 | 0.9576 |
| 24 | 3339 | 0.9470 | 0.9373 | 0.9074 | 0.9138 | 0.9740 |
| 28 | 3339 | 0.9581 | 0.9511 | 0.9247 | 0.9341 | 0.9831 |

*Tabla 2 Métricas obtenidas en clasificación binaria (Éxito vs Abandono)*

Los resultados muestran una idea bastante clara: cuanto más avanza el curso, mejor es el modelo identificando qué estudiantes tienen riesgo de abandono. Al principio, en las semanas 1 y 3, el rendimiento es más discreto porque todavía hay poca información sobre el comportamiento del alumnado; es decir, el sistema aún "conoce poco" a cada estudiante. Aun así, ya desde la semana 5 el modelo alcanza un AUC de 0.8266, lo que significa que distingue bastante bien entre estudiantes que acabarán teniendo éxito y estudiantes que podrían abandonar. Dicho de forma simple, el AUC mide la capacidad general del modelo para separar ambos perfiles: cuanto más cerca de 1, mejor lo hace.

A partir de ahí, la mejora es constante. La accuracy indica el porcentaje total de aciertos, mientras que la balanced accuracy sirve para comprobar que el modelo no solo acierta en la clase mayoritaria, sino que mantiene un rendimiento equilibrado entre ambos grupos. Por su parte, la precision nos dice cuántos de los estudiantes señalados como "en riesgo" realmente lo estaban, y el recall refleja cuántos de todos los casos reales de abandono consiguió detectar el modelo. En este caso, ver que todas estas métricas suben de forma progresiva es una buena señal: no solo predice más, sino que predice mejor y de forma más fiable.

En términos prácticos, esto significa que el modelo ya empieza a ser útil relativamente pronto y se vuelve muy sólido conforme avanza el semestre. Por ejemplo, en la semana 15 el AUC ya es 0.9231, lo que indica una capacidad muy alta para identificar perfiles de riesgo, y en la semana 28 llega a 0.9831, un valor excelente. Además, en esa fase final la precision (0.9247) y el recall (0.9341) están muy equilibrados, lo que sugiere que el sistema comete pocos errores tanto al señalar falsos riesgos como al dejar escapar estudiantes que realmente abandonan. En resumen, el modelo funciona como una herramienta

de alerta temprana bastante prometedora y gana fiabilidad a medida que dispone de más evidencia del comportamiento académico del estudiante.

Si tomamos como referencia los resultados reportados por el paper de GLU-Transformer (Luo, Yu, Xie, Wu, & Xu, 2024) expuestos en la ilustración 23, se observa un comportamiento muy similar al obtenido en nuestro modelo: el rendimiento mejora de forma progresiva a medida que avanza el curso y se acumula más información sobre la actividad del estudiante en el entorno virtual. En su caso, las métricas evolucionan desde valores moderados en la semana 5 hasta un desempeño muy elevado en la semana 25, lo que refuerza la idea de que los modelos secuenciales son especialmente adecuados para capturar patrones de riesgo de abandono cuando la evidencia temporal se va consolidando.

| | Weeks | Accuracy (%) | Precision (%) | Recall (%) |
|---|---|---|---|---|
| **GLU-Transformer** | 5 | 80.07 | 81.73 | 62.06 |
| | 10 | 85.65 | 86.67 | 74.15 |
| | 15 | 89.76 | 91.35 | 82.96 |
| | 20 | 93.26 | 95.02 | 88.24 |
| | 25 | 96.54 | **97.68** | **92.57** |

*Ilustración 24 Resultados del paper GLU-Transformer (Luo, Yu, Xie, Wu, & Xu, 2024)*

Al comparar ambos resultados, la tendencia es similar: el rendimiento mejora conforme avanza el curso y el modelo dispone de más información para distinguir entre éxito y abandono. En nuestro caso, esta evolución se aprecia especialmente en el AUC, que pasa de 0.8266 en la semana 5 a 0.9831 en la semana 28, lo que refleja una capacidad muy alta para discriminar entre ambos perfiles. No obstante, nuestro modelo adopta un enfoque más arriesgado, ya que prioriza la detección de abandonos incluso a costa de sacrificar algo de precisión. Es decir, acepta generar más falsos positivos con tal de reducir el número de estudiantes en riesgo que podrían pasar desapercibidos, una decisión coherente con el objetivo de alerta temprana. En conjunto, estos resultados muestran que

el modelo desarrollado en este TFM ofrece un rendimiento competitivo y alineado con el estado del arte, situándose en un nivel comparable al del paper de referencia.

### 6.3.2. Otros tipos de clasificación.

De forma complementaria a la formulación binaria principal (Aprobados vs. Abandonos), se evaluaron configuraciones de clasificación trinaría y cuaternaria con el objetivo de analizar el comportamiento del modelo bajo escenarios de mayor granularidad. Los resultados completos pueden consultarse en el Apéndice III, donde se detallan todas las métricas por ventana temporal. De manera general, se observa una evolución coherente y progresiva del rendimiento en todos los casos: las métricas mejoran sistemáticamente conforme aumenta la información disponible (W=5 → W=25) y la función de pérdida desciende de forma estable, lo que confirma la consistencia del entrenamiento.

No obstante, el incremento en el número de clases introduce una mayor complejidad en la frontera de decisión, reduciendo el rendimiento global respecto a la formulación binaria. En el escenario trinario se aprecia una caída moderada en accuracy y F1-macro, mientras que en la configuración cuaternaria la degradación es más acusada, especialmente en balanced accuracy y métricas macro, reflejando un mayor solapamiento entre perfiles académicos intermedios.

En conjunto, estos resultados evidencian que, aunque el modelo mantiene estabilidad estructural, su desempeño óptimo se alcanza en la formulación binaria (Éxito vs Abandono), siendo esta la más adecuada para el objetivo predictivo planteado en el presente trabajo.

## 6.4. IA Explicable (XAI) en clustering.

Aunque el modelo de Clustering segmenta los perfiles con coherencia estadística, es necesario caracterizar cada grupo con mayor precisión. Para ello, se incorpora un análisis de IA Explicable (XAI) en el caso de la semana 12, al tratarse de punto intermedio del curso ofreciendo un equilibrio adecuado entre escasez y acumulación de información. No obstante, los resultados de otras semanas de la Z-effect pueden consultarse semana a semana en la carpeta reports/clustering (Apéndice I).

La matriz Z-effect recoge las 30 variables más discriminativas de cada perfil. Sus valores representan efectos estandarizados respecto a la media global, facilitando la comparación estructural entre perfiles.

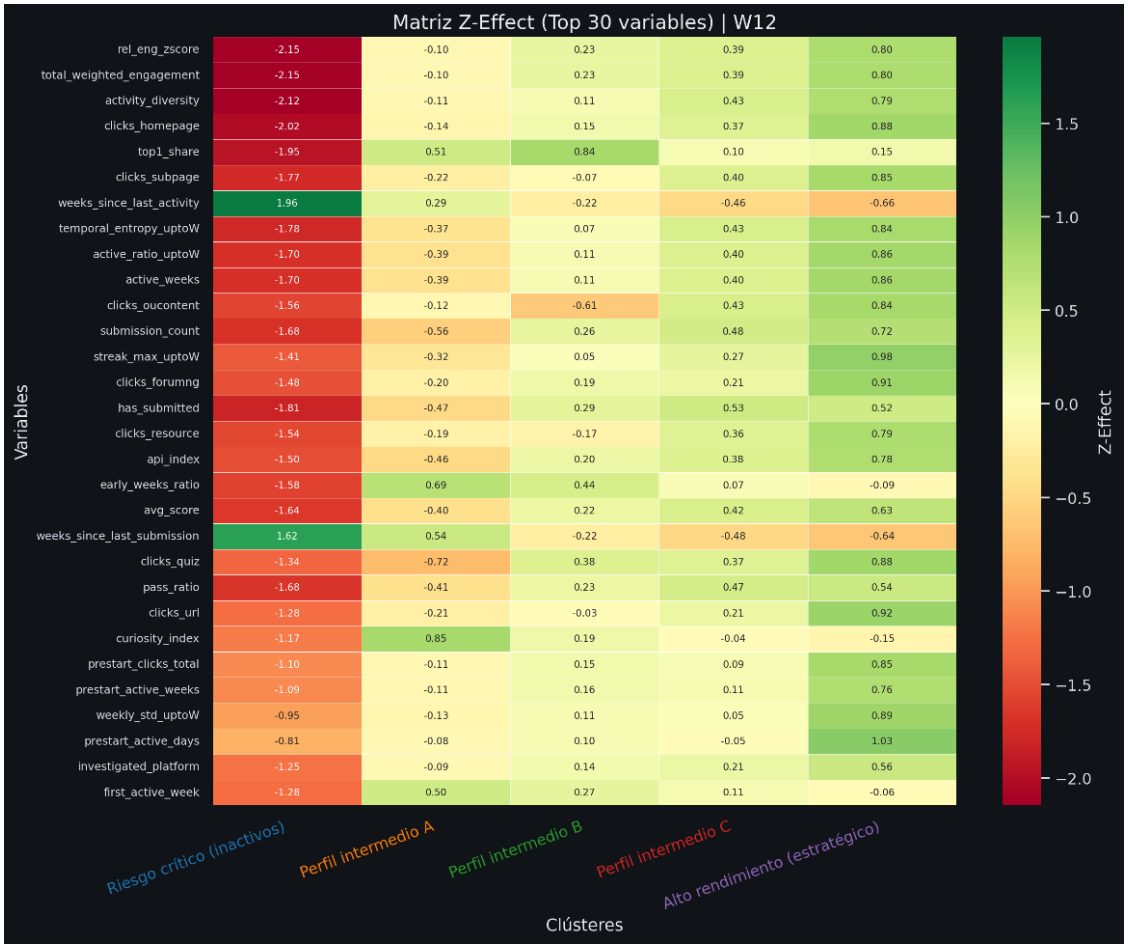


*Ilustración 25 Matriz Z-Effect de las 30 variables más discriminativas por clúster (W12)*

El análisis de la matriz Z-Effect confirma que los clústeres no son categorías aisladas, sino que cada grupo tiene comportamientos diferentes. Esta diferenciación permite caracterizar los siguientes perfiles y definir intervenciones adaptativas:

- Riesgo crítico (inactivos): son estudiantes que apenas están usando la plataforma, participan poco o nada, entregan poco y muestran señales claras de desconexión. No solo tienen baja actividad, sino también una relación muy débil con el curso en general.

- Perfil intermedio A: parece un grupo de estudiantes que empezó con cierta curiosidad o intención de seguir el curso, pero que no consiguió mantener una dinámica estable. Están presentes, pero de forma algo irregular, y todavía no convierten esa presencia en un buen seguimiento académico. Lo caracterizan estudiantes con interés inicial, pero con baja consolidación de hábitos.

- Perfil intermedio B: Este grupo se sitúa cerca de la media en muchas variables, aunque con algunos rasgos distintivos. cumplen con una parte importante de lo esperado y mantienen un seguimiento funcional del curso, aunque sin destacar demasiado. No son de alto rendimiento, pero tampoco parecen en riesgo fuerte.

- Perfil intermedio C: La idea que transmite este perfil es la de estudiantes que sí están metidos en el curso, trabajan con cierta regularidad, utilizan varios recursos de la plataforma y mantienen una participación razonablemente constante. Quizá no son tan fuertes o estratégicos como el grupo de alto rendimiento, pero claramente están en una trayectoria positiva. estudiantes implicados, activos y con buen seguimiento del curso.

- Perfil de alto rendimiento: Lo interesante no es solo que participan mucho, sino cómo participan. No parece un uso caótico ni puntual, sino bastante constante, amplio y sostenido en el tiempo. Además, tienen menor distancia desde la última actividad y entrega, lo que refuerza la idea de continuidad. Todo esto encaja con estudiantes que no solo están presentes, sino que saben organizarse, mantenerse activos y aprovechar bien la plataforma.

En definitiva, la IA explicativa permite transformar los resultados del clustering en perfiles comprensibles y útiles desde el punto de vista educativo. Gracias a la matriz Z-Effect, cada clúster puede interpretarse no solo como un grupo estadísticamente distinto, sino como una forma concreta de participación y seguimiento del curso. Esto refuerza la validez práctica del modelo y abre la puerta al diseño de intervenciones personalizadas, ajustadas al nivel de implicación, continuidad y riesgo de cada perfil.

## 6.5. IA Explicativa en el modelo secuencial Transformer.

En el caso del modelo Transformer, la explicabilidad se ha abordado desde dos perspectivas complementarias, con el objetivo de sintetizar los resultados obtenidos y comprender con mayor profundidad qué variables ejercen una mayor influencia sobre las predicciones del modelo.

### 6.5.1. Análisis SHAP sobre variables estáticas y acumulativas.

Los valores SHAP permiten analizar la contribución de las variables de entrada a la predicción del modelo, identificando cuáles tienen mayor influencia en la salida y, por tanto, en el proceso de decisión. En la tabla X se recogen las cinco variables con mayor peso para cada ventana temporal, calculadas sobre el bloque de variables estáticas y acumulativas, al tratarse del conjunto más directamente interpretable mediante esta técnica. Se ha optado por mostrar

únicamente este top 5 con el fin de sintetizar la información y facilitar la lectura de la memoria. No obstante, en el Apéndice I, dentro del apartado de reports, puede consultarse el top 10 completo de variables SHAP para cada una de las ventanas de tiempo analizadas.

| Semana | Top 1 | Top 2 | Top 3 | Top 4 | Top 5 |
|---|---|---|---|---|---|
| W01 | Estud (0.015580) | Creds (0.007592) | Preint (0.005351) | Socio (0.003796) | Subpag (0.003301) |
| W03 | Estud (0.018752) | ÍndAPI (0.015530) | Creds (0.014545) | NotaM (0.010728) | SemEnt (0.007634) |
| W05 | ÍndAPI (0.013670) | NotaM (0.012227) | ClkUlt (0.011571) | Estud (0.005792) | Creds (0.004718) |
| W08 | ÍndAPI (0.036146) | NotaM (0.018757) | Tardío (0.011016) | RachaF (0.010098) | Estud (0.009045) |
| W10 | ÍndAPI (0.021378) | Estud (0.010728) | PendNot (0.010700) | NotaM (0.008833) | ClkUlt (0.008774) |
| W12 | ÍndAPI (0.035676) | SemEnt (0.025034) | SemAct (0.016749) | NotaM (0.015289) | Tardío (0.010016) |
| W15 | ÍndAPI (0.075095) | SemEnt (0.032775) | SemAct (0.027131) | ClkUlt (0.021395) | NotaM (0.015969) |
| W18 | SemEnt (0.047697) | ÍndAPI (0.037040) | SemAct (0.036562) | ActRat (0.018949) | ClkUlt (0.014755) |
| W20 | ÍndAPI (0.044299) | SemEnt (0.042046) | SemAct (0.025162) | ClkUlt (0.020616) | Aprob (0.009877) |
| W24 | SemEnt (0.062626) | SemAct (0.043182) | ÍndAPI (0.032692) | PendNot (0.023724) | SemUso (0.016736) |
| W28 | SemEnt (0.061195) | SemAct (0.055217) | ÍndAPI (0.041550) | ClkUlt (0.022780) | PendNot (0.009814) |

*Tabla 3 Características estaticas y acumuladas más discriminantes*

Se puede apreciar que, en la semana 1, el modelo discrimina principalmente a partir del nivel educativo previo (Estud), los créditos matriculados (Cred), la intensidad de interacción con la plataforma antes del inicio del curso (preInt) y el nivel socioeconómico asociado al código postal (socio). Este patrón resulta coherente, ya que en una fase tan temprana el modelo todavía no dispone de suficiente historial de actividad académica y, por

tanto, se apoya en mayor medida en variables de contexto sociodemográfico y en las señales de interacción previas al comienzo del curso.

En la semana 3, el Transformer sigue otorgando un peso importante al nivel educativo previo (Estud) y a los créditos matriculados (Creds), pero empiezan a ganar relevancias variables vinculadas al rendimiento y al seguimiento académico, como el índice combinado de actividad y rendimiento (ÍndAPI), la nota media (NotaM) y las semanas transcurridas desde la última entrega (SemEnt). Esto sugiere que, a medida que aparecen las primeras evidencias de desempeño, el modelo comienza a complementar las variables de contexto con señales académicas tempranas.

Entre las semanas 5 y 12 se observa una transición clara en el criterio de discriminación del Transformer. En un primer momento, el modelo se apoya sobre todo en variables de rendimiento inicial y compromiso reciente, como el ÍndAPI, la NotaM y la actividad de la última semana (ClkUlt), aunque todavía conserva cierta influencia de variables de contexto como Estud y Creds. Sin embargo, conforme avanza el curso, ganan pesos variables relacionadas con el seguimiento continuado del estudiante, como las semanas desde la última entrega (SemEnt), las semanas desde la última actividad (SemAct), el retraso en las entregas (Tardío) o la tendencia de las calificaciones (PendNot). En conjunto, esto sugiere que el modelo pasa de apoyarse en señales tempranas de rendimiento y contexto a fundamentar sus predicciones en indicadores de continuidad, regularidad y posible desconexión académica.

A partir de la semana 15, esta tendencia se intensifica y el modelo pasa a apoyarse de forma muy marcada en variables que combinan rendimiento acumulado y continuidad reciente. El ÍndAPI, las semanas desde la última

entrega (SemEnt) y desde la última actividad (SemAct) se consolidan como los principales factores explicativos, acompañados por la actividad reciente (ClkUlt), la proporción de semanas activas (ActRat), la proporción de aprobados (Aprob), la pendiente de notas (PendNot) o el número de semanas activas (SemUso). En conjunto, esto indica que, en la fase intermedia y final del curso, el Transformer discrimina sobre todo a partir de señales de persistencia, regularidad y posible desconexión sostenida, más que de variables de contexto inicial.

### 6.5.2. Valores SHAP secuenciales.

En este apartado nos centraremos más en las 5 características principales en cada ventana de tiempo,

| Semana | Top_1 | Top_2 | Top_3 | Top_4 | Top_5 |
|---|---|---|---|---|---|
| W01 | Inicio 0.0010 | Sub-pag 0.0009 | Foro 0.0008 | Prueba 0.0002 | Tema 0.0001 |
| W03 | Prueba 0.0025 | Tema 0.0012 | Sub-pag 0.0010 | TestExt 0.0010 | Inicio 0.0003 |
| W05 | Sub-pag 0.0006 | TestExt 0.0004 | Prueba 0.0004 | Enlace 0.0003 | Equipo 0.0002 |
| W08 | Prueba 0.0003 | Repaso 0.0002 | Panel 0.0002 | TestExt 0.0001 | Equipo 0.0001 |
| W10 | Panel 0.0002 | Equipo 0.0001 | Prueba 0.0001 | Recurso 0.0001 | Sondeo 0.0001 |
| W12 | Prueba 0.0003 | Enlace 0.0003 | TestExt 0.0003 | Recurso 0.0001 | Clase 0.0001 |
| W15 | Web 0.0003 | TestExt 0.0002 | Inicio 0.0001 | Sondeo 0.0000 | Foro 0.0000 |
| W18 | Inicio 0.0002 | Hoja 0.0002 | Foro 0.0001 | Tema 0.0001 | Recurso 0.0001 |
| W20 | Hoj-Com 0.0002 | Recurso 0.0001 | TestExt 0.0001 | Sub-pag 0.0001 | Inicio 0.0001 |
| W24 | Enlace 0.0001 | Inicio 0.0001 | Datos 0.0001 | Web 0.0001 | Panel 0.0001 |
| W28 | Hoj-Com 0.0003 | Prueba 0.0002 | Datos 0.0002 | Tema 0.0001 | Carpeta 0.0001 |

### 6.5.3. Mapas de atención.

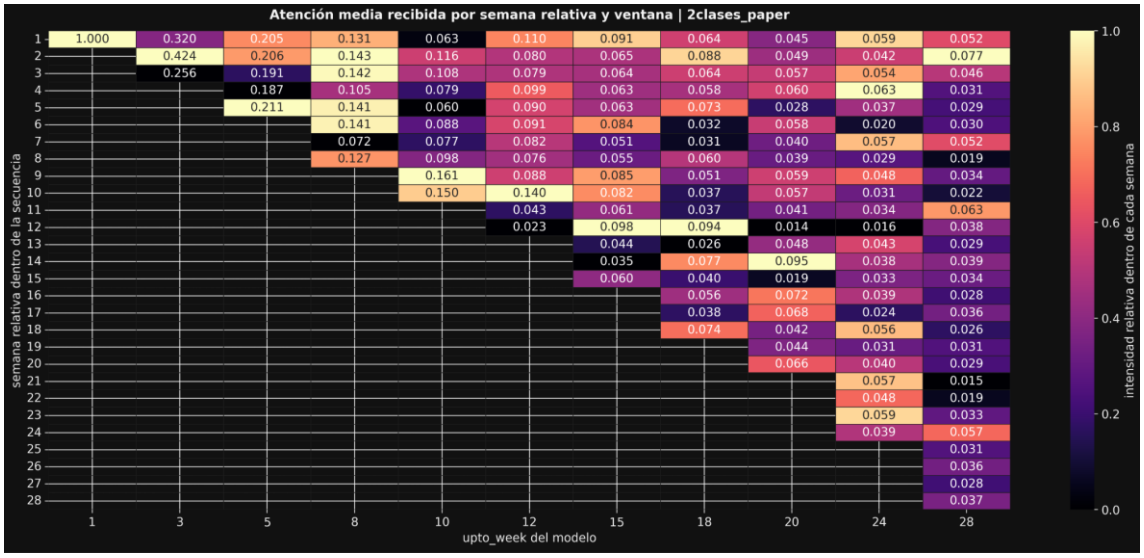

# 7. Conclusiones.

En el apartado 5.5.5 se confirma y ratifica que añadir características de custering mejoro las métricas, hay que subrayar que es el caso particular de este problema, con esta estructura de datos y que para sacar conclusiones mas generales habría que probar con diferentes datasets y siguiendo estrategias similares por lo que la premisa de que hacer clustering previo mejora los resultados de manera general, sería muy arriesgado.

Desde una perspectiva aplicada, estos resultados sugieren líneas de intervención diferenciadas. El perfil de Riesgo crítico requiere acciones tempranas centradas en reactivación y seguimiento de continuidad, priorizando la reducción de periodos de inactividad prolongada. Los perfiles intermedios podrían beneficiarse de estrategias de acompañamiento que fomenten regularidad y consolidación evaluativa, evitando la transición hacia abandono. En cambio, el perfil de Alto rendimiento puede ser objeto de estrategias de enriquecimiento o mentoría, aprovechando su comportamiento estratégico y proactivo. De este modo, la interpretación explicativa del clustering no solo valida el modelo estadísticamente, sino que proporciona una base operativa para intervenciones educativas adaptativas.

## 7.1. Conclusiones para trabajar en proyectos reales de IA

- Se puede considera iluso que en una primera iteración hagamos un pre-procesado e ingeniería de caracteristicas perfecto que no nos haga volver hacia atrás. Más bien, todo lo contrario, hay que estar continuamente
- Es muy importante antes de hacer finetuning o transformar la arquitectura no guiarse únicamente por la intuición sino inmediatamente tener graficas y visualizaciones que nos permitan tomar decisiones más informadas.
- Más features no significa más calidad de resultados.
- Importancia de contextualizar datos.

# 8. Referencias

Al-Tameemi, G., Xue, J., Ali, I. H., & Ajit, S. (2024). A Hybrid Machine Learning Approach for Predicting Student Performance Using Multi-class Educational Datasets. *Procedia Computer Science, 238*, 888-895. doi:10.1016/j.procs.2024.06.108

El Ghali, M., Atouf, I., El Guemmat, K., Broumi, S., & Talea, M. (2025). ENHANCING E-LEARNING THROUGH STRATEGIC STUDENT SEGMENTATION: INSIGHTS FROM THE OULAD DATABASE . *Theoretical and Applied Information Technology, 103*(4), 1290-1299.

Firat, M. (2025). Comparative Analysis of Random Forest vs XGBoost Machine Learning Algorithms for Predicting ODL Student Success.

Gamage, S. H., Ayres, J. R., & Behrend, M. B. (Enero de 2022). A systematic review on trends in using Moodle for teaching and learning. *International Journal of STEM Education, 9*(9), 1-24. doi:https://doi.org/10.1186/s40594-021-00323-x

Gašević, D., Dawson, S., Rogers, T., & Gasevic, D. (2016). Learning analytics should not ignore instructional conditions. *Computers & Education*, 53-66.

Hasan, R., Palaniappan, S., Mahmood, S., Abbas, A., Sarker, K. U., & Sattar, M. U. (2020). Predicting Student Performance in Higher Educational Institutions Using Video Learning Analytics and Data Mining Techniques. *Applied Sciences, 10*(11), 3894. doi:10.3390/app10113894

Instituto Andaluz Interuniversitario en Ciencia de Datos e Inteligencia Computacional (DASCI). (s.f.). *DASCI.* Recuperado el 2026, de Minería

de datos educativos y análisis del aprendizaje: https://dasci.es/linea-investigacion/mineria-de-datos-educativos/

Junejo, N. U., Nawaz, M. W., Huang, Q., Dong, X., Wang, C., & Zheng, G. (2024). Accurate Multi-Category Student Performance Forecasting at Early Stages of Online Education Using Neural Networks. *arXiv preprint arXiv:2412.05938*, 1-27.

Khosravi, H., Buckingham Shum, S., Chen, G., Conati, C., Tsai, Y.-S., Kay, J., . . . Gašević, D. (2022). Computers and Education: Artificial Intelligence. *Computers and Education: Artificial Intelligence, 3*. Obtenido de https://doi.org/10.1016/j.caeai.2022.100074

Kusumawardani, S. S., & Alfarozi, S. A. (2023). Transformer Encoder Model for Sequential Prediction of Student Performance Based on Their Log Activities. *11*, págs. 18960-18971. IEEE. doi:10.1109/ACCESS.2023.3246122

Kuzilek, J., Hlosta, M., & Zdrahal, Z. (2017). Open University Learning Analytics dataset. *Scientific Data, 4*(170171).

Luo, H., Yu, Q., Xie, S., Wu, H., & Xu, K. (2024). GLU-Transformer for Predicting Withdrawal in VLE. *ICBAR '24: Proceedings of the 2024 4th International Conference on Big Data, Artificial Intelligence and Risk Management*, 835-840.

Papadogiannis, I., Wallace, M., & Karountzou, G. (2024). Educational Data Mining: A Foundational Overview. *Encyclopedia, 4*(4), 1644-1664.

Parlamento Europeo y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 por el que se establecen normas armonizadas sobre*

*inteligencia artificial (Ley de Inteligencia Artificial).* Bruselas. Obtenido de http://data.europa.eu/eli/reg/2024/1689/o

Sejnowski, T. J. (2020). The unreasonable effectiveness of deep learning in artificial intelligence. *Proc Natl Acad Sci U S A.* doi:10.1073/pnas.1907373117

Soepriyanto, Y., Nugroho, R. P., Nahri, M. H., Kesuma, D. W., & Setiasih, M. (2025). From logs to insights: A comprehensive framework for data-driven learning insights. *Jurnal Inovasi Teknologi Pendidikan, 12*(1), 40-49. doi:https://doi.org/10.21831/jitp.v12i1.77432

Torkhani, W., & Rezgui, K. (2025). OULAD MOOC Student Performance. (págs. 228-241). Atlantis Press. doi:10.2991/978-94-6463-654-3_18

# Apéndice I: Repositorio de Código y Reproducibilidad

Acceso al Repositorio Todo el código fuente, los notebooks de exploración (EDA) y los scripts de entrenamiento desarrollados para este Trabajo de Fin de Máster se encuentran alojados en un repositorio público de GitHub para garantizar la transparencia y reproducibilidad de los resultados.

| Atributo | Detalle |
|---|---|
| URL del Repositorio | https://github.com/MichaeLaudrup/Artificial_Intelligence_Msc/tree/main/TFM_education_ai_analytics` |
| Plataforma | GitHub |
| Lenguaje Principal | Python 3.12+ |
| Librerías Clave | Pandas, TensorFlow/Keras, Scikit-learn, SHAP |
| Licencia | MIT License (Código abierto) |
| Código QR para acceso directo | |

*Tabla 4 Ficha técnica de repositorio código fuente*

Estructura del Repositorio: El proyecto sigue una arquitectura modular inspirada en los estándares de la industria para ciencia de datos, lo que garantiza la separación de preocupaciones y facilita la reproducibilidad del experimento. A continuación, se detalla la jerarquía de directorios y la función de sus componentes principales:

root/: Directorio principal del proyecto que contiene los archivos de configuración y automatización.

- data/: Almacén central de datos, organizado por etapas de madurez:
    - raw/: Copias inalteradas de los datos originales (OULAD).
    - interim/: Datos transformados durante los procesos de limpieza intermedios.
    - processed/: Conjuntos de datos finales, anonimizados y listos para alimentar los modelos de IA.
    - external/: Datos complementarios de terceras fuentes utilizados en el análisis.
- notebooks/: Cuadernos interactivos (.ipynb) utilizados para la experimentación inicial.
    - data_exploration.ipynb: Documenta el análisis exploratorio (EDA), visualizaciones estadísticas y la validación de hipótesis iniciales.
- educational_ai_analytics/: Núcleo del código fuente desarrollado como un paquete modular de Python:
    - dataset.py: Funciones para la extracción y carga eficiente de los datos.
    - features.py: Implementación de la ingeniería de variables y transformadores.
    - modeling/: Scripts dedicados al entrenamiento, validación cruzada y serialización de los modelos.
    - plots.py: Motor de visualización personalizado para la generación de gráficas presentadas en este trabajo.
    - config.py: Definición de hiperparámetros, rutas del sistema y constantes globales.
- models/: Directorio destinado a almacenar los pesos de los modelos entrenados y los archivos de metadatos asociados.
- reports/: Resultados del análisis.
    - figures/: Gráficas y representaciones visuales exportadas en alta resolución para la memoria del TFM.

- references/: Documentación técnica, diccionarios de datos y manuales de las fuentes de información utilizadas.
- Makefile: Archivo de automatización que permite replicar todo el flujo de trabajo (limpieza, procesado y entrenamiento) mediante comandos simples (ej. make data, make models).
- pyproject.toml: Especificación de la versión de Python (3.12+) y lista exhaustiva de dependencias necesarias para recrear el entorno virtual.

# Apendice II: Tablas de características

## Características del autoencoder.

| Característica | Descripción |
|---|---|
| imd_band | Índice de Privación Múltiple (proxy de nivel socioeconómico), mapeado numéricamente. |
| age_band | Rango de edad del estudiante categorizado numéricamente. |
| highest_education | Nivel educativo previo del estudiante (escala ordinal). |
| num_of_prev_attempts | Número de veces que el alumno ha intentado superar el módulo previamente. |
| studied_credits | Carga académica total (créditos) matriculada simultáneamente. |
| region_encoded | Región geográfica de residencia del estudiante, codificada numéricamente. |
| investigated_platform | Variable binaria (0/1) que indica si el alumno accedió a la plataforma antes de iniciar el curso. |
| prestart_clicks_total | Volumen total de clics registrados antes del inicio oficial. |
| prestart_active_days | Número total de días distintos en los que hubo actividad previa al inicio. |
| prestart_active_weeks | Número total de semanas distintas con actividad antes de arrancar. |
| prestart_earliest_day | Día exacto (en negativo) en el que el alumno realizó su primera conexión histórica. |
| prestart_anticipation | Valor absoluto del primer día de conexión (días de antelación al inicio). |
| prestart_intensity | Ratio de intensidad pre-curso (clics totales divididos entre días activos). |
| clicks_[tipo_actividad] | 18 variables independientes que acumulan los clics normalizados por cada tipo de recurso (ej. clicks_forumng, clicks_homepage, clicks_quiz, clicks_oucontent, etc.). |
| total_weighted_enga | Compromiso acumulado aplicando ponderaciones |

| | |
|---|---|
| gement | (ej. +peso a cuestionarios, -peso a lecturas). |
| rel_eng_zscore | Proxy del compromiso (total_weighted_engagement), normalizado (Z-score) por curso. |
| last_week_clicks_weighted | Volumen de compromiso ponderado generado específicamente en la última semana evaluada. |
| momentum_2w | Aceleración del esfuerzo: compara la actividad de las últimas 2 semanas frente a las 2 previas. |
| effort_slope | Pendiente de regresión lineal sobre los clics semanales (tendencia general de esfuerzo). |
| temporal_entropy_uptoW | Entropía de la distribución temporal (valores altos = constancia; bajos = picos esporádicos). |
| weekly_std_uptoW | Desviación estándar de los clics semanales (mide la volatilidad en el ritmo de estudio). |
| activity_diversity | Cantidad de tipos de recursos diferentes (foros, wikis, pdfs) que el estudiante ha utilizado. |
| curiosity_index | Ratio entre la diversidad de recursos utilizados y el número de semanas activas. |
| top1_share | Proporción de la actividad total concentrada exclusivamente en el recurso más utilizado. |
| prestart_ratio | Proporción de los clics totales del curso que ocurrieron antes del Día 0. |
| early_weeks_ratio | Proporción del esfuerzo total concentrado en las primeras 4 semanas del curso. |
| first_active_week | Semana exacta en la que el estudiante registró su primera interacción post-inicio. |
| active_weeks | Número total de semanas en las que el alumno interactuó con el VLE. |
| active_ratio_uptoW | Porcentaje de semanas con actividad respecto al total de semanas transcurridas. |
| streak_max_uptoW | Racha máxima histórica de semanas consecutivas con actividad. |
| streak_final | Racha de semanas consecutivas de actividad que llega viva hasta la semana actual (W-1). |
| weeks_since_last_activity | Semanas de inactividad transcurridas desde el último clic (indicador clave de riesgo). |
| has_submitted | Variable binaria (0/1) que indica si el alumno ha |

| | |
|---|---|
| | entregado al menos una actividad. |
| submission_count | Número total de evaluaciones entregadas hasta la fecha de corte. |
| avg_score | Calificación media obtenida en las tareas entregadas (0-100). |
| score_std | Desviación estándar de las calificaciones (estabilidad del rendimiento del alumno). |
| pass_ratio | Porcentaje de entregas que superan la nota mínima de aprobación (40%). |
| late_ratio | Porcentaje de entregas realizadas fuera de la fecha límite oficial. |
| score_slope | Tendencia de las calificaciones (pendiente ascendente o descendente en el rendimiento). |
| weeks_since_last_submission | Semanas transcurridas desde que el alumno realizó su última entrega evaluable. |
| api_index | Índice compuesto que premia conjuntamente buenas notas y volumen de entregas. |

*Tabla 5 Características de entrada al autoencoder*

## Características del Transformer.

| Característica | Descripción |
|---|---|
| dataplus | Uso de actividades tipo base de datos, donde se registran, consultan o exploran entradas de información. |
| dualpane | Uso de recursos interactivos con visualización en dos paneles simultáneos. |
| externalquiz | Interacción con cuestionarios o pruebas alojadas fuera de Moodle. |
| folder | Accesos a carpetas que agrupan varios archivos descargables relacionados. |
| forumng | Participación en foros de discusión del curso. |
| glossary | Uso del glosario de conceptos y definiciones del módulo. |
| homepage | Accesos a la página principal del curso. |
| htmlactivity | Uso de contenidos o actividades embebidas en HTML. |
| oucollaborate | Interacción con herramientas colaborativas o de trabajo en equipo. |
| oucontent | Consulta del contenido didáctico estructurado del curso. |
| ouelluminate | Participación en clases virtuales, tutorías o sesiones síncronas. |
| ouwiki | Uso de actividades tipo wiki para construcción colaborativa |

| | |
|---|---|
| | de contenido. |
| page | Consulta de páginas informativas simples dentro del entorno Moodle. |
| questionnaire | Respuesta a encuestas, formularios o sondeos. |
| quiz | Realización de cuestionarios o pruebas integradas en la plataforma. |
| resource | Acceso a recursos estáticos descargables como PDFs o documentos. |
| subpage | Navegación por subpáginas internas que estructuran el contenido del curso. |
| url | Apertura de enlaces externos compartidos en la plataforma. |
| sharedsubpage | Acceso a subpáginas compartidas entre secciones o cursos. |
| repeatactivity | Uso de actividades de práctica o autoevaluación repetibles. |

*Tabla 6 Características secuenciales del transformer*

| Característica | Descripción |
|---|---|
| imd_band | Índice de Privación Múltiple, utilizado como proxy del nivel socioeconómico del estudiante y transformado a escala numérica. |
| age_band | Rango de edad del estudiante, codificado ordinalmente. |
| highest_education | Nivel educativo previo alcanzado antes de cursar el módulo. |
| num_of_prev_attempts | Número de intentos previos en el mismo módulo. |
| studied_credits | Carga académica total matriculada simultáneamente. |
| region_encoded | Región geográfica de residencia del estudiante, codificada numéricamente. |

| | |
|---|---|
| investigated_platform | Variable binaria que indica si el alumno accedió a la plataforma antes del inicio oficial. |
| prestart_clicks_total | Total de clics registrados antes del comienzo del curso. |
| prestart_active_days | Número de días distintos con actividad previa al inicio. |
| prestart_active_weeks | Número de semanas distintas con actividad antes del arranque oficial. |
| prestart_earliest_day | Primer día de actividad histórica, medido en días negativos respecto al inicio del curso. |
| prestart_anticipation | Antelación absoluta, en días, con la que el alumno accedió por primera vez. |
| prestart_intensity | Intensidad de actividad previa al curso, calculada como clics totales divididos entre días activos. |

*Tabla 7 Características estáticas iniciales*

| Característica | Descripción |
|---|---|
| clicks_dataplus | Clics acumulados en actividades tipo base de datos. |
| clicks_dualpane | Clics acumulados en recursos dualpane. |
| clicks_externalquiz | Clics acumulados en cuestionarios externos. |
| clicks_folder | Clics acumulados en carpetas de materiales. |
| clicks_forumng | Clics acumulados en foros. |

| | |
|---|---|
| clicks_glossary | Clics acumulados en glosarios. |
| clicks_homepage | Clics acumulados en la página principal del curso. |
| clicks_htmlactivity | Clics acumulados en actividades HTML. |
| clicks_oucollaborate | Clics acumulados en herramientas colaborativas. |
| clicks_oucontent | Clics acumulados en contenido docente estructurado. |
| clicks_ouelluminate | Clics acumulados en clases o tutorías virtuales. |
| clicks_ouwiki | Clics acumulados en wikis. |
| clicks_page | Clics acumulados en páginas internas. |
| clicks_questionnaire | Clics acumulados en cuestionarios o encuestas. |
| clicks_quiz | Clics acumulados en quizzes de Moodle. |
| clicks_resource | Clics acumulados en recursos descargables. |
| clicks_subpage | Clics acumulados en subpáginas. |
| clicks_url | Clics acumulados en enlaces externos. |

*Tabla 8 Características de actividades acumuladas hasta la semana W*

| Característica | Descripción |
|---|---|
| weeks_since_last_activity | Semanas transcurridas desde el último clic registrado. Indicador fuerte de inactividad reciente. |
| streak_final | Racha de semanas consecutivas con actividad que sigue viva hasta la semana actual. |
| active_weeks | Número total de semanas con actividad. |
| active_ratio_uptoW | Proporción de semanas activas respecto al total de semanas observadas hasta W. |
| first_active_week | Semana exacta en que se produjo la primera |

| | |
|---|---|
| | interacción tras el inicio. |
| streak_max_uptoW | Máxima racha histórica de semanas consecutivas con actividad. |
| weekly_std_uptoW | Desviación estándar de la actividad semanal, usada como medida de volatilidad. |
| temporal_entropy_uptoW | Entropía temporal de la distribución del esfuerzo; alta si la actividad está repartida, baja si se concentra en picos. |
| effort_slope | Tendencia global del esfuerzo semanal medida como pendiente lineal. |
| momentum_2w | Cambio reciente del esfuerzo comparando las 2 últimas semanas frente a las 2 anteriores. |
| top1_share | Proporción del esfuerzo total concentrado en el recurso más usado. |
| activity_diversity | Número de tipos de recursos distintos utilizados por el alumno. |
| curiosity_index | Relación entre diversidad de recursos y semanas activas. |
| last_week_clicks_weighted | Compromiso ponderado generado específicamente en la última semana observada. |
| early_weeks_ratio | Proporción del esfuerzo total concentrado en las primeras cuatro semanas. |
| prestart_ratio | Proporción del esfuerzo total que ocurrió antes del Día 0. |
| W_fraction_completed | Fracción de progreso temporal completada respecto a la ventana actual W. |

*Tabla 9 Comportamiento general*

| Característica | Descripción |
|---|---|
| has_submitted | Variable binaria que indica si el estudiante ha entregado al menos una actividad. |
| submission_count | Número total de entregas realizadas hasta la fecha de corte. |
| avg_score | Nota media obtenida en las entregas realizadas. |
| score_std | Desviación estándar de las notas; mide estabilidad del rendimiento. |
| pass_ratio | Proporción de entregas que superan el umbral de aprobado. |
| late_ratio | Proporción de entregas realizadas fuera de |

| | |
|---|---|
| | plazo. |
| score_slope | Tendencia temporal de las calificaciones del alumno. |
| weeks_since_last_submission | Semanas transcurridas desde la última entrega evaluable. |
| api_index | Índice compuesto que combina número de entregas y rendimiento obtenido. |

*Tabla 10 Evaluaciones y rendimiento académico*

# Apéndice III: Métricas de entrenamiento en Transformers.

## Resultados en clasificación binaria (Existo vs Fracaso)

| Métrica | W=5 | W=10 | W=15 | W=20 | W=25 |
|---|---|---|---|---|---|
| Accuracy | 0.7403 | 0.8000 | 0.8334 | 0.8750 | 0.8946 |
| ROC (One-vs-Rest) | 0.8083 | 0.8721 | 0.9085 | 0.9396 | 0.9578 |
| Balanced Accuracy | 0.7345 | 0.7938 | 0.8294 | 0.8704 | 0.8915 |
| F1-Score. | 0.7008 | 0.7669 | 0.8116 | 0.8568 | 0.8818 |
| Loss. | 0.0481 | 0.0409 | 0.0348 | 0.0289 | 0.0240 |
| Precision. | 0.7481 | 0.8321 | 0.8508 | 0.9112 | 0.9171 |
| Recall. | 0.6591 | 0.7111 | 0.7759 | 0.8086 | 0.8491 |

*Tabla 11 Métricas de entrenamiento del transformer clase binaria (Exito vs Fracaso)*

## Resultados clasificación trinaria (éxito, suspenso, abandono)

| Métrica | 5 | 10 | 15 | 20 | 25 |
|---|---|---|---|---|---|
| Accuracy | 0.6381 | 0.6853 | 0.7098 | 0.7317 | 0.7631 |
| AUC (OvR) | 0.7446 | 0.8045 | 0.8375 | 0.8698 | 0.8924 |
| Balanced Accuracy | 0.5330 | 0.6088 | 0.6416 | 0.6778 | 0.6978 |
| F1 Macro | 0.5379 | 0.6156 | 0.6450 | 0.6743 | 0.6930 |
| F1 Weighted | 0.6133 | 0.6794 | 0.7065 | 0.7338 | 0.7562 |
| Precision Macro | 0.5629 | 0.6260 | 0.6493 | 0.6715 | 0.6932 |

| | | | | | |
|---|---|---|---|---|---|
| Recall Macro | 0.5330 | 0.6088 | 0.6416 | 0.6778 | 0.6978 |
| Precision Weighted | 0.6077 | 0.6768 | 0.7040 | 0.7364 | 0.7529 |
| Recall Weighted | 0.6381 | 0.6853 | 0.7098 | 0.7317 | 0.7631 |
| Loss | 0.0946 | 0.0795 | 0.0708 | 0.0603 | 0.0506 |

Clasificación cuaternaria (Éxito, abandono, suspenso, sobresaliente).

| Métrica | 5 | 15 | 20 | 25 |
|---|---|---|---|---|
| Accuracy | 0.4674 | 0.5666 | 0.6212 | 0.6444 |
| Balanced Accuracy | 0.4509 | 0.5762 | 0.6116 | 0.6403 |
| AUC (OvR) | 0.7318 | 0.8191 | 0.8506 | 0.8707 |
| F1 Macro | 0.4464 | 0.5510 | 0.5913 | 0.6217 |
| F1 Weighted | 0.4750 | 0.5736 | 0.6215 | 0.6508 |
| Precision Macro | 0.4683 | 0.5452 | 0.5810 | 0.6140 |
| Recall Macro | 0.4509 | 0.5762 | 0.6116 | 0.6403 |
| Precision Weighted | 0.5075 | 0.5929 | 0.6275 | 0.6649 |
| Recall Weighted | 0.4674 | 0.5666 | 0.6212 | 0.6444 |
| Top-2 Accuracy | 0.7773 | 0.8916 | 0.9318 | 0.9509 |
| Loss | 0.1113 | 0.0833 | 0.0664 | 0.0561 |

*Tabla 12 Resultados del transformer en clasificación binaria.*

# Apéndice IV: Descripción de campos de SHAP

## Campos SHAP secuenciales

| Nombre Original (OULAD) | Abreviatura | Descripción de la actividad en la plataforma |
|---|---|---|
| homepage | Inicio | La página principal del curso. Es el punto de entrada al entorno virtual (VLE). |
| oucontent | Tema | Contenido de estudio estructurado propio de la Open University (suele incluir lecturas y material didáctico del módulo). |
| forumng | Foro | Foros de discusión donde los estudiantes interactúan, debaten y resuelven dudas con sus compañeros y tutores. |
| quiz | Prueba | Cuestionarios y pruebas de evaluación estándar integradas directamente en la plataforma Moodle. |
| subpage | Sub-pag | Subpáginas utilizadas para organizar y estructurar el contenido dentro de la página principal del curso. |
| resource | Recurso | Archivos estáticos subidos por los docentes para que los alumnos los descarguen (como PDFs, documentos de texto, etc.). |
| url | Enlace | Enlaces (links) compartidos en la plataforma que dirigen a los estudiantes a páginas web o recursos externos. |
| ouelluminate | Clase | Sesiones de tutoría en vivo, conferencias o clases virtuales (utilizando la herramienta Elluminate/Blackboard Collaborate). |
| externalquiz | TestExt | Pruebas o cuestionarios evaluativos que están alojados en plataformas o proveedores externos a Moodle. |
| questionnaire | Sondeo | Encuestas o formularios utilizados para recopilar *feedback*, opiniones o autoevaluaciones de los alumnos. |
| oucollaborate | Equipo | Herramientas específicas de Moodle diseñadas para el trabajo colaborativo o proyectos grupales. |
| ouwiki | Wiki | Actividad colaborativa donde los estudiantes pueden crear, editar y organizar páginas de |

| | | |
|---|---|---|
| | | contenido de forma conjunta. |
| page | Hoja | Páginas web simples dentro de Moodle utilizadas para mostrar información estática (textos, imágenes o instrucciones). |
| dualpane | Panel | Un recurso de visualización interactivo que muestra contenido dividido en dos paneles simultáneos. |
| htmlactivity | Web | Contenido dinámico o actividades interactivas incrustadas en la plataforma y desarrolladas en formato HTML. |
| sharedsubpage | Hoj-Com | Subpáginas de contenido que están compartidas entre diferentes secciones o incluso diferentes cursos. |
| repeatactivity | Repaso | Actividades de autoevaluación o ejercicios de práctica diseñados para que el alumno los repita varias veces. |
| dataplus | Datos | Una actividad tipo base de datos donde los estudiantes o profesores pueden recopilar, ver y buscar entradas de información. |
| glossary | Léxico | Un glosario de conceptos y definiciones del curso. Puede ser creado por el docente o construido colaborativamente. |
| folder | Carpeta | Un directorio que agrupa varios archivos descargables relacionados entre sí para mantener el curso ordenado. |

*Tabla 13 Descripción de campos SHAP para variables secuenciales*

## Campos SHAP estáticos y acumulativos.

| Nombre original | Abreviatura | Significado |
|---|---|---|
| highest_education | Estud | Nivel educativo previo |
| studied_credits | Creds | Créditos matriculados |
| prestart_intensity | Preint | Intensidad previa al inicio |
| imd_band | Socio | Nivel socioeconómico |
| clicks_subpage | Subpag | Clics en subpáginas |
| top1_share | Top1 | Peso del recurso más usado |
| prestart_active_days | Predías | Días activos antes del inicio |
| prestart_clicks_total | Preclk | Clics antes del inicio |
| api_index | ÍndAPI | Índice combinado de |

| | | |
|---|---|---|
| | | entregas y rendimiento |
| avg_score | NotaM | Nota media |
| weeks_since_last_submission | SemEnt | Semanas desde la última entrega |
| score_slope | PendNot | Pendiente de notas |
| last_week_clicks_weighted | ClkUlt | Clics ponderados de la última semana |
| clicks_dualpane | Panel | Clics en recurso dualpane |
| streak_final | RachaF | Racha activa final |
| late_ratio | Tardío | Proporción de entregas tardías |
| early_weeks_ratio | Tempr | Peso de las primeras semanas |
| weeks_since_last_activity | SemAct | Semanas desde la última actividad |
| active_ratio_uptoW | ActRat | Proporción de semanas activas |
| submission_count | NúmEnt | Número de entregas |
| curiosity_index | Curios | Índice de curiosidad/diversidad |
| pass_ratio | Aprob | Proporción de aprobados |
| active_weeks | SemUso | Número de semanas activas |

*Tabla 14 Explicación variables SHAP estaticas y acumulativas.*

# Anexos I: Estructura y diccionario de datos OULAD.

- Dimensión del estudiante (students_processed.csv): Esta tabla maestra consolida la información estática y demográfica, actuando como el perfil base de cada alumno matriculado.

| Campo | Descripción |
|---|---|
| code_module | Identificador del curso (ej. AAA, BBB). |
| code_presentation | Semestre en el que se imparte (ej. 2013J, 2014B). |
| id_student | ID único anonimizado del estudiante. |
| gender | Género del estudiante (M/F). |
| region | Región geográfica de residencia en UK. |
| highest_education | Nivel educativo previo (ej. A Level, HE Qualification). |
| imd_band | Índice de Privación Múltiple (nivel socioeconómico; % más bajo indica mayor pobreza). |
| age_band | Rango de edad (0-35, 35-55, 55<=). |
| num_of_prev_attempts | Número de veces que el estudiante ha intentado este módulo previamente. |
| studied_credits | Carga total de créditos que el estudiante cursa actualmente. |
| disability | Indicador de discapacidad declarada (Y/N). |
| final_result | Variable Objetivo: Pass, Distinction, Fail, Withdrawn. |
| date_registration | Día relativo al inicio del curso en que se formalizó la matrícula. |
| date_unregistration | Día relativo en que se produjo la baja (si aplica). |

*Tabla 15 Descripción de datos de estudiantes*

- Dimensión de Rendimiento (assessments_processed.csv): Contiene los resultados cuantitativos de los hitos evaluativos, permitiendo trazar la evolución académica del alumno.

| Campo | Descripción |
|---|---|
| id_assessment | ID único de la prueba específica. |
| id_student | ID del estudiante. |
| date_submitted | Día relativo al inicio del curso en que se realizó la entrega. |
| is_banked | Indicador de si la nota ha sido convalidada de una presentación anterior. |
| score | Calificación obtenida (escala 0-100). |
| assessment_type | Tipología: TMA (Corrección por tutor), CMA (Corrección automática), Exam. |
| date | Fecha límite oficial de entrega (*Deadline*). |
| weight | Ponderación de la evaluación en la nota final del curso. |

*Tabla 16 Descripción de entrega de actividades*

- Dimensión de Comportamiento (interactions_processed.csv): Representa el log de actividad diario en el Entorno Virtual de Aprendizaje (VLE). Dada su granularidad, constituye la fuente principal para el modelado secuencial.

| Campo | Descripción |
|---|---|
| code_module | Identificador del curso (ej. AAA, BBB). |
| code_presentation | Semestre en el que se imparte (ej. 2013J, 2014B). |
| id_student | ID único anonimizado del estudiante. |
| gender | Género del estudiante (M/F). |
| region | Región geográfica de residencia en UK. |
| highest_education | Nivel educativo previo (ej. A Level, HE Qualification). |
| imd_band | Índice de Privación Múltiple (nivel socioeconómico; % más bajo indica mayor pobreza). |
| age_band | Rango de edad (0-35, 35-55, 55<=). |
| num_of_prev_attempts | Número de veces que el estudiante ha intentado este módulo previamente. |
| studied_credits | Carga total de créditos que el estudiante cursa actualmente. |

| | |
|---|---|
| disability | Indicador de discapacidad declarada (Y/N). |
| final_result | Variable Objetivo: Pass, Distinction, Fail, Withdrawn. |
| date_registration | Día relativo al inicio del curso en que se formalizó la matrícula. |
| date_unregistration | Día relativo en que se produjo la baja (si aplica). |

*Tabla 17 Descripción datos de interacción de estudiantes*