

Usted vende el trabajo como arquitectura híbrida, pero luego admite que el clustering no mejoró de forma consistente al Transformer; entonces, ¿en qué sentido exacto su contribución es híbrida y no simplemente un sistema con dos módulos paralelos?

El planteamiento inicial sí era híbrido en sentido estricto, porque contemplaba que las salidas del clustering enriquecieran directamente al Transformer. Sin embargo, la evidencia experimental mostró que esa integración no aportaba mejoras consistentes, y por honestidad metodológica la formulación final del trabajo evolucionó hacia dos módulos complementarios: uno no supervisado, orientado a segmentar e interpretar perfiles, y otro supervisado, orientado a la predicción temprana.

Además, a nivel de interpretación pedagógica y de acciones a tomar se puede considerar que se deben tomar decisiones basándose en los dos modelos y no solo en uno. Cabe señalar que a veces el clustering metía a un alumno en riesgo de abandono crítico y el transformer predecía que aprobaba, la clase real era abandono, por lo que surge una oportunidad de trabajar en sistemas híbridos (usar otro modelo) que cocatene la salida de los dos. Se intentó con modelos simples, pero al final aprendían a imitar al transformer y no se enriquecían del clustering, pero sigue habiendo margen de exploración con más modelos.

Si la integración fuerte entre el módulo no supervisado y el supervisado no aportó mejora suficiente, ¿por qué no replanteó antes el objetivo del TFM para evitar una promesa metodológica más ambiciosa de lo que finalmente demuestran los resultados?

Si que se replanteó el objetivo, es más en la memoria se plasma toda la evolución desde la idea inicial hacia un sistema más complementario, sobretodo se mantuvo el objetivo general, pero se cambió la manera de abordarlo, y esto no se ocultó, por honestidad académica y por plasmar de manera práctica como un sistema inicialmente propuesto puede evolucionar hacia otro enfoque sin perder valor o utilidad.

¿Cómo justifica científicamente mantener el bloque de clustering en el núcleo argumental del trabajo si su utilidad final fue sobre todo interpretativa y no predictiva?

No diría que su utilidad fuera solo interpretativa, ya desde las primeras semanas se aprecia que el clustering es capaz de separar de manera muy limpia un grupo de alto de riesgo dándonos una orientación inicial de a que perfil pertenece el estudiante. Además, tal y como se formula en la pregunta, creo que ha aportado un gran valor añadido de interpretabilidad.

Usted concluye que el Autoencoder fue más adecuado que PCA para segmentar perfiles, pero también reconoce que esa superioridad no debe generalizarse; entonces, ¿hasta dónde llega realmente su hallazgo?

Demostramos que para este caso y este contexto una AE es mejor que un PCA, y tal vez este resultado invite a explorar lo mismo para estudios que solo han usado PCA y han perdido la oportunidad de capturar el comportamiento no lineal.

¿Qué evidencia tiene de que los clústeres obtenidos son estables y no artefactos de la ventana temporal, la semilla aleatoria o la parametrización del GMM?

probé distintas semillas, distintos samples y ajuste del GMM, y los perfiles no cambiaban de forma arbitraria. Además, no me apoyé en una sola visualización, sino en AIC, BIC y métricas de calidad del clustering, comprobando también que en validación y test los grupos seguían teniendo sentido.

Y, además, el Autoencoder se entrenó de forma común para todas las ventanas, lo que ayuda a que la representación latente sea más consistente y no dependa por completo de una única partición temporal

Usted usa SHAP, mapas de atención y Z-Effect; ¿cómo evita presentar correlaciones explicadas como si fueran causalidad pedagógica?

XAI aquí se usa para interpretación y generación de hipótesis de intervención, no para inferencia causal. Quiero explicar esto poniendo un ejemplo, lógicamente si los valores SHAP nos dicen que los alumnos que intervinieron en el foro y que más visitaron la página de inicio tenían menos riesgo de abandonar, no quiere decir, que porque forcemos a los alumnos a participar a los foros o ir a la página de inicio al comienzo del curso, esto signifique menos riesgo de abandono, no es causal, pero si nos puede dar una pista orientativa de que acciones tomar, que es animar a los alumnos a participar en los foros para que se comuniquen con los estudiantes más aventajados (los que suelen tener menos riesgo sin intervención) y se genere sinergia positiva entre ambos grupos, tal y como se defiende en el TFM son acciones orientativas, no extremadamente vinculantes.

¿Por qué deberíamos aceptar que un mapa de atención del Transformer constituye una explicación fiable y no solo una visualización sugerente?

Con las limitaciones y el contexto de este TFM, creo que la conclusión que tuvimos con los mapas de atención es bastante pobre, me atrevería a afirmar que la conclusión a la que se llegó es que “no se puede llegar a una conclusión” porque no sigue un patrón uniforme, repetible y coherente. Resultaron en datos un poco caóticos y esto se plasmó en la memoria.

Sin embargo, es verdad que el sistema está preparado para sistemas mucho más largo, es decir, si en vez de analizar 6 meses, analizamos un curso entero o una matrícula de carrera de universidad completa, tenemos secuencias mucho más largas y en ese caso los mapas de atención pueden jugar un papel diferente y aportar más información

Usted afirma que evita data leakage usando ventanas acumulativas hasta la semana W , pero también incorpora variables acumulativas de notas, entregas e interacción; ¿qué garantías exactas ofrece de que ninguna transformación haya usado información futura indirectamente?

Para empezar todas las normalizaciones, estandarizaciones e imputaciones de información se hicieron siempre sobre el conjunto de entrenamiento y nunca sobre el conjunto de test y validación. Así evitamos que información privilegiada de estos conjuntos llegue en la fase de training.

Más a nivel software todo log del alumno en la plataforma tiene una etiqueta de la semana en la que hizo el movimiento, nunca se coge información de una semana posterior al momento en el que se intenta agrupar o predecir si el alumno abandonara

Además, también se normalizo toda la información con respecto del curso, evitándose incluso que los modelos de IA discriminaran por curso mas que por perfil conductual o por otros datos del alumno.

En la pérdida dual del autoencoder, ¿cómo decidió el peso relativo entre reconstrucción y clustering y cómo sabe que no estaba forzando artificialmente una separación aparente?

A ver, al final el objetivo no era reconstruir, el objetivo era reducir numero de características, eliminar ruido y outliers y en ese nuevo espacio latente forzar de manera muy ligera el agrupamiento.

En primera instancia no se hizo un autoencoder con tendencia al clustering, sino que simplemente se comprimio al espacio latente y luego se hizo clustering sobre ese espacio latente, demanera natural con Kmeans y la técnica del codo o viendo la silloute tanto para PCA como AE salían entre 4-5 clústeres. también en GMM se uso AIC y BIC siempre buscando el equilibrio entre buenas métricas cuantitativas y buena interpretabilidad.

Si el sistema real tuviera que desplegarse, ¿cómo gestionaría operativamente 11 modelos distintos, 11 umbrales y 11 lógicas de intervención?

Primero reuniría a un grupo de docentes para que decidan cuales son los cortes temporales más importantes en los que consideran intervenir, tras esto, a nivel software automatizaría el despliegue de los modelos en diferentes servicios de la nube, en general son modelos ligeros y los tiempos de inferencia para un alumno son de segundos. Debo recordar que el sistema es muy flexible y que poniendo un array tipo: [1,2,3,4,5,6] estamos diciendo las ventanas de corte

Al final habría que crear reglas de negocio que puentearán los resultados de los modelos con datos que se deben alimentar a gráficas, dashboards, etc.

¿No cree que entrenar 11 Transformers independientes complica mucho la reproducibilidad y el mantenimiento frente a un único modelo condicionado por tiempo?

Al final todo esta automatizado, usted va a un archivo de hiperparámetros pone las ventanas temporales que quiere calcular y lo configura y ahí le genera el numero de modelos que desee, ya en varios artículos científicos también se apreció que se seguía esta estrategia.

Si imaginamos que cogemos solo un transformer ¿Qué fecha elegiríamos? El día cero ¿hay suficiente información? En el punto intermedio del curso, tal vez sea el momento más apropiado, o tal vez al final, claramente, la respuesta es no, porque sería tarde para abandonar, entonces buscamos flexibilidad y más capacidad para poder abordar el problema desde diferentes momentos temporales.

OTRAS PREGUNTAS

Preguntas duras

- ¿Por qué eligió GMM como modelo final de clustering y no otro método orientado explícitamente a densidades arbitrarias o estabilidad estructural?
- Usted menciona AIC y BIC para elegir el número de componentes, pero también dice que no siempre escoge el valor mínimo sino el equilibrio con interpretabilidad; ¿no introduce eso un componente subjetivo difícil de reproducir?
- Si el clustering se apoya en embeddings generados por un autoencoder entrenado con una pérdida dual, ¿cómo separa el efecto del embedding del efecto del algoritmo de agrupamiento?
- **¿Qué aporta realmente el autoencoder frente a una buena ingeniería manual de variables seguida de PCA o incluso de UMAP para visualización?** Velocidad, reducción de ruido y outliers. Al final también se ha hecho sobreingeniería porque el objetivo del TFM es demostrar conocimientos.

Metodología y validez

- ¿Puede explicar con precisión qué transformaciones se ajustaron solo con train y cuáles se aplicaron después a validación y test sin recalibrar?
- ¿La imputación de nulos, la normalización Z-score y las codificaciones se aprendieron exclusivamente sobre entrenamiento en todas las fases del pipeline, también en clustering y autoencoder?
- Usted dice que los datos diarios tenían demasiado ruido y por eso agrega semanalmente; ¿cómo sabe que esa agregación no elimina señales tempranas relevantes que sí podrían detectar abandono inminente?

- ¿Por qué eligió exactamente las ventanas 1, 3, 5, 8, 10, 12, 15, 18, 20, 25 y 28 y no una secuencia regular o un criterio optimizado formalmente?
- ¿No cree que entrenar 11 Transformers independientes complica mucho la reproducibilidad y el mantenimiento frente a un único modelo condicionado por tiempo?
- ¿Hasta qué punto sus buenos resultados al final del curso son metodológicamente interesantes, si en semanas tardías la predicción del abandono es bastante más fácil porque el fenómeno ya casi ha ocurrido?
- ¿Cuál es, desde el punto de vista práctico, la semana mínima en la que usted considera que el sistema empieza a ser útil para intervención real, y por qué?
- Si el AUC en semana 5 ronda 0.83, ¿qué trade-off concreto entre recall y precisión considera aceptable para no saturar al profesorado con falsos positivos?

Diseño del problema

- Usted descartó la clasificación multiclase porque los resultados fueron pobres y centró el objetivo en abandono; ¿esto responde a una decisión metodológica sólida o a una simplificación motivada por rendimiento?
- ¿No está sesgando la definición del problema al excluir fail, cuando pedagógicamente suspenso y abandono pueden ser dos formas distintas de riesgo académico igualmente relevantes?
- Si el tribunal le dijera que ha convertido un problema más rico en uno más fácil para obtener mejores métricas, ¿cómo respondería?
- ¿Por qué agrupa aprobado y sobresaliente como “éxito” en una sola clase, cuando probablemente representan trayectorias de interacción distintas?
- En un contexto de alerta temprana, ¿por qué prioriza abandono sobre bajo rendimiento si muchas intervenciones docentes buscan precisamente evitar suspensos antes de que ocurran?

Modelos y resultados

- Su Transformer mejora claramente al añadir variables estáticas y acumulativas además de la secuencia; entonces, ¿qué parte del mérito corresponde realmente al Transformer y qué parte a la ingeniería de características tabulares?
- ¿Comparó el Transformer final contra una baseline fuerte de gradient boosting con exactamente las mismas variables estáticas y acumulativas?
- Si no hizo esa comparación de forma equivalente, ¿cómo puede afirmar que la arquitectura secuencial era necesaria y no simplemente suficiente?

- Usted muestra una mejora progresiva de accuracy, balanced accuracy, precision, recall y AUC con el avance del curso; ¿cómo separa mejora real del modelo de la simple disponibilidad de más evidencia acumulada?
- ¿Tiene intervalos de confianza, validación cruzada o análisis de varianza por semillas para sostener que las diferencias entre configuraciones son robustas?
- En un dataset desbalanceado, ¿por qué debería el tribunal fijarse en accuracy en lugar de priorizar balanced accuracy, recall de abandono o AUC-PR?
- Si su sistema está orientado a intervención temprana, ¿no sería más honesto optimizar explícitamente recall de la clase abandono, aunque baje la precisión?
- Usted afirma que el modelo fue configurado para priorizar la detección de abandonos; ¿qué cambio concreto hizo para ello, ajuste de umbral, weighting de clases, focal loss, o solo interpretación posterior?
- ¿Qué pasa si el modelo funciona bien en OULAD porque aprende regularidades propias de ese ecosistema institucional y no patrones generales del comportamiento académico?
- Si los cursos difieren mucho en intensidad de interacción, ¿cómo demuestra que el modelo no está aprendiendo en parte la asignatura o el diseño del curso en vez del riesgo del estudiante?

XAI y utilidad real

- Si SHAP dice que una variable pesa mucho, ¿qué garantiza que la recomendación pedagógica derivada sea válida y no una sobreinterpretación?
- ¿Cómo validó que las recomendaciones docentes propuestas a partir de los clústeres y del Transformer sean realmente accionables y no solo plausibles?
- Usted habla varias veces de “potencialmente útil” para el profesorado; ¿no revela eso que la utilidad pedagógica aún no está demostrada empíricamente?
- ¿Qué diferencia hay en su trabajo entre explicabilidad técnica del modelo e interpretabilidad pedagógica verdaderamente operativa?
- Si un docente le preguntara “¿qué hago mañana con este alumno concreto?”, ¿su sistema ofrece una respuesta suficientemente específica o solo una orientación general?

Ética y sesgos

- Usted excluye género y discapacidad por prudencia ética, pero mantiene variables como riqueza del código postal, nivel educativo previo e intentos anteriores; ¿por qué esas variables le parecen aceptables y no otras?
- ¿No existe el riesgo de que variables socioeconómicas agregadas introduzcan sesgos estructurales, aunque no sean atributos sensibles directos?

- Si el modelo identifica como de alto riesgo a estudiantes de contextos más desfavorecidos, ¿cómo evita que la herramienta refuerce profecías autocumplidas o intervenciones estigmatizantes?
- ¿Ha evaluado fairness entre subgrupos, aunque no use ciertas variables en el modelo final?
- ¿No cree que eliminar variables sensibles puede ocultar desigualdades en vez de mitigarlas, al impedir auditar el sesgo del sistema?

Defensa conceptual

- ¿Cuál diría que es la aportación científica principal de su TFM en una sola frase: mejora predictiva, diseño metodológico, integración de módulos o traducibilidad pedagógica?
- Si el tribunal le obliga a renunciar a una de estas piezas —Autoencoder, clustering, Transformer o XAI—, ¿cuál quitaría y por qué?
- ¿Qué parte del trabajo considera más sólida empíricamente y qué parte más débil pero prometedora?
- ¿Cuál es la crítica más seria que usted mismo haría a su trabajo antes de que la hagamos nosotros?
- Si tuviera dos meses más, ¿qué experimento haría para convencer a un tribunal escéptico de que el trabajo aporta algo más que una combinación razonable de técnicas conocidas?

Las que más te pueden caer

Estas son, para mí, las **más probables** en una defensa dura:

- “Usted lo llama híbrido, pero realmente no mejora predictivamente al integrar clustering y Transformer; explíquelo.”
- “¿Por qué excluyó fail y se quedó con un problema binario más favorable?”
- “¿Cómo garantiza ausencia total de data leakage en variables acumulativas, imputación y normalización?”
- “¿Qué aporta el Transformer frente a una baseline tabular fuerte con las mismas variables?”
- “¿En qué evidencia basa que sus explicaciones son pedagógicamente accionables y no solo interpretaciones plausibles?”
- “¿Hasta dónde puede generalizar resultados obtenidos solo con OULAD?”