




Análisis de información generada en plataformas educativas a partir de herramientas de inteligencia artificial.

Hacia la detección temprana e interpretable del riesgo académico

Trabajo de fin de Máster (TFM)
Michael Laudrup Luis González

DEFINICIÓN DEL PROBLEMA

- **LMS:** Sistema de gestión del aprendizaje.
- Cada interacción del estudiante deja un registro de interacción
- Estos registros no se aprovechan para intervenciones pedagógicas. Incluso cuando se usa IA, no se explican los resultados (Caja negra).



The screenshot displays the VIU LMS interface. The top navigation bar includes 'INICIO', 'CALENDARIO', 'SECRETARÍA', 'CRAI-BIBLIOTECA', 'HERRAMIENTAS E IA', 'TRAYECTORIA', 'SERVICIOS', and 'VIDA UNIVERSITARIA'. The main content area lists four courses:

- 01 MIAR** 50686-Python para la Inteligencia Artificial
CURSO: 1º | INICIO: 2025-05-05 | GRUPO: A
DOCENTES: IVÁN FUERTES TORRECILLA | FRANKLIN ALVAREZ CARDINALE
- 02 MIAR** 50687-Matemáticas para la Inteligencia Artificial
CURSO: 1º | INICIO: 2025-04-29 | GRUPO: A
DOCENTES: AMILCAR JESÚS PÉREZ ARGUINZONES | ZORAIDA MARGARITA SIVOLI BARRIOS | ELÍAS FERREIRO VILA
- 03 MIAR** 50688-Algoritmos de Optimización
CURSO: 1º | INICIO: 2025-05-09 | GRUPO: A
DOCENTES: JOSE MANUEL CAMACHO CAMACHO | JESÚS GIL RUIZ
- 04 MIAR** 50689-Razonamiento Aproximado
CURSO: 1º | INICIO: 2025-07-02 | GRUPO: A
DOCENTES: JOSE ANGEL OLIVAS VARELA | MARTA MARIA ARGUEDAS LAFUENTE

Below the course listings, a detailed view of the course '07MIAR_04_A_2025-26_Redes Neuronales y Deep Learning' is shown. The page includes a 'Bienvenida' (Welcome) message and a section titled 'Redes Neuronales y Deep Learning | 6 ECTS'. The welcome message states: 'Bienvenid@s a la asignatura Redes Neuronales y Deep Learning. Esta asignatura le proporciona al estudiante los fundamentos de redes neuronales e adquirirá las bases necesarias para poder aplicar estas técnicas a campos tan apasionante: del lenguaje natural, entre otros. Conceptos teóricos como el proceso de entrenamiento de diseño de arquitecturas de red neuronal convolucional y recurrente, o la generación de cor la práctica esta tecnología en infinidad de tareas y aplicaciones que envuelven a la inteliger se familiarizará con los frameworks más utilizados en el campo del deep learning. La asign y validación de modelos basados en redes neuronales bajo los paradigmas del aprendizaje. Consulta la guía didáctica de la asignatura para cualquier duda. 30 de septiembre de 2025 - 28 de noviembre de 2025. Profesor/a: Para dudas docentes relacionadas con la asignatura, contacta con el profesor/a: Haciendo uso de la herramienta de foros o mediante correo electrónico (jcamacho 4/8/2025'.

OBJETIVOS

GENERAL

Desarrollar un sistema de IA para detectar tempranamente el riesgo académico en LMS, segmentar perfiles de aprendizaje y generar explicaciones útiles para orientar intervenciones pedagógicas.


ESPECÍFICOS

- Procesamiento OULAD
- Aprendizaje supervisado para clasificación.
- Aprendizaje no supervisado para agrupaciones.
- Explicar por que se clasifica o se segmenta de una forma u otra
- Proponer acciones pedagógicas recomendadas según los resultados de los modelos

ESTADO DEL ARTE Y APORTACIÓN

Tras un estudio del estado del arte nos inspiramos en:

- **El Ghali et al. (2025):** referencia para segmentación de estudiantes.
- **Luo et al. (2024):** referencia para predicción temprana del abandono.
- **XAI en educación:** traducir resultados de clustering y clasificación en explicaciones para intervención docente.



APORTACIÓN TFM

integración experimental de segmentación, predicción y explicabilidad.

DATASET OULAD

- Base de datos real de la Open University de Londres
- 32.000 estudiantes.
- Más de 10 millones de interacciones.



DIMENSIÓN DEL ESTUDIANTE

Datos sociodemográficos del estudiante, nivel educativo, nivel de riqueza, fecha de registro, etc.



DIMENSIÓN DE ACTIVIDADES

Entregas de actividades y evaluaciones de estas mismas. Responde a las preguntas:

¿Que actividades entrego? ¿Cuándo?
¿que calificación obtuvo? ¿tiene
actividades sin entregar?



DIMENSIÓN DE COMPORTAMIENTO

Comportamiento del estudiante, responde a las preguntas:

¿A que hace clic el estudiante?
¿Cuántas veces? ¿En que semana?

Metodología empleada CRISP-DM Chapman y otros (2000)
CRISP-DM 1.0: Step-by-step data mining guide.




Comprensión del
negocio



Entender
datos



Preparación
de datos




Modelado





Evaluación
y XAI

ANÁLISIS EXPLORATORIO DE DATOS I






- Desbalanceo de clases.
- Alta representatividad de la clase abandono.
- Baja representatividad de la clase suspenso + hay una línea muy delgada entre estudiantes que abandonan y suspenden (problemas en clasificación trinaría o cuaternaria)

ANÁLISIS EXPLORATORIO DE DATOS II



ANÁLISIS EXPLORATORIO DE DATOS II






Comprensión del
negocio



Entender
datos



Preparación
de datos



Modelado



Evaluación
y XAI

INGENIERÍA DE CARACTERÍSTICAS I

Se usan tanto para clustering como para clasificación

Bloque	Variables	Finalidad
Datos sociodemográficos	imd_band, age_band, highest_education, region_encoded	Caracterizar el contexto personal del estudiante.
Historial académico	num_of_prev_attempts, studied_credits	Incorporar antecedentes académicos relevantes.
Información temporal inicial	date_registration	Capturar el momento de incorporación al curso.
Actividad previa al inicio	prestart_clicks_total, prestart_active_days, prestart_active_weeks, prestart_earliest_day	Medir interacción temprana con la plataforma.
Rasgos conductuales previos	investigated_platform, prestart_intensity, prestart_anticipation	Resumir exploración, intensidad y anticipación de uso.


INGENIERÍA DE CARACTERÍSTICAS II

Se usan tanto para clustering como para clasificación

Grupo	Ejemplos	Función
Interacción semanal	<code>clicks_*</code> por tipo de recurso	Modelar la secuencia temporal de uso del LMS.
Constancia	<code>streak, active_weeks, weeks_since_last_activit y</code>	Detectar continuidad o riesgo de desconexión.
Engagement	<code>weighted_engagement, momentum, effort_slope</code>	Medir intensidad y cambio reciente del esfuerzo.
Estilo de uso	<code>diversity, top1_share, entropy, curiosity</code>	Caracterizar el patrón de navegación.
Rendimiento	<code>avg_score, pass_ratio, late_ratio, score_slope</code>	Incorporar el historial académico hasta W.

INGENIERÍA DE CARACTERÍSTICAS III

- Concepto de ventana de tiempo.
- División en 3 subconjuntos: Train, evaluation, test.
- Datos sensibles o poco éticos se excluyen (AI Act)
- Normalización por curso.
- Para el transformer se añade adicionalmente comportamiento semana a semana.






Comprensión del
negocio



Entender
datos



Preparación
de datos




Modelado



Evaluación
y XAI

MODELADO I



MODELADO II

AUTOENCODER

- Se entrena un Autoencoder para reducir dimensionalidad.
- Sin perdida de Clustering se eligen 4-5 clústeres.
- Perdida de Clustering y perdida de reconstrucción.
- Todas las ventanas de tiempo.






Ilustración 1 Diagrama de Deep Clustering Network (DCN)

<https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10047866>

MODELADO III

RESULTADOS MODELADO



MODELADO IV

CLUSTERING

PCA + GMM




AE + GMM



Nombre métrica	Valor PCA	Valor AE	Objetivo	Ganador	Descripción
Silueta	0.0600	0.1870	↑ MAX	AE 🚀	Cohesión vs separación (distancias). Más alto = clusters más compactos y separados.
Calinski Harabasz	903.1506	6848.6567	↑ MAX	AE 🚀	Dispersión entre-clusters vs intra-cluster. Más alto = mejor partición.
Davies-Bouldin	3.9037	1.6067	↓ MIN	AE 🚀	Solape promedio entre clusters. Más bajo = clusters más separados.
BIC	1416998.4688	1086602.2358	↓ MIN	AE 🚀	Bayesian Information Criterion. Evalúa ajuste penalizando la complejidad. Más bajo = mejor.
AIC	1415038.2075	1084641.9745	↓ MIN	AE 🚀	Akaike Information Criterion. Similar a BIC pero con menor penalización por complejidad. Más bajo = mejor.
Log-Likelihood Promedio	-31.0413	-23.7910	↑ MAX	AE 🚀	Probabilidad logarítmica media de los datos según el GMM. Más alto = mejor ajuste.

MODELADO V

TRANSFORMER



```

* HIPERPARÁMETROS MODIFICADOS:
  * with_static: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss      : 0.0441 -> 0.0413 (Δ: -0.0028 | -6.38%) MEJORÓ
  - accuracy  : 0.7125 -> 0.7402 (Δ: +0.0277 | +3.88%) MEJORÓ
  - balanced_accuracy : 0.7058 -> 0.7239 (Δ: +0.0181 | +2.57%) MEJORÓ
  - auc_ovr   : 0.7625 -> 0.7863 (Δ: +0.0238 | +3.13%) MEJORÓ
  - precision : 0.5195 -> 0.5585 (Δ: +0.0390 | +7.51%) MEJORÓ
  - recall    : 0.6886 -> 0.6826 (Δ: -0.0061 | -0.88%) empeoró
  - f1_score  : 0.5922 -> 0.6143 (Δ: +0.0221 | +3.73%) MEJORÓ
  
```

```

* HIPERPARÁMETROS MODIFICADOS:
  * use_clustering_features: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss      : 0.0316 -> 0.0315 (Δ: -0.0000 | -0.11%) MEJORÓ
  - accuracy  : 0.7974 -> 0.7974 (Δ: +0.0000 | +0.00%) Estable
  - balanced_accuracy : 0.7649 -> 0.7592 (Δ: -0.0057 | -0.75%) empeoró
  - auc_ovr   : 0.8327 -> 0.8284 (Δ: -0.0043 | -0.52%) empeoró
  - precision : 0.6605 -> 0.6670 (Δ: +0.0066 | +0.99%) MEJORÓ
  - recall    : 0.6826 -> 0.6623 (Δ: -0.0203 | -2.97%) empeoró
  - f1_score  : 0.6713 -> 0.6646 (Δ: -0.0067 | -1.00%) empeoró
  
```

```

* COMPARATIVA: [29] 2026-03-10 19:09:53 vs [30] 2026-03-10 19:11:31
* HIPERPARÁMETROS MODIFICADOS:
  * accumulated_uptow: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss      : 0.0353 -> 0.0316 (Δ: -0.0038 | -10.63%) MEJORÓ
  - accuracy  : 0.7319 -> 0.7974 (Δ: +0.0655 | +8.95%) MEJORÓ
  - balanced_accuracy : 0.7182 -> 0.7649 (Δ: +0.0467 | +6.50%) MEJORÓ
  - auc_ovr   : 0.7794 -> 0.8327 (Δ: +0.0534 | +6.85%) MEJORÓ
  - precision : 0.5462 -> 0.6605 (Δ: +0.1143 | +20.92%) MEJORÓ
  - recall    : 0.6836 -> 0.6826 (Δ: -0.0010 | -0.15%) empeoró
  - f1_score  : 0.6072 -> 0.6713 (Δ: +0.0641 | +10.56%) MEJORÓ
  
```




Comprensión del
negocio



Entender
datos



Preparación
de datos



Modelado




**Evaluación
y XAI**


RESULTADOS I

AGRUPAMIENTO

SEMANA 1 DEL CURSO



SEMANA 5 DEL CURSO




RESULTADOS II

AUTOENCODER

SEMANA 12 DEL CURSO



SEMANA 24 DEL CURSO



RESULTADOS III

CLASIFICACIÓN BINARIA

week	n_sampl es	accuracy	Balanced accuracy	precision	recall	auc
1	2774	0.695025	0.634221	0.553603	0.396725	0.713280
3	3203	0.726506	0.719960	0.567568	0.654206	0.783230
5	3252	0.803813	0.761390	0.682875	0.655172	0.832960
8	3283	0.845263	0.807918	0.732932	0.732197	0.877149
10	3290	0.864134	0.840348	0.777555	0.777555	0.900789
12	3291	0.881191	0.844570	0.839866	0.751503	0.908812
15	3295	0.891958	0.871739	0.843424	0.808809	0.934743
18	3297	0.909918	0.897196	0.849112	0.861000	0.954141
20	3299	0.933010	0.920534	0.897566	0.885000	0.966172
24	3299	0.947560	0.948014	0.916503	0.933000	0.985396
28	3299	0.968172	0.962908	0.948949	0.948000	0.990856

GLU-Transformer for Predicting Withdrawal in VLE

Haoxin Luo
Shantou Polytechnic
Shantou, Guangdong, China
hxluo@stpt.edu.cn

Qianyu Yu*
Shantou Polytechnic
Shantou, Guangdong, China
qyyu@stpt.edu.cn

Shaohao Xie
Shantou Polytechnic
Shantou, Guangdong, China
shxie@stpt.edu.cn

Haohai Wu
Shantou Polytechnic
Shantou, Guangdong, China
hhwu@stpt.edu.cn

Kaibin Xu
Shantou Polytechnic
Shantou, Guangdong, China
kbxu@stpt.edu.cn

Abstract

Virtual learning is a new and effective mode of education, where predicting students' early departure in advance helps make a timely strategy to keep students. By analyzing the click behavior of students in the open-source Open University Learning Analytics dataset, we propose GLU-Transformer to predict the probability of students leaving early. Experiments show that the model proposed in this study has stable and good performance. By means of using the data on students' first 25 weeks of activity in OULA dataset for prediction, the model achieves 96.54% accuracy, 97.68% precision and 92.57% recall.


environment and make it better adapt to the individual needs of students is still challenging in the current education field. As a cutting-edge artificial intelligence technology, deep learning provides a new opportunity for the intelligent development of virtual learning environment [1, 2].

By simulating the operation mechanism of the human brain neural network, deep learning can automatically extract and learn complex features in the data, so as to achieve intelligent decision-making and prediction. In the virtual learning environment, deep learning can be applied to a lot of aspects, such as learning resource recommendation, learning path optimization, learning emotion

	Weeks	Accuracy (%)	Precision (%)	Recall (%)
GLU-Transformer	5	80.07	81.73	62.06
	10	85.65	86.67	74.15
	15	89.76	91.35	82.96
	20	93.26	95.02	88.24
	25	96.54	97.68	92.57

XAI (IA EXPLICABLE) I

CLUSTERING




Clúster	Acciones
Riesgo crítico (inactivos)	- Mensajes personalizados de reenganche - Alertas tempranas por inactividad - Tutorías breves de seguimiento
Perfil intermedio A	- Secuencias de tareas cortas y guiadas - Recordatorios periódicos - Retroalimentación frecuente
Perfil intermedio B	- Actividades de aplicación práctica - Integración de recursos del curso - Tareas de autoevaluación
Perfil intermedio C	- Tareas abiertas con mayor autonomía - Actividades con elección de itinerario - Dinámicas de coevaluación
Alto rendimiento	- Actividades optativas de profundización - Mentoría entre iguales - Tutoría o apoyo guiado a grupos intermedios o en riesgo

Necesidad de pedagogos

XAI (IA EXPLICABLE)

VARIABLES ESTÁTICAS




Ventana temporal	Acción principal (estáticas/acumulativas)
Semanas 1-8	Envío de un correo de seguimiento inicial con orientación sobre el arranque del curso, organización del trabajo y recursos de apoyo.
Semanas 10-20	Envío de una alerta personalizada al detectar retrasos en entregas, inactividad o empeoramiento del rendimiento, junto con una tutoría breve de seguimiento.
Semanas 21-28	Contacto individual urgente para reactivar la participación y priorizar tareas pendientes, con acompañamiento intensivo de cierre si es necesario.

XAI (IA EXPLICABLE)

VARIABLES SECUENCIALES

Ventana temporal	Acción complementaria (secuenciales)
Semanas 1-8	Envío de correo para animar a participar en los foros y tutoriales para conocer la página de inicio de la plataforma universitaria.
Semanas 10-20	Mensaje de seguimiento si se observa un patrón de uso irregular o fragmentado en actividades concretas del curso.
Semanas 21-28	Mensaje de reenganche centrado en tareas finales cuando la interacción en la plataforma sea residual o poco sostenida.



CONCLUSIONES Y LIMITACIONES

CONCLUSIONES

- El valor principal está en el ecosistema completo: segmentación, predicción secuencial e interpretabilidad.
- El Autoencoder obtiene representaciones útiles para clustering frente a PCA.
- El agrupamiento por clustering desde fases tempranas ya muestra resultados prometedores.
- XAI permite traducir señales técnicas en hipótesis de intervención pedagógica.

LIMITACIONES

- Posible sobreingeniería en ventanas cortas; arquitectura interesante para secuencias más largas y escalabilidad.
- Dependencia de OULAD
- Aprender a trabajar con resultados imperfectos.
- Elección de número de clústeres.
- Control de fuga de datos.
- Acciones pedagógicas recomendadas

LÍNEAS DE TRABAJO A FUTURO

- Validación externa: Testeo en otros LMS e instituciones.
- Mejora UX para docentes.
- Unión de salidas de Aprendizaje supervisado y no supervisado.
- Refinamiento de acciones pedagógicas con expertos en la materia
- Sistema de retroalimentación año tras año.



¿PREGUNTAS?

MUCHAS GRACIAS