


Análisis de información generada en plataformas educativas a partir de herramientas de inteligencia artificial.

Hacia la detección temprana e interpretable del riesgo académico

Trabajo de fin de Máster (TFM)
Michael Laudrup Luis González

DEFINICIÓN DEL PROBLEMA

- **LMS:** Sistema de gestión del aprendizaje.
- Cada interacción del estudiante deja un registro de interacción
- Estos registros no se aprovechan para intervenciones pedagógicas. Incluso cuando se usa IA, no se explican los resultados (Caja negra).



The screenshot displays the VIU LMS interface. The top navigation bar includes 'INICIO', 'CALENDARIO', 'SECRETARÍA', 'CRAI-BIBLIOTECA', 'HERRAMIENTAS E IA', 'TRAYECTORIA', 'SERVICIOS', and 'VIDA UNIVERSITARIA'. The main content area lists four courses:

- 01 MIAR** 50686-Python para la Inteligencia Artificial
CURSO: 1º | INICIO: 2025-05-05 | GRUPO: A
DOCENTES: IVÁN FUERTES TORRECILLA | FRANKLIN ALVAREZ CARDINALE
- 02 MIAR** 50687-Matemáticas para la Inteligencia Artificial
CURSO: 1º | INICIO: 2025-04-29 | GRUPO: A
DOCENTES: AMILCAR JESÚS PÉREZ ARGUINZONES | ZORAIDA MARGARITA SIVOLI BARRIOS | ELÍAS FERREIRO VILA
- 03 MIAR** 50688-Algoritmos de Optimización
CURSO: 1º | INICIO: 2025-05-09 | GRUPO: A
DOCENTES: JOSE MANUEL CAMACHO CAMACHO | JESÚS GIL RUIZ
- 04 MIAR** 50689-Razonamiento Aproximado
CURSO: 1º | INICIO: 2025-07-02 | GRUPO: A
DOCENTES: JOSE ANGEL OLIVAS VARELA | MARTA MARIA ARGUEDAS LAFUENTE

Below the course listings, a detailed view of the course '07MIAR_04_A_2025-26_Redes Neuronales y Deep Learning' is shown. The page includes a sidebar with navigation links: 'INFORMACIÓN GENERAL', 'ACTIVIDAD FORMATIVA', 'COMUNICACIÓN', and 'SERVICIOS'. The main content area displays the course title 'Redes Neuronales y Deep Learning | 6 ECTS' and a welcome message from the professor, Dr. José Manuel Camacho Camacho. The message states that the course provides the foundations of neural networks and deep learning, covering topics like natural language processing, convolutional and recurrent neural networks, and the generation of content. It also mentions that the course will familiarize students with the most used frameworks in the field of deep learning and the validation of models based on neural networks under the paradigms of learning.

OBJETIVOS

GENERAL

Desarrollar un sistema de IA para detectar tempranamente el riesgo académico en LMS, segmentar perfiles de aprendizaje y generar explicaciones útiles para orientar intervenciones pedagógicas.


ESPECÍFICOS

- Procesamiento OULAD
- Aprendizaje supervisado para clasificación.
- Aprendizaje no supervisado para agrupaciones.
- Explicar por que se clasifica o se segmenta de una forma u otra
- Proponer acciones pedagógicas recomendadas según los resultados de los modelos

ESTADO DEL ARTE Y APORTACIÓN

Tras un estudio del estado del arte nos inspiramos en:

- **El Ghali et al. (2025):** referencia para segmentación de estudiantes.
- **Luo et al. (2024):** referencia para predicción temprana del abandono.
- **XAI en educación:** traducir resultados de clustering y clasificación en explicaciones para intervención docente.



APORTACIÓN TFM

integración experimental de segmentación, predicción y explicabilidad.

ANÁLISIS EXPLORATORIO DE DATOS I

- Base de datos real de la Open University de Londres
- 32.000 estudiantes.
- Más de 10 millones de iteraciones.



DIMENSIÓN DEL ESTUDIANTE

Datos sociodemográficos del estudiante, nivel educativo, nivel de riqueza, fecha de registro, género.



DIMENSIÓN DE ACTIVIDADES

Entregas de actividades y evaluaciones de estas mismas. Responde a las preguntas:

¿Que actividades entrego? ¿Cuándo?
¿que calificación obtuvo? ¿tiene
actividades sin entregar?



DIMENSIÓN DE COMPORTAMIENTO

Comportamiento del estudiante, responde a las preguntas:

¿A que hace clic el estudiante?
¿Cuántas veces? ¿En que semana?




Comprensión del
negocio



Entender
datos



Preparación
de datos




Modelado





Evaluación
y XAI

ANÁLISIS EXPLORATORIO DE DATOS I






- Desbalanceo de clases.
- Alta representatividad de la clase abandono.
- Baja representatividad de la clase suspenso + hay una línea muy delgada entre estudiantes que abandonan y suspenden (problemas en clasificación trinaría o cuaternaria)

ANÁLISIS EXPLORATORIO DE DATOS II



Kusumawardani y Alfarozi (2023). Transformer Encoder Model for Sequential Prediction of Student Performance Based on Their Log Activities

ANÁLISIS EXPLORATORIO DE DATOS II






Comprensión del
negocio



Entender
datos



Preparación
de datos



Modelado



Evaluación
y XAI

INGENIERÍA DE CARACTERÍSTICAS I

Se usan tanto para clustering como para clasificación

Bloque	Variables	Finalidad
Datos sociodemográficos	imd_band, age_band, highest_education, region_encoded	Caracterizar el contexto personal del estudiante.
Historial académico	num_of_prev_attempts, studied_credits	Incorporar antecedentes académicos relevantes.
Información temporal inicial	date_registration	Capturar el momento de incorporación al curso.
Actividad previa al inicio	prestart_clicks_total, prestart_active_days, prestart_active_weeks, prestart_earliest_day	Medir interacción temprana con la plataforma.
Rasgos conductuales previos	investigated_platform, prestart_intensity, prestart_anticipation	Resumir exploración, intensidad y anticipación de uso.


INGENIERÍA DE CARACTERÍSTICAS II

Se usan tanto para clustering como para clasificación

Grupo	Ejemplos	Función
Interacción semanal	<code>clicks_*</code> por tipo de recurso	Modelar la secuencia temporal de uso del LMS.
Constancia	<code>streak, active_weeks, weeks_since_last_activity</code>	Detectar continuidad o riesgo de desconexión.
Engagement	<code>weighted_engagement, momentum, effort_slope</code>	Medir intensidad y cambio reciente del esfuerzo.
Estilo de uso	<code>diversity, top1_share, entropy, curiosity</code>	Caracterizar el patrón de navegación.
Rendimiento	<code>avg_score, pass_ratio, late_ratio, score_slope</code>	Incorporar el historial académico hasta W.

INGENIERÍA DE CARACTERÍSTICAS III

- Concepto de ventana de tiempo.
- División en 3 subconjuntos: Train, evaluation, test.
- Datos sensibles o poco éticos se excluyen (AI Act)
- Normalización por curso.
- Para el transformer se añade adicionalmente comportamiento semana a semana.






Comprensión del
negocio



Entender
datos



Preparación
de datos




Modelado



Evaluación
y XAI

MODELADO I



MODELADO II

- Se entrena un Autoencoder para reducir dimensionalidad.
- Perdida de Clustering y perdida de reconstrucción.
- Todas las ventanas de tiempo.






Ilustración 1 Diagrama de Deep Clustering Network (DCN)

<https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=10047866>

MODELADO III

AUTOENCODER



MODELADO IV

CLUSTERING

PCA + GMM



AE + GMM



Nombre métrica	Valor PCA	Valor AE	Objetivo	Ganador	Descripción
Silueta	0.0600	0.1870	↑ MAX	AE 🚀	Cohesión vs separación (distancias). Más alto = clusters más compactos y separados.
Calinski Harabasz	903.1506	6848.6567	↑ MAX	AE 🚀	Dispersión entre-clusters vs intra-cluster. Más alto = mejor partición.
Davies-Bouldin	3.9037	1.6067	↓ MIN	AE 🚀	Solape promedio entre clusters. Más bajo = clusters más separados.
BIC	1416998.4688	1086602.2358	↓ MIN	AE 🚀	Bayesian Information Criterion. Evalúa ajuste penalizando la complejidad. Más bajo = mejor.
AIC	1415038.2075	1084641.9745	↓ MIN	AE 🚀	Akaike Information Criterion. Similar a BIC pero con menor penalización por complejidad. Más bajo = mejor.
Log-Likelihood Promedio	-31.0413	-23.7910	↑ MAX	AE 🚀	Probabilidad logarítmica media de los datos según el GMM. Más alto = mejor ajuste.

Es para estos datos, con esta ingeniería de características, no es un resultado extrapolable a otros estudios

MODELADO V

CLUSTERING

- Inicialmente se entreno un autoencoder sin perdida de clustering que daba de manera natural 4-5 clústeres.
- Se busca equilibrio entre interpretabilidad y buenas métricas.
- Se obtienen en total 11 modelos GMM, cada uno especializado en agrupar en cada ventana de tiempo concreta.




Ilustración 10 Comparación BIC/AIC en PCA
 Autoría propia - Apéndice I - Notebook 4/





Ilustración 11 Evolución BIC/AIC con AE -
 Autoría propia - Apéndice I - Notebook 4

MODELADO VI

TRANSFORMER



```

* HIPERPARÁMETROS MODIFICADOS:
  * with_static: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss           : 0.0441 -> 0.0413 (Δ: -0.0028 | -6.38%) MEJORÓ
  - accuracy       : 0.7125 -> 0.7402 (Δ: +0.0277 | +3.88%) MEJORÓ
  - balanced_accuracy : 0.7058 -> 0.7239 (Δ: +0.0181 | +2.57%) MEJORÓ
  - auc_ovr        : 0.7625 -> 0.7863 (Δ: +0.0238 | +3.13%) MEJORÓ
  - precision      : 0.5195 -> 0.5585 (Δ: +0.0390 | +7.51%) MEJORÓ
  - recall         : 0.6886 -> 0.6826 (Δ: -0.0061 | -0.88%) empeoró
  - f1_score       : 0.5922 -> 0.6143 (Δ: +0.0221 | +3.73%) MEJORÓ
  
```

```

* HIPERPARÁMETROS MODIFICADOS:
  * use_clustering_features: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss           : 0.0316 -> 0.0315 (Δ: -0.0000 | -0.11%) MEJORÓ
  - accuracy       : 0.7974 -> 0.7974 (Δ: +0.0000 | +0.00%) Estable
  - balanced_accuracy : 0.7649 -> 0.7592 (Δ: -0.0057 | -0.75%) empeoró
  - auc_ovr        : 0.8327 -> 0.8284 (Δ: -0.0043 | -0.52%) empeoró
  - precision      : 0.6605 -> 0.6670 (Δ: +0.0066 | +0.99%) MEJORÓ
  - recall         : 0.6826 -> 0.6623 (Δ: -0.0203 | -2.97%) empeoró
  - f1_score       : 0.6713 -> 0.6646 (Δ: -0.0067 | -1.00%) empeoró
  
```


```

* COMPARATIVA: [29] 2026-03-10 19:09:53 vs [30] 2026-03-10 19:11:31
* HIPERPARÁMETROS MODIFICADOS:
  * accumulated_uptow: False --> True

* EVOLUCIÓN DE MÉTRICAS (Validación):
  - loss           : 0.0353 -> 0.0316 (Δ: -0.0038 | -10.63%) MEJORÓ
  - accuracy       : 0.7319 -> 0.7974 (Δ: +0.0655 | +8.95%) MEJORÓ
  - balanced_accuracy : 0.7182 -> 0.7649 (Δ: +0.0467 | +6.50%) MEJORÓ
  - auc_ovr        : 0.7794 -> 0.8327 (Δ: +0.0534 | +6.85%) MEJORÓ
  - precision      : 0.5462 -> 0.6605 (Δ: +0.1143 | +20.92%) MEJORÓ
  - recall         : 0.6836 -> 0.6826 (Δ: -0.0010 | -0.15%) empeoró
  - f1_score       : 0.6072 -> 0.6713 (Δ: +0.0641 | +10.56%) MEJORÓ
  
```




Comprensión del
negocio



Entender
datos



Preparación
de datos




Modelado



**Evaluación
y XAI**

RESULTADOS I


AUTOENCODER




RESULTADOS II

AGRUPAMIENTO

SEMANA 1 DEL CURSO



SEMANA 5 DEL CURSO




RESULTADOS III

AUTOENCODER

SEMANA 12 DEL CURSO




SEMANA 24 DEL CURSO



XAI (IA EXPLICABLE)

AUTOENCODER



Clúster	Acciones
Riesgo crítico (inactivos)	- Mensajes personalizados de reenganche - Alertas tempranas por inactividad - Tutorías breves de seguimiento
Perfil intermedio A	- Secuencias de tareas cortas y guiadas - Recordatorios periódicos - Retroalimentación frecuente
Perfil intermedio B	- Actividades de aplicación práctica - Integración de recursos del curso - Tareas de autoevaluación
Perfil intermedio C	- Tareas abiertas con mayor autonomía - Actividades con elección de itinerario - Dinámicas de coevaluación
Alto rendimiento	- Actividades optativas de profundización - Mentoría entre iguales - Tutoría o apoyo guiado a grupos intermedios o en riesgo

Necesidad de pedagogos

RESULTADOS

CLASIFICACIÓN BINARIA

week	n_sampl es	accuracy	Balanced accuracy	precision	recall	auc
1	2774	0.695025	0.634221	0.553603	0.396725	0.713280
3	3203	0.726506	0.719960	0.567568	0.654206	0.783230
5	3252	0.803813	0.761390	0.682875	0.655172	0.832960
8	3283	0.845263	0.807918	0.732932	0.732197	0.877149
10	3290	0.864134	0.840348	0.777555	0.777555	0.900789
12	3291	0.881191	0.844570	0.839866	0.751503	0.908812
15	3295	0.891958	0.871739	0.843424	0.808809	0.934743
18	3297	0.909918	0.897196	0.849112	0.861000	0.954141
20	3299	0.933010	0.920534	0.897566	0.885000	0.966172
24	3299	0.947560	0.948014	0.916503	0.933000	0.985396
28	3299	0.968172	0.962908	0.948949	0.948000	0.990856

GLU-Transformer for Predicting Withdrawal in VLE

Haoxin Luo
Shantou Polytechnic
Shantou, Guangdong, China
hxluo@stpt.edu.cn

Qianyu Yu*
Shantou Polytechnic
Shantou, Guangdong, China
qyyu@stpt.edu.cn

Shaohao Xie
Shantou Polytechnic
Shantou, Guangdong, China
shxie@stpt.edu.cn

Haohai Wu
Shantou Polytechnic
Shantou, Guangdong, China
hhwu@stpt.edu.cn

Kaibin Xu
Shantou Polytechnic
Shantou, Guangdong, China
kbxu@stpt.edu.cn

Abstract

Virtual learning is a new and effective mode of education, where predicting students' early departure in advance helps make a timely strategy to keep students. By analyzing the click behavior of students in the open-source Open University Learning Analytics dataset, we propose GLU-Transformer to predict the probability of students leaving early. Experiments show that the model proposed in this study has stable and good performance. By means of using the data on students' first 25 weeks of activity in OULA dataset for prediction, the model achieves 96.54% accuracy, 97.68% precision and 92.57%recall.

environment and make it better adapt to the individual needs of students is still challenging in the current education field. As a cutting-edge artificial intelligence technology, deep learning provides a new opportunity for the intelligent development of virtual learning environment [1, 2].

By simulating the operation mechanism of the human brain neural network, deep learning can automatically extract and learn complex features in the data, so as to achieve intelligent decision-making and prediction. In the virtual learning environment, deep learning can be applied to a lot of aspects, such as learning resource recommendation, learning path optimization, learning emotion

	Weeks	Accuracy (%)	Precision (%)	Recall (%)
GLU-Transformer	5	80.07	81.73	62.06
	10	85.65	86.67	74.15
	15	89.76	91.35	82.96
	20	93.26	95.02	88.24
	25	96.54	97.68	92.57

RESULTADOS

CLASIFICACIÓN BINARIA

Accurate Multi-Category Student Performance
Forecasting at Early Stages of Online Education
Using Neural Networks

Naveed Ur Rehman Junejo^{1,2}, Muhammad Wasim Nawaz³,
Qingsheng Huang^{4*}, Xiaoqing Dong¹, Chang Wang¹,

Table 5 Early prediction of students' performance in online learning while considering all features.

	5% course duration			10% course duration			20% course duration		
	Precision	Recall	F1-score	Precision	Recall	F1-score	Precision	Recall	F1-score
Distinction	0.76	0.74	0.75	0.79	0.83	0.81	0.87	0.92	0.89
Fail	0.70	0.63	0.66	0.76	0.74	0.75	0.85	0.84	0.85
Pass	0.82	0.85	0.84	0.87	0.87	0.87	0.93	0.92	0.92
Withdrawn	0.96	0.95	0.95	0.98	0.96	0.97	0.98	0.98	0.98
Accuracy	0.82			0.86			0.92		
Macro average	0.81	0.79	0.80	0.85	0.85	0.85	0.91	0.91	0.91
Weighted average	0.82	0.82	0.82	0.86	0.86	0.86	0.92	0.92	0.92

	40% course duration			60% course duration			100% course duration		
	Precision	Recall	F1-score	Precision	Recall	F1-score	Precision	Recall	F1-score
Distinction	0.94	0.97	0.95	0.95	0.97	0.96	0.97	0.99	0.98
Fail	0.94	0.94	0.94	0.92	0.95	0.93	0.97	0.96	0.96
Pass	0.98	0.97	0.97	0.98	0.97	0.97	0.99	0.99	0.99
Withdrawn	0.99	0.98	0.99	1.00	0.99	0.99	1.00	0.99	0.99
Accuracy	0.97			0.97			0.98		
Macro average	0.96	0.96	0.96	0.96	0.97	0.96	0.98	0.98	0.98
Weighted average	0.97	0.97	0.97	0.97	0.97	0.97	0.98	0.98	0.98

3.2.3 Feature engineering

It involves creating new features from existing data to improve the predictive power of the model. One such feature is the total number of days a student was registered for a course namely *total_reg.days*. This feature is derived by subtracting the *registration_date* from the *unregistration_date* in *student.registration.csv*.

Transformer Encoder Model for Sequential Prediction of Student Performance Based on Their Log Activities

SRI SUNING KUSUMAWARDANI^{1b}, (Member, IEEE),

AND SYUKRON ABU ISHAQ ALFAROZI^{1b}, (Member, IEEE)

Department of Electrical and Information Engineering, Universitas Gadjah Mada, Yogyakarta 55281, Indonesia

Corresponding author: Sri Suning Kusumawardani (suning@ugm.ac.id)

TABLE 3. Performance comparison of different time period between models with a positional encoding module versus without positional encoding module. The overall performance is the average performance of the daily prediction.


Models	Stages and Performance (%)												AD(a, b)	
	20%		40%		60%		80%		100%		Overall			
	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1	Acc	F1
f-pd daily ^a	*77.27	*52.25	*82.75	*67.43	*86.87	*75.55	*89.59	*81.53	*91.34	*85.58	*83.58	*67.84	**5.66	**16.52
f-pd daily pe ^b	71.09	39.71	75.89	55.98	82.19	66.36	83.55	70.02	83.46	69.79	77.92	51.33		
w-pd daily ^a	*82.93	*67.80	*90.27	*83.47	*94.52	*90.88	*96.69	*94.67	*98.14	*97.08	*89.59	*80.82	**4.78	**12.92
w-pd daily pe ^b	73.61	55.13	84.70	73.22	90.98	85.03	92.75	88.30	93.25	89.13	84.81	67.90		
fw-pd daily ^a	*75.41	*71.50	*82.83	*80.91	*88.23	*86.77	*90.78	*89.93	*93.42	*93.01	*83.03	*81.02	**5.75	**6.37
fw-pd daily pe ^b	67.40	64.82	75.99	71.67	83.28	80.48	86.49	84.60	86.85	84.94	77.28	74.65		

^abetter than the other model based on numerical value. A positive AD indicates that model *a* is better, otherwise model *b* is better for a negative AD.

^b**significantly different based on statistical testing with p-value < 0.01


XAI (IA EXPLICABLE)

AUTOENCODER



Ventana temporal	Acción principal (estáticas/acumulativas)
Semanas 1-8	Envío de un correo de seguimiento inicial con orientación sobre el arranque del curso, organización del trabajo y recursos de apoyo.
Semanas 10-20	Envío de una alerta personalizada al detectar retrasos en entregas, inactividad o empeoramiento del rendimiento, junto con una tutoría breve de seguimiento.
Semanas 21-28	Contacto individual urgente para reactivar la participación y priorizar tareas pendientes, con acompañamiento intensivo de cierre si es necesario.

Ventana temporal	Acción complementaria (secuenciales)
Semanas 1-8	Envió de correo para animar a participar en los foros y tutoriales para conocer la página de inicio de la plataforma universitaria.
Semanas 10-20	Mensaje de seguimiento si se observa un patrón de uso irregular o fragmentado en actividades concretas del curso.
Semanas 21-28	Mensaje de reenganche centrado en tareas finales cuando la interacción en la plataforma sea residual o poco sostenida.



CONCLUSIONES PRINCIPALES

HALLAZGOS CLAVE

- De Híbrido a Complementario.
- Autoencoders > PCA
- Contexto en Transformers: El rendimiento mejora drásticamente al combinar series temporales (interacciones) con variables estáticas y acumulativas.
- XAI (SHAP/Atención): Caja negra → Explicación

– LIMITACIONES CRÍTICAS

- Dependencia OULAD
- Señales invisibles.
- Posibilidad de sobreingeniería (cesgada por objetivos académicos).

CONCLUSIONES Y HALLAZGOS

LÍNEAS DE TRABAJO A FUTURO

- Validación externa: Testeo en otros LMS e instituciones.
- Mejorar UX para docentes.
- Refinamiento de acciones pedagógicas con expertos en la materia.
- Sistema de retroalimentación año tras año.

MUCHAS GRACIAS